


## 1. 확률, 확률분포

조건부 확률	$C_1 \subset S$ 에서 $C_1$ 를 새로운 표본 공간으로 설정 $\rightarrow C_2 \subset S$ 에 대해 1. $P(C_2 C_1) = P(C_1 \cap C_2 C_1) = \frac{P(C_1 \cap C_2)}{P(C_1)} \Leftrightarrow P(C_1 \cap C_2) = P(C_2 C_1) P(C_1)$ 2. Bayes ( $C_i$ 는 상호 배반=disjoint, $S$ 의 partition) 1) Law of total prob: $P(A) = \sum P(A \cap C_i) = \sum P(A   C_i) P(C_i)$ 2) Bayes' theorem: $P(C_i   A) = \frac{P(A \cap C_i)}{P(A)} = \frac{P(A   C_i) P(C_i)}{\sum P(A   C_i) P(C_i)}$
독립성	1) $P(C_i)$ : $C_i$ 사전확률 (prior) 2) $P(C_i   A)$ : $C_i$ 사후확률 (posterior) $\leftarrow$ 표본 A에서 관찰된 $C_i$ 3) 독립성: $P(A \cap B \cap C) = P(A)P(B)P(C)$ 이면 A,B,C는 statistically independent
확률 변수	1. Prob mass function; PMF (discrete) $\rightarrow$ CDF of PMF: $F(x) = P((-\infty, x]) = \sum_{(-\infty, x]} p(x)$ *변환: $p_y(y) = p_x(w(y))$ ; 1-on-1 function $x = w(y)$ 2. Prob density function; PDF (continuous) $>0$ 1) $F(x) = \int_{-\infty}^x f(t)dt \Leftrightarrow 2) \frac{d}{dx}F(x) = f(x)$ ( $F$ 는 $f$ 의 CDF) 3) $P([a, b]) = \int_a^b f(x)dx = F(b) - F(a)$ *변환: $X$ 가 pdf $f_X$ on $S_X$ & $Y$ 가 pdf $f_Y$ on $S_Y$ ; 1-on-1 $w(y) = x$ $\rightarrow f_Y(y) = f_X(w(y)) dx/dy  \Leftrightarrow f_Y(y) = f_X(w(y)) \text{abs}(J)$ (Jacobian: $J= w'(y) $ / $J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{vmatrix}$ ) * $J$ 는 행렬식 * Support(받침): PDF $\neq 0$ 인 space // *CDF는 유일 for PDF, PMF
기대값	1. 조건: $E( X )$ 존재 $\Leftrightarrow$ ① 연속 pdf 존재 ② $\int_{-\infty}^{\infty}  x f(x)dx < \infty$ (이산 pmf 존재 $\rightarrow \sum  x_i  p_i(x) < \infty$ ) 2. 기대값: 1) $E(X) = \int_{-\infty}^{\infty} x f(x)dx$ 2) $E(X) = \sum x_i p(x_i)$ 3. $y = g(x)$ : 1) $E(g(x)) = \int_{-\infty}^{\infty} g(x)f(x)dx$ & $E(g(x)) = \sum g(x_i)p(x_i)$ 2) $E(k_1g_1(x) + k_2g_2(x)) = k_1E(g_1(x)) + k_2E(g_2(x))$ 1. 평균: $\mu = E(X)$ 2. 분산: $\sigma^2 = Var(X) = E[(X - \mu)^2] = E(X^2) - \mu^2 = M''(0) - M'(0)^2$ * $Var(aX + b) = a^2Var(X)$ 3. 적률생성함수 (MGF) *조건: $t \in (-h, h)$ for $\forall h > 0 \leftarrow 0$ 을 포함하는 개구간에서 mgf 존재 1) $M(t) = E(e^{tx}) \rightarrow M_X(0)^{(r)} = E(X^r)$ *분포의 $r$ 차 moment ① $M(0)^{(r)} = \frac{d^r}{dt^r} \int_{-\infty}^{\infty} e^{tx} f(x)dx \big _{t=0} = \int_{-\infty}^{\infty} \frac{d^r}{dt^r} e^{tx} f(x)dx \big _{t=0} = \int_{-\infty}^{\infty} x^r e^{tx} f(x)dx \big _{t=0} = \int_{-\infty}^{\infty} x^r f(x)dx = E(X^r)$ ② $M(0)^{(r)} = \frac{d^r}{dt^r} \sum e^{tx_i} p(x_i) \big _{t=0} = \sum \frac{d^r}{dt^r} e^{tx_i} p(x_i) = \sum x_i^r e^{tx_i} p(x_i) \big _{t=0} = \sum x_i^r p(x_i) = E(X^r)$ 2) 성질 ① MGF의 유일성: $M_X(t) = M_Y(t) \Leftrightarrow X = Y$ (pdf 동일) ② $M_{X+\alpha}(t) = e^{at} M_X(t) \quad \because M_{X+\alpha}(t) = E(e^{t(x+\alpha)}) = e^{at} E(e^{tx}) = e^{at} M_X(t)$ ③ $M_{\alpha X}(t) = M_X(at) \quad \because M_{\alpha X}(t) = E(e^{t(\alpha X)}) = E(e^{(\alpha t)X}) = M_X(\alpha t)$ ④ $M_{aX+b}(t) = e^{bt} M_X(at)$ ⑤ $M_Y(t) = \prod M_{X_i}(k_i t), \quad t <  \min(h_i) $ (for $Y = \sum k_i X_i, \quad X_i$ 는 모두 독립) ⑥ $M_Y(t) = [M(t)]^n$ (for $Y = \sum X_i, \quad X_i$ 는 iid 확률변수)
중요한 부등식	1. $E(X^m)$ 이 존재하면 $\rightarrow E(X^k)$ 존재 for $k \leq m$ *증명: $E(X^k) = \int_{-\infty}^{\infty}  x ^k f(x)dx = \int_{ x  \leq 1}  x ^k f(x)dx + \int_{ x  \geq 1}  x ^k f(x)dx \leq \int_{ x  \leq 1} f(x)dx + \int_{ x  \geq 1}  x ^m f(x)dx \leq \int_{-\infty}^{\infty} f(x)dx + \int_{-\infty}^{\infty}  x ^m f(x)dx \leq 1 + E(X^m) \quad \therefore$ 유한함 2. Markov: $P[u(X) \geq c] \leq E[u(X)]/c$ (for $u(X) \geq 0, c > 0; E[u(X)]$ 존재) *증명: $E[u(x)] = \int_{-\infty}^{\infty} u(x)f(x)dx \geq \int_{u(x) \geq c} u(x)f(x)dx \geq c \int_{u(x) \geq c} f(x)dx = c P[u(x) \geq c]$ 3. Chebyshev: $P( X - \mu  \geq k\sigma) \leq 1/k^2$ (for $k > 0; X$ 가 $\mu, \sigma^2$ (유한) 가짐) *증명: Markov에서 $u(X) = (X - \mu)^2, c = k^2 \sigma^2$

## 2-1. 이변량분포

이변수	<p>1) Joint CDF: <math>F(x, y) = P(\{X \leq x\} \cap \{Y \leq y\})</math>      * <math>\mathbf{X} = (X, Y)^T \in D</math>; <b>Random vector X</b></p> <p>* <math>P((a_1, a_2] \times (b_1, b_2]) = F(a_2, b_2) - F(a_1, b_2) - F(a_2, b_1) + F(a_1, b_1) = \int_{b_1}^{b_2} \int_{a_1}^{a_2} f(x, y) dx dy</math></p> <p>2) Joint PMF: <math>\sum_y \sum_x p(x, y) = 1</math></p> <p>3) Joint PDF: <math>F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(x, y) dy dx</math>    (<math>\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1</math>)  <math>\Leftrightarrow \frac{\partial^2(F)}{\partial x \partial y} = f(x, y)</math></p> <p>4) Marginal dist: 한 변수의 효과만 봄; 다른 변수는 <math>(-\infty, \infty)</math> 전부 포괄          * <math>F_X(x) = P(\{X \leq x\}) = P(\{X \leq x\} \cap \{-\infty &lt; Y &lt; \infty\})</math>          ① PMF of x: <math>F_X(x) = \sum_{(-\infty, x]} \{\sum_{y \in (-\infty, \infty)} p(x, y)\} \rightarrow p_X(x) = \sum_{y \in (-\infty, \infty)} p(x, y)</math>          ② PDF of x: <math>F_X(x) = \int_{-\infty}^x \{\int_{-\infty}^{\infty} f(x, y) dy\} dx \rightarrow f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy</math></p>
이변수 기대값	<p>* <math>E(g(X, Y))</math> 존재 조건 <math>\Leftrightarrow E( g(X, Y) ) &lt; \infty</math></p> <p>기대값: <math>E(g(X, Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy</math> (이산형: <math>E(g(X, Y)) = \sum \sum g(x, y) p(x, y)</math>)</p> <p>1) <math>E(k_1 g_1 + k_2 g_2) = k_1 E(g_1) + k_2 E(g_2)</math>      2) <math>E(\mathbf{X}) = [E(X) \ E(Y)]^T = [\int_{-\infty}^{\infty} x f_X(x) dx \ \int_{-\infty}^{\infty} y f_Y(y) dy]^T</math></p> <p>3) <math>M(t_1, t_2) = E(\exp(t_1 X + t_2 Y)) \rightarrow \mathbf{t} = (t_1, t_2)^T</math>에 대해 <math>M(\mathbf{t}) = E(\exp(\mathbf{t}^T \mathbf{X}))</math>  <math>E(X^k Y^m) = \frac{\partial^{k+m}}{\partial t_1^k \partial t_2^m} M(0, 0) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^k y^m \exp(t_1 x + t_2 y) f(x, y) dx dy</math></p>
이변수 변환	<p>* 변환 조건: 1) <math>\mathbf{X} = (X_1, X_2)</math>의 받침 S      2) <math>S \rightarrow T</math> 사상하는 일대일 대응: <math>y_1 = u_1(x_1, x_2)</math> &amp; <math>y_2 = u_2(x_1, x_2)</math>          3) <math>T \rightarrow S</math> 사상하는 위 대응 역: <math>x_1 = w_1(y_1, y_2)</math> &amp; <math>x_2 = w_2(y_1, y_2)</math></p> <p>1. 이산형 변환: <math>p_Y(y_1, y_2) = p_X[w_1(y_1, y_2), w_2(y_1, y_2)]</math> for <math>(y_1, y_2) \in T</math> &amp; 나머지 pmf 0          * <math>X_1, X_2 \rightarrow Y</math>로만 변환 시, dummy 변수를 하나 더 만들어 <math>Y_2</math>로 지정해주고 marginal Y dist를 구함</p> <p>2. 연속형 변환: <math>f_Y(y_1, y_2) = f_X[w_1(y_1, y_2), w_2(y_1, y_2)]  J </math> for <math>(y_1, y_2) \in T</math> &amp; 나머지 pdf 0          * MGF 이용 변환: <math>E(\exp(tY)) = E(\exp(t(X_1 + X_2))) \rightarrow</math> MGF 유일성으로 Y의 PMF/PDF 구함</p>
조건부	<p>1. 조건부 PMF: <math>p_{2 1}(x_2 x_1) = \frac{p(x_1, x_2)}{p_1(x_1)}</math></p> <p>2. 조건부 PDF: <math>f_{2 1}(x_2 x_1) = \frac{f(x_1, x_2)}{f_1(x_1)}</math> (<math>f_1</math>는 <math>f_{1,2}</math>의 marginal 분포)          1) <math>P(a &lt; Y &lt; b   X = x) = \int_a^b f_{Y X}(y x) dy</math> &amp; <math>P(c &lt; X &lt; d   Y = y) = \int_c^d f_{X Y}(x y) dx</math>          2) <math>P(-\infty &lt; Y &lt; \infty   X = x) = \int_{-\infty}^{\infty} f_{Y X}(y x) dy = \int_{-\infty}^{\infty} \frac{f(x, y)}{f_X(x)} dy = \frac{1}{f_X(x)} \int_{-\infty}^{\infty} f(x, y) dy = 1</math>          3) 조건부 기대값: <math>E(\mathbf{u}(Y) x) = \int_{-\infty}^{\infty} u(y) f_{Y X}(y x) dy \rightarrow \mathbf{x}</math>의 함수          ① 조건부 평균: <math>E(Y x) = \int_{-\infty}^{\infty} y f_{Y X}(y x) dy</math>      ② 조건부 분산: <math>\text{Var}(Y x) = E(Y^2 x) - [E(Y x)]^2</math></p> <p>* 정리: <math>\mu_Y</math> 추정 <math>\leftarrow E(Y X)</math>이 Y보다 더 신뢰도 높음 (Rao &amp; Blackwell)          1) <math>E[E(Y X)] = E(Y)</math>      2) <math>\text{Var}(E(Y X)) \leq \text{Var}(Y)</math>      * Y 분산 유한</p> <p>* 증명: <math>E(Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dy dx = \int_{-\infty}^{\infty} [\int_{-\infty}^{\infty} y f_{Y X}(y x) dy] f_X(x) dx = \int_{-\infty}^{\infty} E(Y X) f_X(x) dx = E(E(Y X))</math></p>
공분산 / 상관 계수	<p>1. 공분산: <math>\text{Cov}(\mathbf{X}, \mathbf{Y}) = E[(\mathbf{X} - \mu_X)(\mathbf{Y} - \mu_Y)] = E(\mathbf{XY}) - E(\mathbf{X})E(\mathbf{Y})</math>      * 독립이면 <math>\text{Cov}(\mathbf{X}, \mathbf{Y}) = 0 \Leftrightarrow E(\mathbf{XY}) = E(\mathbf{X})E(\mathbf{Y})</math></p> <p>2. 상관계수: <math>\rho = \frac{\text{Cov}(\mathbf{X}, \mathbf{Y})}{\sigma_X \sigma_Y} = \sigma_{XY} / (\sigma_X \sigma_Y)</math> (<math>-1 \leq \rho \leq 1</math>) <math>\rightarrow y = a + bx</math> (<math>b &gt; 0</math>)에 <math>\rho</math>의 강도로 집중 (<math>0 &lt; \rho \leq 1</math>)</p> <p>3. 선형조건부평균: <math>E(Y X) = a + bx \rightarrow E(Y X) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X)</math> &amp; <math>E(\text{Var}(Y X)) = \sigma_Y^2 (1 - \rho^2)</math>          * 회귀분석 모회귀계수 <math>\beta = \rho(\sigma_Y / \sigma_X) = \text{Cov}(X, Y) / \text{Var}(X)</math> ;      * X, Y 분산 유한</p>
독립	<p>* 정의: <math>f(x, y) = f_X(x) f_Y(y) \Leftrightarrow \mathbf{X}, \mathbf{Y}</math>는 독립 [<math>x \in (a, b)</math> &amp; <math>y \in (c, d)</math>] (받침이 수평/수직선 box에 존재해야 함)</p> <p>1. 조건부 증명: <math>f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \int_{-\infty}^{\infty} f_{Y X}(y x) f_X(x) dx = f_{Y X}(y x) \int_{-\infty}^{\infty} f_X(x) dx = f_{Y X}(y x)</math></p> <p>2. 동치류          1) <math>f(x, y) = f_X(x) f_Y(y)</math>          2) <math>F(x, y) = F_X(x) F_Y(y)</math>      * 증명: <math>\partial^2 F / \partial x \partial y = f_X(x) f_Y(y)</math>          3) <math>P(a &lt; X &lt; b, c &lt; Y &lt; d) = P(a &lt; X &lt; b) P(c &lt; Y &lt; d)</math>          * 증명: <math>P(a &lt; X &lt; b, c &lt; Y &lt; d) = F(b, d) - F(a, d) - F(b, c) + F(a, c) = [F_X(b) - F_X(a)][F_Y(d) - F_Y(c)]</math>          4) <math>E[u(X)v(Y)] = E[u(X)] E[v(Y)] \Rightarrow E(XY) = E(X)E(Y) \Leftrightarrow \text{Cov}(X, Y) = 0</math>          5) <math>M(t_1, t_2) = M(t_1, 0) M(0, t_2)</math>      * 증명: <math>M(t_1, t_2) = E(e^{t_1 X + t_2 Y}) = E(e^{t_1 X}) E(e^{t_2 Y}) = M(t_1, 0) M(0, t_2)</math>          * <math>M(t_1, 0)</math>는 x에 대한 marginal 분포의 MGF</p>



## 2-2. 다변량분포

다변수	<p>* <math>\mathbf{x} = (x_1, x_2, \dots, x_p)^T = (X_1(c), X_2(c), \dots, X_p(c))^T</math> for 확률 실험 <math>c \in C</math></p> <p>1. 결합 확률 함수들</p> <p>1) Joint CDF: <math>F(\mathbf{x}) = P[\{X_1 \leq x_1\} \cap \{X_2 \leq x_2\} \cap \dots \cap \{X_p \leq x_p\}]</math></p> <p>2) Joint PMF <math>F(\mathbf{x}) = \sum_{w_1 \leq x_1} \dots \sum_{w_p \leq x_p} p(w_1, \dots, w_p)</math></p> <p>3) Joint PDF: <math>F(\mathbf{x}) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_p} f(x_1, \dots, x_p) dx_p \dots dx_1 \quad (\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_p \dots dx_1 = 1)</math>  <math>\Leftrightarrow \frac{\partial^p \{F(\mathbf{x})\}}{\partial x_1 \dots \partial x_p} = f(\mathbf{x})</math></p>
	<p>2. Marginal/Conditional</p> <p>1) <math>f_1(x_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_2 \dots dx_p</math>  <math>\rightarrow f_{2, \dots, p 1}(x_2, \dots, x_p   x_1) = \frac{f(\mathbf{x})}{f_1(x_1)}</math></p> <p>2) <math>f_{2,4,5}(x_2, x_4, x_5) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(\mathbf{x}) dx_1 dx_3 dx_6 \quad \leftarrow \mathbf{x} = (x_1, x_2, x_3, x_4, x_5, x_6)^T</math>  <math>\rightarrow f_{1,3,6 2,4,5}(x_1, x_3, x_6   x_2, x_4, x_5) = \frac{f(\mathbf{x})}{f_{2,4,5}(x_2, x_4, x_5)}</math></p>
	<p>3. 기대값</p> <p>1) <math>E(u(\mathbf{x})) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(x_1, \dots, x_p) dx_1 \dots dx_p</math> (존재성: <math>\exists E( u(\mathbf{x}) )</math>) *이산: <math>E(u(\mathbf{x})) = \sum_{x_1} \dots \sum_{x_p} u(x_1, \dots, x_p)</math></p> <p>2) <math>E(\sum k_i Y_i) = \sum k_i E(Y_i)</math></p> <p>3) <math>E[u(X_2, \dots, X_p)   x_1] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(x_2, \dots, x_p) f_{2, \dots, p 1}(x_2, \dots, x_p   x_1) dx_2 \dots dx_p</math></p>
	<p>4. 독립: <math>E(\prod u_i(X_i)) = \prod E(u_i(X_i))</math> 등 동치류 (<math>f, F, P, E, M</math>)  *iid (independent and identically distributed): 여러 확률 변수가 서로 독립 &amp; 동일한 분포</p>
	<p>5. 변환: <math>\mathbf{X}</math>의 받침 <math>S</math>에 대해, <math>\mathbf{X} \Leftrightarrow \mathbf{Y}</math>가 일대일이 되는 <math>S_1, \dots, S_k</math>의 부분 공간 상 각각의 야코비안 <math>J_i</math> 정의</p> $g(\mathbf{y}) = \sum_{i=1}^k  J_i  f[w_{1i}(\mathbf{x}), \dots, w_{pi}(\mathbf{x})]$
Random matrix	<p>* <b>Random matrix</b> <math>\mathbf{W} = [W_{ij}]</math>, <math>W_{ij}</math> (<math>1 \leq i \leq m</math>, <math>1 \leq j \leq n</math>)</p> <p>1. <math>E(\mathbf{W}) = [E(W_{ij})]</math> (일렬로 배열하여 <math>m \times n</math>의 벡터로 생각)</p> <p>1) <math>E[\mathbf{A}\mathbf{W} + \mathbf{B}\mathbf{V}] = \mathbf{A}E[\mathbf{W}] + \mathbf{B}E[\mathbf{V}]</math> (<math>\mathbf{A}, \mathbf{B}</math>: <math>k \times m</math> 상수 행렬, <math>\mathbf{W}, \mathbf{V}</math>: <math>m \times n</math> 확률 행렬)</p> <p>2) <math>E[\mathbf{A}\mathbf{W}\mathbf{B}] = \mathbf{A}E(\mathbf{W})\mathbf{B}</math> (<math>\mathbf{A}</math>: <math>k \times m</math>, <math>\mathbf{W}</math>: <math>m \times n</math>, <math>\mathbf{B}</math>: <math>n \times l</math>)</p> <p>2. 분산-공분산 행렬 (Variance-Covariance matrix) *<math>\mathbf{X} = (X_1, X_2, \dots, X_p)^T</math>; 모든 VCM는 양의 반정부호(psd)</p> <p>1) 정의: <math>\text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = [\sigma_{ij}]</math> (<math>\boldsymbol{\mu} = E(\mathbf{X})</math>)  <math>\rightarrow \sigma_i^2 = \text{Var}(X_i)</math> &amp; <math>\sigma_{ij} = \text{Cov}(X_i, X_j)</math></p> <p>2) 정리 ① <math>\text{Cov}(\mathbf{X}) = E(\mathbf{X}\mathbf{X}^T) - \boldsymbol{\mu}\boldsymbol{\mu}^T</math> (<math>\sigma_i^2 &lt; \infty</math>)  ② <math>\text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A}\text{Cov}(\mathbf{X})\mathbf{A}^T</math> (<math>\sigma_i^2 &lt; \infty</math>, <math>\mathbf{A}</math>: <math>m \times p</math>)</p> <p>3. MGF: <math>M(\mathbf{t}) = E[\exp(\mathbf{t}^T \mathbf{X})] = E[\prod_{i=1}^p \exp(t_i X_i)]</math> (*<math>X_i</math> 독립 <math>\rightarrow M(\mathbf{t}) = M(t_1, \dots, 0) \dots M(0, \dots, t_p) = \prod_{i=1}^p E[\exp(t_i X_i)]</math>)</p> <p>1) <math>M_Y(\mathbf{t}) = \prod M_{X_i}(\mathbf{t})</math> (<math>\mathbf{Y} = \sum \mathbf{X}_i</math>, 각 <math>\mathbf{X}_i \in \mathbb{R}^n</math>은 독립)</p> <p>2) <math>M_Y(\mathbf{t}) = e^{\mathbf{b}^T \mathbf{t}} M_X(\mathbf{A}^T \mathbf{t})</math> (<math>\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}</math>; <math>\mathbf{A}</math>: <math>m \times p</math>; <math>\mathbf{t} \in \mathbb{R}^m</math>; <math>\mathbf{b} \in \mathbb{R}^m</math>)</p> <p>3. 선형결합: <math>T = \sum_{i=1}^n a_i X_i</math>, <math>W = \sum_{i=1}^m b_i Y_i</math></p> <p>1) <math>E(T) = \sum_{i=1}^n a_i E(X_i)</math> (*<math>E[ X_i ] &lt; \infty</math>)</p> <p>2) <math>\text{Cov}(T, W) = \sum \sum a_i b_j \text{Cov}(X_i, Y_j)</math> (*<math>E[X_i^2] &lt; \infty</math>, <math>E[Y_j^2] &lt; \infty</math>)</p> <p>① <math>\text{Var}(T) = \text{Cov}(T, T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i &lt; j} a_i a_j \text{Cov}(X_i, X_j)</math> (*<math>E[X_i^2] &lt; \infty</math>)</p> <p>② <math>\text{Var}(T) = \text{Cov}(T, T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i)</math> (*<math>X_1, \dots, X_n</math>이 유한 분산, 독립)</p> <p>3) 표본 추정량: <math>X_1, \dots, X_n</math>이 <math>\mu, \sigma^2</math> 가지는 iid 확률변수</p> <p>① 표본평균: <math>\bar{X} = \sum_{i=1}^n X_i / n</math> &amp; 표본분산: <math>S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1) = \sum X_i^2 - n\bar{X}^2 / (n-1)</math></p> <p>② <math>E(\bar{X}) = \sum_{i=1}^n E(X_i) / n = n\mu / n = \mu</math> &amp; <math>\text{Var}(\bar{X}) = \sum_{i=1}^n (\frac{1}{n})^2 \text{Var}(X_i) = n(\frac{1}{n})^2 \sigma^2 = \sigma^2 / n</math></p> <p>③ <math>E(S^2) = \sum E(X_i^2) - nE(\bar{X}^2) / (n-1) = \frac{n(\mu^2 + \sigma^2) - n(\mu^2 + \frac{\sigma^2}{n})}{n-1} = \sigma^2</math>  (<math>\bar{X}</math>, <math>S^2</math>는 독립 by Student's 정리)</p>

### 3-1. 주요 분포: 이산

이항 분포	<p>* Bernoulli experiment: 성공/실패로 서로 배반인 확률 실험</p> <p>* Bernoulli trial: 베르누이 실험을 독립적으로 반복 (성공 확률 <math>p</math> 동일)</p> <p>* Bernoulli distribution의 유도: <math>X(\text{성공})=1, X(\text{실패})=0 \rightarrow \text{PMF: } p(x) = p^x(1-p)^{1-x} \quad * \mu = p, \sigma^2 = p(1-p)</math></p>
	<p>* <b>Binomial distribution (이항분포):</b> <math>n</math>회 반복한 베르누이 시행에서 <b>성공한 총 횟수</b> 분포</p> <p>1. PMF: <math>p(x) = \binom{n}{x} p^x (1-p)^{n-x} \sim b(n, p) \quad (x = 0, 1, \dots, n)</math></p> <p>2. MGF: <math>M(t) = \sum e^{tx} p(x) = [(1-p) + (pe^t)]^n \quad (t \in \mathbb{R})</math></p> <p>3. 기대값 1) <math>\mu = np</math> <span style="margin-left: 100px;"><math>* \mu = M'(0) = n[(1-p) + pe^t]^{n-1}(pe^t) _{t=0} = np</math></span></p> <p style="margin-left: 150px;">2) <math>\sigma^2 = np(1-p)</math> <span style="margin-left: 100px;"><math>* \sigma^2 = M''(0) - (M'(0))^2 = n(n-1)p^2 + np - (np)^2 = np(1-p)</math></span></p> <p>4. 가법성: <math>Y = \sum X_i, X_i \sim B(n_i, p) \rightarrow Y \sim B(\sum n_i, p)</math>          (증명) <math>M_Y(t) = \prod M_{X_i}(t) = \prod [(1-p) + (pe^t)]^{n_i} = [(1-p) + (pe^t)]^{\sum n_i}</math></p> <p>* <math>p(x)</math>가 성공확률(= 평균) <math>p</math>인 Bernoulli분포 <math>\leftrightarrow X \sim B(1, p)</math>  <math>\rightarrow Y = \sum_{i=1}^{20} X_i</math> (iid)에 대해 <math>p(y)</math>는 20회 시행 중 평균 20<math>p</math>회 성공하는 Bernoulli <math>\leftrightarrow Y \sim B(20, p)</math></p>
	<p>* <b>Multinomial distribution (다항분포)</b></p> <p>1. PMF: <math>p(x_1, \dots, x_{k-1}) = \frac{n!}{(x_1)! \dots (x_k)!} (p_1)^{x_1} \dots (p_k)^{x_k} \rightarrow p_k = 1 - \sum_{i=1}^{k-1} p_i \text{ \&amp; } x_k = n - \sum_{i=1}^{k-1} x_i</math></p> <p>2. MGF: <math>M(t_1, \dots, t_{k-1}) = (p_1 e^{t_1} + \dots + p_{k-1} e^{t_{k-1}} + p_k)^n</math></p>
	<p>* R codes 1) dbinom (k,n,p): <math>P(X=k)</math> 2) pbinom (k,n,p): <math>P(X \leq k)</math></p>
	<p>* <b>Negative binomial distribution (음이항분포):</b> <math>X</math>번 실패 후 <math>r</math>번 성공 (베르누이 시행) *<math>r</math>번 성공시 나감</p> <p>1. PMF: <math>p(x) = \binom{x+r-1}{r-1} p^r (1-p)^x</math> 2. MGF: <math>M(t) = p^r [1 - (1-p)e^t]^{-r} \quad (e^t &lt; 1/(1-p))</math>  <math>\Leftrightarrow</math> [이항: <math>x+(r-1)</math>번 중 <math>(r-1)</math>번 성공] <math>\times [p]</math> <span style="margin-left: 50px;"><math>* \binom{-n}{k} = (-n)(-n-1)\dots(-n-k+1)/k! = (-1)^k \binom{n+k-1}{k}</math></span></p>
	<p>* <b>Geometric distribution (기하 분포):</b> <math>X</math>번 실패 후 처음 성공 (베르누이 시행) <math>\Leftrightarrow r=1</math>인 음이항분포</p> <p>1. PMF: <math>p(x) = p(1-p)^x</math> 2. MGF: <math>M(t) = p[1 - (1-p)e^t]^{-1}</math></p>
Poisson 분포	<p>* <b>Hypergeometric distribution (초기하분포)</b></p> <p>1. PMF: <math>p(x) = \frac{\binom{D}{x} \binom{N-D}{n-x}}{\binom{N}{n}}</math> <span style="margin-left: 50px;"><math>* N</math>개 중 <math>D</math>개가 성공 &amp; <b>비복원추출:</b> <math>n</math>번 시행 <math>\rightarrow x</math>번 성공 확률</span></p> <p>2. 기대값: 1) <math>\mu = n \left(\frac{D}{N}\right)</math> 2) <math>\sigma^2 = n \left(\frac{D}{N}\right) \left(1 - \frac{D}{N}\right) \frac{(N-n)}{(N-1)}</math> <span style="margin-left: 50px;"><math>N \gg n</math>이면 이항분포로 근사 가능</span></p>
	<p>* Poisson process: 일정한 구간 (시간, 공간)에서 독립적으로 발생하는 event를 생성하는 과정 (<b>비기역성</b>)</p> <p>* Poisson postulate: 짧은 구간 <math>h</math> (<math>h \rightarrow 0</math>)에 대해</p> <p>1) <math>g(1, h) = \lambda h + o(h)</math> <span style="margin-left: 50px;"><math>* g(x, w)</math>는 구간 길이 <math>w</math> 내에 <math>x</math>회 발생 확률</span></p> <p>2) <math>\sum_{x=2}^{\infty} g(x, h) = o(h)</math> (<math>\approx</math> 미소 구간 <math>h</math>에 둘 이상은 본질적 불가) <span style="margin-left: 50px;"><math>* \lim_{h \rightarrow 0} o(h)/h = 0</math> (little-o)</span></p> <p>3) 겹치지 않는 구간 <math>\rightarrow</math> 확률적으로 독립 <span style="margin-left: 100px;"><math>\therefore g(x, w) = \frac{e^{-\lambda w} (\lambda w)^x}{x!}</math></span></p>
	<p>1. PMF: <math>p(x) = \frac{e^{-\mu} \mu^x}{x!} \quad (x = 0, 1, 2, \dots)</math> (<math>* \sum p(x) = e^{-\mu} \sum \left(\frac{\mu^x}{x!}\right) = e^{-\mu} e^{\mu} = 1</math>) <math>\leftarrow</math> 주어진 시간에 <math>x</math>회 발생 분포</p> <p>2. 기댓값: <math>\mu = \sigma^2 = \lambda w</math> (<math>\lambda</math> 단위 길이당 발생률, <math>w</math>: 주어진 영역 크기)</p> <p>3. MGF: <math>M(t) = e^{\mu(e^t-1)} \quad (t \in \mathbb{R})</math></p> <p>4. 가법성: <math>Y = \sum X_i, X_i \sim \text{Poi}(m_i) \rightarrow Y \sim \text{Poi}(\sum m_i)</math>          (증명) <math>M_Y(t) = \prod M_{X_i}(t) = \prod e^{m_i(e^t-1)} = e^{(\sum m_i)(e^t-1)}</math></p> <p>* <math>p(x)</math>가 주어진 100초당 평균 <math>\mu</math>회 발생 Poisson <math>\leftrightarrow X \sim \text{Poi}(\mu)</math>  <math>\rightarrow Y = \sum_{i=1}^{20} X_i</math> (iid)에 대해 <math>p(y)</math>는 주어진 20 <math>\times</math> 100초당 평균 20<math>\mu</math>회 발생 Poisson <math>\leftrightarrow Y \sim \text{Poi}(20\mu)</math></p>
	<p>* 이항분포 <math>b(n, p) \xrightarrow{D}</math> 푸아송분포 (<math>\mu = np</math>) (MGF의 극한으로 분포수렴 증명)</p>
	<p>* R codes 1) dpois (k,m): <math>P(X=k)</math> 2) ppois (k,m): <math>P(X \leq k)</math></p>

### 3-2. 주요 분포: 감마 연관 분포

Γ 분포	<p>* 감마함수: <math>\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y} dy</math> (<math>\alpha &gt; 0</math>)</p> <p>* <math>\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1) \rightarrow \Gamma(n) = (n - 1)!</math> for 자연수 n      * <math>\Gamma(1) = 1, \Gamma(1/2) = \sqrt{\pi}</math></p> <p>* 스텔링 근사: <math>\Gamma(k + 1) \approx \sqrt{2\pi k} \left(\frac{k}{e}\right)^k</math></p>
	<p>* <b>Gamma distribution (감마분포):</b> <math>\alpha (\in \mathbb{R})</math> 번째 Poisson event 발생까지 걸리는 대기 시간</p> <p>1. PDF: <math>f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \sim \Gamma(\alpha, \beta)</math> (<math>0 \leq x &lt; \infty</math>) (감마함수 식에 <math>y = x/\beta</math> 대입; <math>\alpha &gt; 0</math> &amp; <math>\beta &gt; 0</math>)</p> <p>2. 기댓값: 1) <math>\mu = \alpha\beta</math>, 2) <math>\sigma^2 = \alpha\beta^2</math></p> <p>3. MGF: <math>M(t) = 1/(1 - \beta t)^\alpha</math> (<math>t &lt; 1/\beta</math>)</p> <p>4. 가법성: <math>Y = \sum X_i, X_i \sim \Gamma(\alpha_i, \beta) \rightarrow Y \sim \Gamma(\sum \alpha_i, \beta)</math> (증명) <math>M_Y(t) = \prod M_{X_i}(t) = \prod (1 - \beta t)^{-\alpha_i} = (1 - \beta t)^{-\sum \alpha_i}</math></p> <p>5. 스칼라배: <math>X \sim \Gamma(\alpha, \beta) \Rightarrow kX \sim \Gamma(\alpha, k\beta)</math> (*증명: 야코비안 변수변환)</p> <p>6. 유도: k번 Poisson event 발생까지 시간을 <math>T_i</math>로 분할 <math>\rightarrow</math> 각 <math>T_i \sim \Gamma(1, \frac{1}{\lambda}) \rightarrow Y = \sum_{i=1}^k T_i \sim \Gamma(k, \frac{1}{\lambda})</math> (*Erlang 분포: 자연수 k인 감마 분포)</p>
	<p>* R codes 1) dgamma (x, shape=a, scale=b): <math>f(X=x)</math> 2) pgamma (x, shape=a, scale=b): <math>P(X \leq x)</math></p>
지수 분포	<p>* <b>Exponential distribution (지수분포):</b> 1번째 Poisson event 발생까지 대기 시간 = <math>\Gamma(1, \beta)</math></p> <p>1. PDF: <math>f(x) = \frac{1}{\beta} e^{-x/\beta}</math> 2. 기댓값: 1) <math>\mu = \beta</math>, 2) <math>\sigma^2 = \beta^2</math></p> <p>3. 유도: W가 첫 번째 Poisson event 까지 걸린 시간  <math>\rightarrow</math> w시간 내 푸아송 사건 없을 확률: <math>P(W &gt; w) = \frac{e^{-\lambda w} (\lambda w)^0}{0!} = e^{-\lambda w} \Leftrightarrow P(0 &lt; W &lt; w) = 1 - e^{-\lambda w}</math>  <math>\therefore f(w) = \lambda e^{-\lambda w}</math> (<math>\beta = 1/\lambda</math>)</p>
$\chi^2$ 분포	<p>* <b>Chi-square distribution (카이제곱 분포):</b> 자유도 r에 대해, <math>\chi^2(r) = \Gamma(\frac{r}{2}, 2)</math></p> <p>1. PDF: <math>f(x) = \frac{1}{\Gamma(\frac{r}{2}) 2^{\frac{r}{2}}} x^{\frac{r}{2}-1} e^{-\frac{x}{2}} \sim \chi^2(r)</math> (<math>0 \leq x &lt; \infty</math>)</p> <p>2. 기댓값: 1) <math>\mu = r</math>, 2) <math>\sigma^2 = 2r</math> 3. MGF: <math>M(t) = 1/(1 - 2t)^{r/2}</math> (<math>t &lt; 1/2</math>)</p> <p>4. <math>E(X^k) = 2^k \frac{\Gamma(\frac{r}{2} + k)}{\Gamma(\frac{r}{2})}</math>, <math>k &gt; -\frac{r}{2}</math></p> <p>5. 가법성 (corollary): <math>Y = \sum X_i, X_i \sim \chi^2(r_i) \rightarrow Y \sim \chi^2(\sum r_i)</math></p>
	<p>* R codes 1) dchisq (x,r): <math>f(X=x)</math> 2) pchisq (x,r): <math>P(X \leq x)</math></p>
β 분포	<p>* 베타함수: <math>B(\alpha, \beta) = \int_0^1 y^{\alpha-1} (1-y)^{\beta-1} dy</math> (<math>\alpha &gt; 0, \beta &gt; 0</math>)</p> <p>① <math>B(\alpha, \beta) = B(\beta, \alpha)</math>, ② <math>B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}</math></p> <p>* 결합 PDF: <math>h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-(x_1+x_2)}</math>; <math>0 \leq x_1 &lt; \infty, 0 \leq x_2 &lt; \infty</math> (<math>X_1, X_2</math> 독립)</p> <p>* <math>Y_1 = X_1/(X_1 + X_2)</math> &amp; <math>Y_2 = X_1 + X_2 \rightarrow Y_1</math>에 대한 marginal distribution이 <math>\text{beta}(\alpha, \beta)</math></p> <p>1. PDF: <math>f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}</math> (<math>0 &lt; x &lt; 1</math>)</p>
	<p>* R codes 1) dbeta(x,a,b): <math>f(X=x)</math> 2) pbeta (x,a,b): <math>P(X \leq x)</math></p>
Dirichlet 분포 (β 확장)	<p>* 결합 PDF: <math>h(x_1, \dots, x_{k+1}) = \prod_{i=1}^{k+1} \frac{1}{\Gamma(\alpha_i)} x_i^{\alpha_i-1} e^{-x_i}</math>; <math>0 \leq x_i &lt; \infty</math> (<math>X_1, \dots, X_k</math> 독립)</p> <p>* <math>Y_i = \frac{X_i}{\sum_{i=1}^{k+1} X_i}</math> (<math>i = 1, 2, \dots, k</math>) &amp; <math>Y_{k+1} = \sum_{i=1}^{k+1} X_i \rightarrow Y_1, \dots, Y_k</math>에 대한 marginal dist이 <math>\text{Dirichlet}(\alpha_1, \dots, \alpha_{k+1})</math></p> <p>1. PDF: <math>g(y_1, \dots, y_{k+1}) = \frac{\Gamma(\alpha_1 + \dots + \alpha_{k+1})}{\Gamma(\alpha_1) \dots \Gamma(\alpha_{k+1})} y_1^{\alpha_1-1} \dots y_k^{\alpha_k-1} [1 - (y_1 + \dots + y_k)]^{\alpha_{k+1}-1}</math> (<math>0 \leq y_k, \sum_{i=1}^k y_i &lt; 1</math>)</p>

### 3-3. 주요 분포: 정규 분포

정규 분포	<p>*표준정규분포: <math>I = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz \rightarrow 0 &lt; \exp\left(-\frac{z^2}{2}\right) &lt; \exp(- z  + 1)</math> 유계 <math>(\int_{-\infty}^{\infty} e^{- z +1} dz = 2e)</math></p> <p><math>\rightarrow I^2 = \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \exp\left(-\frac{x^2+y^2}{2}\right) dx dy = \frac{1}{2\pi} \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta = 1 \quad \therefore f(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right)</math></p> <p>*정규분포: <math>X = \sigma Z + \mu</math> 로 변수 변환 <math>f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}</math></p> <p>*Bell shape 분포: location 모수 (<math>\mu</math>), scale 모수 (<math>\sigma^2</math>) vs. 감마분포 등: shape 모수 (<math>\alpha</math>), scale 모수 (<math>\beta</math>)</p>
	<p><b>*표준 정규 분포 <math>N(0, 1^2)</math></b></p> <p>1. PDF: <math>\phi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \quad (-\infty &lt; z &lt; \infty)</math></p> <p>2. MGF: <math>M(t) = \exp\left(\frac{1}{2}t^2\right), t \in \mathbb{R}</math>      3. 기대값: <math>E(Z) = 0, \text{Var}(Z) = 1</math></p> <p>4. <math>E(Z^k) = \frac{k!}{2^{\frac{k}{2}} \left(\frac{k}{2}\right)!} \quad (k \text{가 짝수}), \quad E(Z^k) = 0 \quad (k \text{가 홀수}) \quad * M(t) = \exp\left(\frac{1}{2}t^2\right) = \sum_{m=0}^{\infty} \left(\frac{t^2}{2}\right)^m / m!</math></p>
	<p><b>*정규 분포 <math>N(\mu, \sigma^2)</math></b></p> <p>1. PDF: <math>f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} \quad (-\infty &lt; x &lt; \infty, \sigma &gt; 0)</math></p> <p>2. MGF: <math>M(t) = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right), t \in \mathbb{R}</math>      3. 기대값: <math>E(Z) = \mu, \text{Var}(Z) = \sigma^2</math></p> <p>4. <math>E(X^k) = E[(\sigma Z + \mu)^k] = \sum_{j=0}^k \binom{k}{j} \sigma^j E(Z^j) \mu^{k-j}</math></p> <p>5. 가법성: <math>Y = \sum a_i X_i, X_i \sim N(\mu_i, \sigma_i^2) \rightarrow Y \sim N[\sum(a_i \mu_i), \sum(a_i \sigma_i)^2]</math> (증명) <math>M_Y(t) = \prod M_{a_i X_i}(t) = \prod M_{X_i}(a_i t) = \prod \exp\left(\mu_i(a_i t) + \frac{1}{2}\sigma_i^2(a_i t)^2\right) = \exp\left((\sum a_i \mu_i)t + \frac{1}{2}(\sum a_i^2 \sigma_i^2)t^2\right)</math></p> <p>6. Corollary: <math>\bar{X} = \sum_{i=1}^n X_i / n, X_i \sim N(\mu, \sigma^2) \text{ (iid)} \rightarrow \bar{X} \sim N(\mu, \sigma^2/n)</math></p>
	<p><b>* 정리: <math>Z^2 \sim \chi^2(1)</math></b></p> <p>pf) <math>W = Z^2</math> 일 때, <math>F(x) = P(W \leq x) = P(Z^2 \leq x) = P(-\sqrt{x} \leq Z \leq \sqrt{x}), x \geq 0</math></p> <p><math>\rightarrow y = \sqrt{w}</math> 변환 시, <math>F(x) = 2 \int_0^{\sqrt{x}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right) dy = \int_0^x \frac{1}{\sqrt{2\pi}\sqrt{w}} \exp\left(-\frac{w}{2}\right) dw</math></p> <p><math>\rightarrow f(x) = \frac{1}{\sqrt{2\pi}} x^{-\frac{1}{2}} e^{-\frac{x}{2}} = \frac{1}{\Gamma(\frac{1}{2}) 2^{1/2}} x^{\frac{1}{2}-1} e^{-\frac{x}{2}} \sim \chi^2(1) \quad (0 \leq x &lt; \infty)</math></p>
	<p><b>* 따름 정리:</b> <math>Y = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)</math> (가법성 of <math>\chi^2</math> using MGF; for iid <math>Z \sim N(0, 1^2)</math>)</p>
	<p><b>* Contaminated normal distribution:</b> 대부분 <math>Z \sim N(0, 1^2)</math>, 일부 outlier <math>\sim N(0, \sigma_c^2)</math> (오염 비율: <math>\varepsilon</math>)</p> <p>1) <math>W = KZ + (1-K)\sigma_c Z</math> for <math>K = \begin{cases} 1 &amp; \text{확률 } 1-\varepsilon \\ 0 &amp; \text{확률 } \varepsilon \end{cases} \quad (Z, K \text{는 독립})</math></p> <p><math>F_W(w) = P(W \leq w) = P(W \leq w, I=1) + P(W \leq w, I=0) = P(Z \leq w)(1-\varepsilon) + P\left(Z \leq \frac{w}{\sigma_c}\right)\varepsilon = (1-\varepsilon)\Phi(w) + \varepsilon\Phi\left(\frac{w}{\sigma_c}\right)</math></p> <p>① PDF: <math>f_W(w) = (1-\varepsilon)\phi(w) + \frac{\varepsilon}{\sigma_c}\phi\left(\frac{w}{\sigma_c}\right)</math>      ② <math>E(W) = 0, \text{Var}(W) = 1 + \varepsilon(\sigma_c^2 - 1)</math></p> <p>2) <math>X = a + bW \quad (b &gt; 0)</math></p> <p>① PDF: <math>f_X(x) = (1-\varepsilon)\phi\left(\frac{x-a}{b}\right) + \frac{\varepsilon}{\sigma_c b}\phi\left(\frac{x-a}{b\sigma_c}\right)</math>      ② <math>E(W) = a, \text{Var}(W) = b^2[1 + \varepsilon(\sigma_c^2 - 1)]</math></p>
	<p>* R codes    1) dnorm(x,a,b): <math>f(X=x)</math>      2) pnorm(x,a,b): <math>P(X \leq x)</math>      (평균 a, 표준편차 b)</p>

### 3-3. 주요 분포: 정규 분포

다변량 정규 분포	<p>* <math>\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p)</math> / <math>\mathbf{z} = (Z_1, \dots, Z_p)^T \in \mathbb{R}^p \sim \text{iid } N(0,1)</math></p> <p>1) PDF: <math>f_{\mathbf{Z}}(\mathbf{z}) = \left(\frac{1}{2\pi}\right)^{p/2} \exp\left(-\frac{1}{2}\mathbf{z}^T\mathbf{z}\right)</math> pf <math>f_{\mathbf{Z}}(\mathbf{z}) = \prod \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z_i^2\right) = \left(\frac{1}{2\pi}\right)^{n/2} \exp\left(-\frac{1}{2}\sum z_i^2\right)</math></p> <p>2)MGF: <math>M_{\mathbf{Z}}(\mathbf{t}) = \exp\left(\frac{1}{2}\mathbf{t}^T\mathbf{t}\right)</math> (<math>\mathbf{t} \in \mathbb{R}^p</math>) pf <math>M_{\mathbf{Z}}(\mathbf{t}) = E\{\exp(\mathbf{t}^T\mathbf{Z})\} = E\{\prod \exp(t_i Z_i)\} = \prod E\{\exp(t_i Z_i)\} = \exp\left(\frac{1}{2}\sum t_i^2\right)</math></p> <p>3) 기대값: <math>E[\mathbf{Z}] = \mathbf{0}</math>, <math>\text{Cov}[\mathbf{Z}] = \mathbf{I}_p</math></p>	
	<p>* <math>\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})</math> / <math>\text{Cov}[\mathbf{X}] = \boldsymbol{\Sigma}</math>가 psd (양반정치)</p> <p><math>\Leftrightarrow p</math>개의 <u>의존관계</u>인 정규분포 확률변수의 <u>결합 분포</u></p> <p>0) 변환: <math>\mathbf{X} = \boldsymbol{\Sigma}^{1/2} \mathbf{Z} + \boldsymbol{\mu}</math> &amp; <math>\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu})</math></p> <p>1) PDF: <math>f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2}  \boldsymbol{\Sigma} ^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T (\boldsymbol{\Sigma}^{-1})(\mathbf{x} - \boldsymbol{\mu})\right\}</math></p> <p>2) MGF: <math>M_{\mathbf{X}}(\mathbf{t}) = \exp\left\{\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T (\boldsymbol{\Sigma}) \mathbf{t}\right\}</math>, (<math>\mathbf{t} \in \mathbb{R}^p</math>)</p> <p>3) 기대값: <math>E[\mathbf{X}] = \boldsymbol{\mu}</math>, <math>\text{Cov}[\mathbf{X}] = \boldsymbol{\Sigma}</math></p>	<p>&lt;유도&gt; <math>\boldsymbol{\Sigma}</math>가 psd &amp; 대칭 <math>\rightarrow</math> EVD 가능</p> <p><math>\boldsymbol{\Sigma} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda} \boldsymbol{\Gamma}</math> (<math>\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)</math>; <math>\lambda_1 \geq \dots \geq \lambda_p</math>)</p> <p><math>\boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda}^{1/2} \boldsymbol{\Gamma}</math>, <math>\boldsymbol{\Sigma}^{-1/2} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda}^{-1/2} \boldsymbol{\Gamma}</math> (if <math>\boldsymbol{\Sigma}</math> is pd)</p> <p><math>E[\mathbf{X}] = E[\boldsymbol{\Sigma}^{1/2} \mathbf{Z}] + \boldsymbol{\mu} = \boldsymbol{\Sigma}^{1/2} E[\mathbf{Z}] + \boldsymbol{\mu} = \boldsymbol{\mu}</math></p> <p><math>\text{Cov}[\mathbf{X}] = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = E[(\boldsymbol{\Sigma}^{1/2} \mathbf{Z})(\boldsymbol{\Sigma}^{1/2} \mathbf{Z})^T]</math></p> <p><math>= \left(\boldsymbol{\Sigma}^{1/2}\right) E(\mathbf{Z}\mathbf{Z}^T) \left(\boldsymbol{\Sigma}^{1/2}\right)^T = \boldsymbol{\Sigma}</math> * <math>E[\mathbf{Z}\mathbf{Z}^T] = \text{Cov}(\mathbf{Z}) + \mathbf{0} = \mathbf{I}_p</math></p>
	<p><b>1-1. Theorem</b> * <math>\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})</math>; <math>\mathbf{A}: m \times p, \mathbf{b} \in \mathbb{R}^m</math></p> <p><math>\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \rightarrow \mathbf{Y} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)</math> (MGF로 증명)</p>	<p>&lt;MGF 유도&gt;</p> <p><math>M_{\mathbf{X}}(\mathbf{t}) = \exp(\mathbf{t}^T \boldsymbol{\mu}) M_{\mathbf{Z}}\left\{\left(\boldsymbol{\Sigma}^{1/2}\right)^T \mathbf{t}\right\}</math></p> <p><math>= \exp(\mathbf{t}^T \boldsymbol{\mu}) \exp\left\{(1/2)[(\boldsymbol{\Sigma}^{1/2})^T \mathbf{t}]^T [(\boldsymbol{\Sigma}^{1/2})^T \mathbf{t}]\right\}</math></p> <p><math>= \exp(\mathbf{t}^T \boldsymbol{\mu}) \exp\left\{(1/2)\mathbf{t}^T (\boldsymbol{\Sigma}^{1/2})^T (\boldsymbol{\Sigma}^{1/2}) \mathbf{t}\right\} = e^{\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T (\boldsymbol{\Sigma}) \mathbf{t}}</math></p>
	<p><b>1-2. Corollary</b> (<math>m</math>개 변수에 대한 <u>주변 분포</u>)</p> <p>* <math>\mathbf{X} \rightarrow \mathbf{X}_1 \in \mathbb{R}^m, \mathbf{X}_2 \in \mathbb{R}^q</math> (<math>p = m + q</math>) 분할</p> <p>- <math>\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} &amp; \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} &amp; \boldsymbol{\Sigma}_{22} \end{bmatrix}</math></p> <p>- <math>\mathbf{A} = [\mathbf{I}_m \quad \mathbf{0}_{mq}] \rightarrow \mathbf{X}_1 = \mathbf{A}\mathbf{X}</math></p> <p><math>\rightarrow \mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \rightarrow \mathbf{X}_1 \sim N_m(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})</math></p> <p>(<math>\because \mathbf{A}\boldsymbol{\mu} = \boldsymbol{\mu}_1, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = [\mathbf{I}_m \quad \mathbf{0}_{mq}] \begin{bmatrix} \boldsymbol{\Sigma}_{11} &amp; \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} &amp; \boldsymbol{\Sigma}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I}_m \\ \mathbf{0}_{mq} \end{bmatrix} = \boldsymbol{\Sigma}_{11}</math>)</p>	
	<p><b>2. 주변분포 독립성:</b> <math>\mathbf{X}_1, \mathbf{X}_2</math> 독립 <math>\Leftrightarrow \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21} = \mathbf{0}</math></p> <p>pf) <math>M_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{t}_1, \mathbf{t}_2) = \exp\left\{\mathbf{t}_1^T \boldsymbol{\mu}_1 + \mathbf{t}_2^T \boldsymbol{\mu}_2 + \frac{1}{2} \begin{bmatrix} \mathbf{t}_1^T &amp; \mathbf{t}_2^T \end{bmatrix} \begin{bmatrix} \boldsymbol{\Sigma}_{11} &amp; \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} &amp; \boldsymbol{\Sigma}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{t}_1 \\ \mathbf{t}_2 \end{bmatrix}\right\}</math></p> <p><math>M_{\mathbf{X}_1}(\mathbf{t}_1)M_{\mathbf{X}_2}(\mathbf{t}_2) = \exp\left\{\mathbf{t}_1^T \boldsymbol{\mu}_1 + \mathbf{t}_2^T \boldsymbol{\mu}_2 + \frac{1}{2}(\mathbf{t}_1^T \boldsymbol{\Sigma}_{11} \mathbf{t}_1 + \mathbf{t}_2^T \boldsymbol{\Sigma}_{22} \mathbf{t}_2)\right\} \therefore M_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{t}_1, \mathbf{t}_2) = M_{\mathbf{X}_1}(\mathbf{t}_1)M_{\mathbf{X}_2}(\mathbf{t}_2) \Leftrightarrow \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21} = \mathbf{0}</math></p>	
	<p><b>3. 조건부 분포:</b> <math>\mathbf{X}_1   \mathbf{X}_2 \sim N_m(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21})</math> (<math>\boldsymbol{\Sigma}</math>는 양정치)</p> <p>pf) <math>\mathbf{W} = \mathbf{X}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \mathbf{X}_2 \rightarrow \begin{bmatrix} \mathbf{W} \\ \mathbf{X}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{I}_m &amp; -\boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \\ \mathbf{0}_{qm} &amp; \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}</math> (<math>\mathbf{A} = \begin{bmatrix} \mathbf{I}_m &amp; -\boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \\ \mathbf{0}_{qm} &amp; \mathbf{I}_q \end{bmatrix}</math>)</p> <p><math>\begin{bmatrix} \mathbf{W} \\ \mathbf{X}_2 \end{bmatrix} \sim N_p(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T); \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = \begin{bmatrix} \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} &amp; \mathbf{0}_{mq} \\ \mathbf{0}_{qm} &amp; \boldsymbol{\Sigma}_{22} \end{bmatrix} \rightarrow \mathbf{W}, \mathbf{X}_2 \text{ 독립}</math></p> <p><math>\mathbf{W}   \mathbf{X}_2 = \mathbf{W} \sim N_m(\boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}) \rightarrow \therefore \mathbf{X}_1   \mathbf{X}_2 \sim N_m(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21})</math></p>	
	<p><b>4. 카이 제곱:</b> <math>W = (\mathbf{X} - \boldsymbol{\mu})^T (\boldsymbol{\Sigma}^{-1})(\mathbf{X} - \boldsymbol{\mu}) = \mathbf{Z}^T \mathbf{Z} \sim \chi^2(p)</math> (<math>\boldsymbol{\Sigma}</math>는 양정치)</p> <p>pf) <math>W = \mathbf{Z}^T \mathbf{Z} = \sum_{i=1}^p Z_i^2 \sim \chi^2(p)</math> * 가법성 of <math>\chi^2</math> using MGF; for iid <math>Z \sim N(0,1^2) \rightarrow \sum_{i=1}^p [(X_i - \mu_i)/\sigma_i]^2 \sim \chi^2(p)</math></p>	
PCA 기본	<p>* <b>Bivariate normal distribution (이변량 정규 분포)</b></p> <p>1) 기댓값: <math>\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 &amp; \sigma_{12} \\ \sigma_{12} &amp; \sigma_2^2 \end{bmatrix}, \sigma_{12} = \rho \sigma_1 \sigma_2</math></p> <p>2) PDF: <math>f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right)\right]\right\}</math></p> <p>3) 조건부 분포: <math>Y   X \sim N[\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)]</math></p>	
	<p><math>\mathbf{Y} = \boldsymbol{\Gamma}\mathbf{X} = (\mathbf{PC}_1, \mathbf{PC}_2, \dots, \mathbf{PC}_p)^T \rightarrow \mathbf{PC}_1 = \mathbf{v}_1^T \mathbf{X}</math> (<math>\mathbf{v}_1</math>: <math>\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}</math>의 <math>\lambda_1</math> 대응 고유벡터)</p> <p>pf) <math>\mathbf{Y} \sim N_p(\boldsymbol{\Gamma}\boldsymbol{\mu}, \boldsymbol{\Gamma}\boldsymbol{\Sigma}\boldsymbol{\Gamma}^T) = N_p(\boldsymbol{\Gamma}\boldsymbol{\mu}, \boldsymbol{\Lambda}) \rightarrow \text{TV}(\mathbf{X}) = \sum \sigma_i^2 = \text{tr}(\boldsymbol{\Sigma}) = \text{tr}(\boldsymbol{\Lambda}) = \sum \lambda_i = \text{TV}(\mathbf{Y})</math></p> <p>어떤 <math>\ \mathbf{a}\ ^2 = 1, \mathbf{a} = \sum_{j=1}^p a_j \mathbf{v}_j</math> <math>\Leftrightarrow \mathbf{a}^T \mathbf{v}_1 = a_1</math></p> <p><math>\rightarrow \text{Var}(\mathbf{a}^T \mathbf{X}) = \text{Cov}(\mathbf{a}^T \mathbf{X}) = \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a} = (\boldsymbol{\Gamma} \mathbf{a})^T \boldsymbol{\Lambda} (\boldsymbol{\Gamma} \mathbf{a}) = \sum_i \lambda_i (\mathbf{a}^T \mathbf{v}_i)^2 = \sum_i \lambda_i a_i^2 \leq \lambda_1 = \text{Var}(Y_1)</math>, 등호조건: <math>\mathbf{a} = \mathbf{v}_1</math></p> <p><math>\therefore Y_1 = \mathbf{v}_1^T \mathbf{X}</math> (고유벡터 <math>\mathbf{v}_1</math>으로 총 데이터 <math>\mathbf{X}</math> 사영): 총분산 <math>\sum \lambda_i</math> 중 최대 분산 <math>\lambda_1</math> 을 설명하는 <math>\mathbf{PC}_1</math></p> <p><math>\rightarrow \mathbf{X} = \boldsymbol{\Gamma}^T \mathbf{Y}</math> 에서 <math>X_k = (v_{1k})\mathbf{PC}_1 + (v_{2k})\mathbf{PC}_2 + \dots</math> (각 <math>v_{ik}</math>는 <math>X_k</math>의 <math>\mathbf{PC}_i</math>에 대한 PC score)</p>	

### 3-4. 주요 분포: t-분포, F-분포

t-분포	<p>Joint PDF: <math>h(w, v) = \left\{ \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}w^2\right) \right\} \left\{ \frac{1}{\Gamma\left(\frac{r}{2}\right) 2^{\frac{r}{2}}} v^{\frac{r}{2}-1} e^{-\frac{v}{2}} \right\} \quad w \in (-\infty, \infty), v \in (0, \infty); \text{서로 독립}</math></p> <p><math>T = \frac{W}{\sqrt{V/r}}</math> 일때 <math>t = \frac{w}{\sqrt{v/r}}, u = v</math>로 변환 시 <math> J  = \frac{\sqrt{u}}{\sqrt{r}} \rightarrow g(t, u)</math> 에서 <math>T</math>의 marginal PDF <math>g_1(w) = \int_0^\infty g(t, u) du</math></p> <p><math>T = \frac{W}{\sqrt{V/r}} \leftarrow W \sim N(0, 1^2), V \sim \chi^2(r); \text{서로 독립}</math></p> <p>1. PDF: <math>f(x) = \frac{\Gamma\left(\frac{r+1}{2}\right)}{\sqrt{r\pi} \Gamma\left(\frac{r}{2}\right)} \left(1 + \frac{x^2}{r}\right)^{-\frac{(r+1)}{2}}, \quad x \in \mathbb{R}</math></p> <p>2. 기대값: <math>E(T) = 0 \quad (r &gt; 1), \quad \text{Var}(T) = \frac{r}{r-2} \quad (r &gt; 2)</math></p> <p>* <math>E(T^k) = E\left[W^k \left(\frac{V}{r}\right)^{-k/2}\right] = E(W^k) E\left[\left(\frac{V}{r}\right)^{-k/2}\right] = \frac{1}{r^{k/2}} E(W^k) E(V^{-k/2})</math></p> <p><math>= E(W^k) \left(\frac{r}{2}\right)^{\frac{k}{2}} \frac{\Gamma\left(\frac{r-k}{2}\right)}{\Gamma\left(\frac{r}{2}\right)}, \quad r &gt; k</math></p> <p>(Cauchy 분포: <math>df = 1</math>인 t 분포, <math>f(x) = \frac{1}{\pi(1+x^2)}</math>)</p>	
	<p>3. Student's theorem *iid <math>X_i \sim N(\mu, \sigma^2) \quad n \uparrow</math> [직관: <math>\sigma^2</math>를 모르나, <math>X_i \sim N(\mu, \sigma^2) \rightarrow \bar{X}, S</math>로 <math>\mu</math> 정확 추정]</p> <p>1) <math>\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad 2) T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \leftarrow T = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right) / \sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}</math></p> <p>pf) <math>V = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^n \left(\frac{(X_i - \bar{X}) + (\bar{X} - \mu)}{\sigma}\right)^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2 = \frac{(n-1)S^2}{\sigma^2} + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2</math></p> <p><math>\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n), \quad \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2 \sim \chi^2(1) \rightarrow \bar{X}, S^2 \text{ 독립; 양변 mgf 취하면 } (1-2t)^{-\frac{n-1}{2}} = E\left(\exp\left\{\frac{(n-1)S^2}{\sigma^2}\right\} t\right)</math></p>	
	<p>* R codes 1) dt(x,r): <math>f(X=x)</math> 2) pt(x,r): <math>P(X \leq x)</math> (자유도 r) // 3) qt(0.975,r): 97.5%인 t값</p>	
F-분포	<p><math>F = \frac{U/r_1}{V/r_2} \leftarrow U \sim \chi^2(r_1), V \sim \chi^2(r_2); \text{서로 독립}</math></p> <p>1. PDF: <math>f(x) = \frac{1}{B\left(\frac{r_1}{2}, \frac{r_2}{2}\right)} \left(\frac{r_1}{r_2}\right)^{\frac{r_1}{2}} \left(1 + \frac{r_1}{r_2}x\right)^{-\frac{r_1+r_2}{2}} x^{\frac{r_1}{2}-1} \quad 0 &lt; x &lt; \infty</math></p> <p>2. 기대값: <math>E(F) = \frac{r_2}{r_2-2} \quad (r_2 &gt; 2)</math></p> <p>* <math>E(F^k) = E\left[\left(\frac{U/r_1}{V/r_2}\right)^k\right] = \left(\frac{r_2}{r_1}\right)^k E(U^k) E(V^{-k})</math></p> <p><math>= \left(\frac{r_2}{r_1}\right)^k \frac{\Gamma\left(\frac{r_1+k}{2}\right) \Gamma\left(\frac{r_2-k}{2}\right)}{\Gamma\left(\frac{r_1}{2}\right) \Gamma\left(\frac{r_2}{2}\right)} \quad (r_2 &gt; 2k)</math></p>	
	<p>* R codes 1) df(x,a,b): <math>f(X=x)</math> 2) pf(x,a,b): <math>P(X \leq x)</math> (자유도 a,b) // 3) qf(0.975,a,b): 97.5%인 F값</p>	

### 3-5. 혼합 분포

혼합 분포	<p>1. 혼합분포: <math>f(x) = \sum_{i=1}^k p_i f_i(x)</math> (각각 받침 <math>S_i</math>, 평균 <math>\mu_i</math>, 분산 <math>\sigma_i^2</math>, <math>\sum_{j=1}^k p_j = 1</math>)</p> <p>1) <math>E(X) = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} x f_i(x) dx = \sum_{i=1}^k p_i \mu_i = \bar{\mu}</math></p> <p>2) <math>\text{Var}(X) = \sum_{i=1}^k p_i \sigma_i^2 + \sum_{i=1}^k p_i (\mu_i - \bar{\mu})^2</math></p> <p>* <math>\text{Var}(X) = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} (x - \bar{\mu})^2 f_i(x) dx = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} (x - \mu_i)^2 f_i(x) dx + \sum_{i=1}^k p_i (\mu_i - \bar{\mu})^2 \int_{-\infty}^{\infty} f_i(x) dx</math></p>	
	<p>2. 응용: 유한 개로 제한할 필요 X</p> <p>1) 감마(<math>\theta, \alpha, \beta</math>)+푸아송(<math>x, \theta</math>) <math>\rightarrow</math> 음이항 분포</p> <p><math>p(x) = \int_0^\infty \left[ \frac{1}{\Gamma(\alpha)\beta^\alpha} \theta^{\alpha-1} e^{-\theta/\beta} \right] \left[ \frac{e^{-\theta} \theta^x}{x!} \right] d\theta = \frac{1}{\Gamma(\alpha)\beta^\alpha x!} \int_0^\infty \theta^{\alpha+x-1} e^{-\theta(a+\beta)/\beta} d\theta = \frac{\Gamma(\alpha+x)}{\Gamma(\alpha)x!} \frac{\beta^x}{(1+\beta)^{\alpha+x}}</math></p> <p><math>\rightarrow p(x) = \frac{(r+x-1)!}{(r-1)!} \frac{p^r (1-p)^x}{x!}, \quad \alpha = r \in \mathbb{Z}^+, \quad \beta = \frac{1-p}{p}</math></p> <p>2) 베이지안 추론: <math>h(x) = \int_{\theta} g(\theta) f(x \theta) d\theta</math>; <math>g(\theta)</math>: Conjugate prior, <math>h(x)</math>: 무조건부</p> <p>① <math>X \theta \sim N(0, 1/\theta), \theta \sim \Gamma(r/2, 2/r) \rightarrow X \sim t(r)</math> ② 이항분포 (p모름) <math>\rightarrow</math> 베타분포 <math>\beta(p)</math>로 추출 <math>\int_0^1 p(x p) g(p) dp</math></p>	



#### 4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

표본 / 통계량	* 표본 $\rightarrow$ 1) 분포 $f(x), p(x)$ 의 추론 // 2) $\theta$ 추론 $\leftarrow f(x), p(x)$ 는 알고 있음 ( $X_i$ : 확률변수, $x_i$ : 실현값)		
	1. 확률 표본 (Random sample): iid $[X_1, \dots, X_n]$		
	2. 통계량 (Statistic): $T = T(X_1, \dots, X_n)$ (표본에 대한 함수) $\rightarrow \theta \in \Omega$ 에 대한 추정량이면 $T$ : 점추정량 (point estimator), 실현값 $t$ : 점추정값 (point estimate)		
	3. 불편추정량 (Unbiased estimator): $E(T) = \theta$ [ $E(\bar{X}) = \mu, E(S^2) = \sigma^2$ ]		
	4. Maximum likelihood estimator (mle) 1) 가능도 함수: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ $\leftarrow$ MLE: $\hat{\theta} = \text{Argmax}[L(\theta)]$ 2) 로그우도 함수: $l(\theta) = \sum_{i=1}^n \ln f(x_i, \theta)$ $\leftarrow$ MLE: $\hat{\theta} = \text{Argmax}[l(\theta)] \leftarrow \partial l / \partial \theta = 0$		
	지수	$l(\beta) = \sum_{i=1}^n \ln \frac{1}{\beta} e^{-\frac{x_i}{\beta}} = -\frac{1}{\beta} \sum x_i - n \ln \beta = -n \left( \frac{1}{\beta} \bar{X} + \ln \beta \right) \rightarrow \frac{\partial l}{\partial \beta} = n \left( \frac{\bar{X}}{\beta^2} - \frac{1}{\beta} \right) \rightarrow \hat{\beta} = \bar{X}$ (also 불편)	
	이항	$l(p) = \sum_{i=1}^n \ln p^{x_i} (1-p)^{1-x_i} = n \bar{X} \ln p + (n - n \bar{X}) \ln(1-p) \rightarrow \frac{\partial l}{\partial p} = n \left( \frac{\bar{X}}{p} - \frac{1-\bar{X}}{1-p} \right) \rightarrow \hat{p} = \bar{X}$ (also 불편)	
	정규	$l(\mu, \sigma) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \nabla l(\mu, \sigma) = \left[ \frac{1}{\sigma} \sum (x_i - \mu), -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum (x_i - \mu)^2 \right]^T$ $\rightarrow \hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$	
CLT	1) Pivot 확률변수: (추정량-모수)/표준오차 2) 중심극한정리: $Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0,1) \leftrightarrow$ 근사적으로 $N(0,1)$ 에 수렴		
신뢰 구간	*신뢰구간: 모수 $\theta$ 가 추정량 $\hat{\theta}$ 에서 얼마나 벗어났는가? 1. 신뢰구간: $1 - \alpha = P_\theta[\theta \in (\hat{\theta}_L, \hat{\theta}_U)] \rightarrow 100(1-\alpha)\%$ 신뢰구간 (같은 신뢰계수 $\rightarrow$ 구간 길이 최소화) *해석: 모수 $\theta$ 가 추정량 $(\hat{\theta}_L, \hat{\theta}_U)$ 구간에 있는 사건 $\sim B(1, 1 - \alpha)$ (95% CI: $\theta$ 가 $(\hat{\theta}_L, \hat{\theta}_U)$ 에 평균 19회/20회)		
	2. 평균 신뢰 구간 ( $z_{\alpha/2}$ : 상위 $\alpha/2$ 에서 z값) $\Leftrightarrow (z_{\alpha/2} = \xi_{1-\alpha/2} \Leftrightarrow F(z_{\alpha/2}) = F(\xi_{1-\alpha/2}) = 1 - \alpha/2)$		
	상황	가정	Pivot statistic
	대표본 (근사;CLT)	평균 $\mu$ 분산 $\sigma^2$	$Z = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0,1)$
	t-구간 정규성 (정확)	$X_i \sim N(\mu, \sigma^2)$	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ (df = n - 1)
신뢰 구간	3. 평균 차이 $(\bar{X} - \bar{Y})$ 신뢰 구간 * $E(\bar{X} - \bar{Y}) = \mu_1 - \mu_2, \text{Var}(\bar{X} - \bar{Y}) = (\sigma_1^2/n_1) + (\sigma_2^2/n_2)$		
	상황	가정	Pivot statistic
	대표본 (근사;CLT)	평균 $\mu_1 - \mu_2$ 분산 $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$	$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{(S_1^2/n_1) + (S_2^2/n_2)}} \sim N(0,1)$
	t-통계량 정규성 (등분산)	$X_i \sim N(\mu_1, \sigma^2)$ $Y_i \sim N(\mu_2, \sigma^2)$	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{(1/n_1) + (1/n_2)}}$ (df = $n_1 + n_2 - 2$ ) $S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{(n_1 - 1) + (n_2 - 1)}$
	t-통계량 정규성 (이분산)	$X_i \sim N(\mu_1, \sigma_1^2)$ $Y_i \sim N(\mu_2, \sigma_2^2)$	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{(S_1^2/n_1) + (S_2^2/n_2)}}$ (Welch's, df<-round(df))
		1) $E(S_p^2) = \sigma^2$ 2) $(n_1 - 1)S_1^2/\sigma^2 \sim \chi^2(n_1 - 1)$ $\rightarrow (n_1 + n_2 - 2)S_p^2 \sim \chi^2(n_1 + n_2 - 2)$ 3) $S_p^2 \leftrightarrow (\bar{X} - \bar{Y})$ 독립 $df = \frac{(\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y})^2}{\frac{(\frac{s_x^2}{n_x})^2}{n_x - 1} + \frac{(\frac{s_y^2}{n_y})^2}{n_y - 1}}$	

#### 4. 통계적 추론 – MLE / 신뢰구간 / 가설검정

##### 4. 비율 차이 (극한 표준정규분포; CLT)

1) 가정:  $X \sim b(1, p_1), Y \sim b(1, p_2) \rightarrow \hat{p}_1 = \bar{X}, \hat{p}_2 = \bar{Y} \quad \therefore E(\hat{p}_1) = p_1, \text{Var}(\hat{p}_1) = p_1(1 - p_1)/n_1$

상황	가정	Pivot statistic
대표본 (근사; CLT)	평균 $p_1 - p_2$ 분산 $\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}$	$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \sim N(0,1)$

##### 5. 이산형 모수

1)  $F_T(T; \theta)$ : 통계량  $T$ 의 cdf;  $\theta$ 에 대해 단조 감소  $\rightarrow$  신뢰 구간:  $F_T(T_{n-1}; \underline{\theta}) = 1 - \alpha_2, F_T(T_n; \bar{\theta}) = \alpha_1$

2) **Bisection algorithm**: 순감소  $g(x) = d \in g([a, b]) \rightarrow$  1) if  $g\{(a+b)/2\} > d \rightarrow$  구간  $[(a+b)/2, b]$  재설정  
 $\rightarrow$  2) if  $g\{(a+b)/2\} < d \rightarrow$  구간  $[a, (a+b)/2]$  재설정

상황	조건	유도
<b>Binomial</b>	$X \sim b(1, p)$ $n = 30, \bar{x} = 0.60$ $T = n\bar{X} \sim b(30, p)$ ( $T_{n-1} = 17, T_n = 18$ )	① <b>하한</b> : $\text{pbinom}(17, 30, 0.4) = 0.9787, \text{pbinom}(17, 30, 0.45) = 0.9286$ $\rightarrow \text{pbinom}(17, 30, \mathbf{0.434}) \approx 0.95$ ② <b>상한</b> : $\text{pbinom}(18, 30, 0.7) = 0.1593, \text{pbinom}(18, 30, 0.8) = 0.0094$ $\rightarrow \text{pbinom}(18, 30, \mathbf{0.747}) \approx 0.05$ $\therefore p$ 의 90% CI: <b>[0.434, 0.747]</b>
<b>Poisson</b>	$X \sim \text{Poi}(\mu)$ $n = 25, \bar{x} = 5$ $T = n\bar{X} \sim \text{Poi}(25\mu)$ ( $T_{n-1} = 124, T_n = 125$ )	① <b>하한</b> : $\text{ppois}(124, 25 \times 4) = 0.9912, \text{ppois}(124, 25 \times 4.4) = 0.9145$ $\rightarrow \text{ppois}(124, 25 \times \mathbf{4.287}) \approx 0.95$ ② <b>상한</b> : $\text{ppois}(125, 25 \times 5.5) = 0.1330, \text{ppois}(125, 25 \times 6) = 0.0204$ $\rightarrow \text{ppois}(125, 25 \times \mathbf{5.8}) \approx 0.05$ $\therefore \mu$ 의 90% CI: <b>[4.287, 5.8]</b>

\*정의:  $(Y_1 < \dots < Y_n) \leftarrow [X_1, \dots, X_n]$  재배열      \*강점: 분포에 종속되지 않음.

1. **PDF**:  $g(y_1, \dots, y_n) = \frac{n!}{1!} f(y_1) \dots f(y_n) \quad (\text{on } a < y_1 < \dots < y_n < b) \quad \text{pf } g(y_1, \dots, y_n) = \sum_{i=1}^n |J_i| f(y_1) \dots f(y_n)$

2. **Marginal PDF** 1)  $g_k(y_k) = \frac{n!}{(k-1)!(n-k)!(1)!} [F(y_k)]^{k-1} [1 - F(y_k)]^{n-k} f(y_k)$

$$\text{pf } g_k(y_k) = \int_a^{y_k} \dots \int_a^{y_2} \int_{y_k}^b \dots \int_{y_{n-1}}^b n! f(y_1) \dots f(y_n) dy_n \dots dy_{k+1} dy_1 \dots dy_{k-1} \quad (y_n \rightarrow y_{k+1}; y_1 \rightarrow y_{k-1})$$

$$2) g_{ij}(y_i, y_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!(1)!(1)!} [F(y_i)]^{i-1} [F(y_j) - F(y_i)]^{j-i-1} [1 - F(y_j)]^{n-j} f(y_i) f(y_j)$$

3. **Quantile (분위수)**:  $\text{cdf } F(\xi_p) = p \leftrightarrow \xi_p = F^{-1}(p), \quad k = \text{floor}[p(n+1)]$

$$1) F(Y_k) \text{는 } \frac{k}{n+1} \text{의 불편추정량: } E(F(Y_k)) = \int_a^b F(y_k) g_k(y_k) dy_k = \int_0^1 \frac{n!}{(k-1)!(n-k)!} z^k (1-z)^{n-k} dz = \frac{k}{n+1}$$

2) **Quantile**: 1분위수 ( $Q_1 = Y_{[0.25(n+1)]}$ )  $\Leftrightarrow$  중위수 ( $Q_2 = Y_{[0.5(n+1)]}$ )  $\Leftrightarrow$  3분위수 ( $Q_3 = Y_{[0.75(n+1)]}$ )

\*중위수: 홀수  $\rightarrow$  중간값  $Y_{(n+1)/2}$  / 짝수  $\rightarrow (Y_{(n/2)} + Y_{(n/2)+1})/2$

$\rightarrow$  **Box plot**:  $h = 1.5(Q_3 - Q_1), LF = Q_1 - h, UF = Q_3 + h$  (LF, UF 바깥: 이상값; 정규분포상  $P \leq 0.007$ )

3) **Q-Q plot**: 표본의 순서통계량  $(Y_1, Y_2, \dots, Y_{50}) \Leftrightarrow$  이론적 분위수  $(Z_{0.02}, Z_{0.04}, \dots, Z_{1.00}) \leftarrow \text{any 분포}$

4) **신뢰구간**:  $1 - \alpha = P(Y_i < \xi_p < Y_j) = \sum_{w=i}^{j-1} \binom{n}{w} p^w (1-p)^{n-w} \leftarrow p = F(\xi_p) \quad (\text{중위수: } p = 1/2)$

#### 4. 통계적 추론 – MLE / 신뢰구간 / 가설검정

- 1) 가설 정의:  $H_0: \theta \in \omega_0$  (Null) vs.  $H_1: \theta \in \omega_1$  (alternative)  $\leftarrow X \sim f(x; \theta)$ 에 대해  $\theta \in \Omega = (\omega_0 \cup \omega_1)$ , 분할
- 2) 가설 검정: 표본  $(X_1, \dots, X_n) \in C \rightarrow H_1$  채택 (기각역  $C \subset D = \text{span}\{(X_1, \dots, X_n)\}$ )  
 표본  $(X_1, \dots, X_n) \notin C \rightarrow H_0$  유지
- 3) 유의 수준:  $\alpha = \max_{\theta \in \omega_0} P_{\theta}[(X_1, \dots, X_n) \in C]$  (복합귀무가설에 대해 모든 null 모수  $\rightarrow$  기각역에 속할 확률 최대)  
 \* 1종 오류:  $H_0$  참, but 기각  $\rightarrow H_1$  채택 (=FP)  $\therefore$  유의수준( $\alpha$ ): 1종 오류 범할 최대 확률
- 4) 검정력:  $\gamma(\theta) = P_{\theta}[(X_1, \dots, X_n) \in C], \theta \in \omega_1 \rightarrow$  유의 수준과 다르게 대립가설 모수에 따라 달라짐  
 ① 2종 오류:  $H_0$  거짓, but 유지  $\rightarrow H_0$  유지 (=FN)  $\therefore \beta$ : 2종 오류 범할 확률 (under given  $\theta \in \omega_1$ )  
 ② 검정력:  $H_0$  거짓  $\rightarrow$  알맞게  $H_1$  채택 (TP)
- 5) P-값: 1) **Upper tail**:  $P\text{-값} = P_{H_0}(X \geq x_{obs}) = 1 - F_{H_0}(x_{obs})$   
 2) **Lower tail**:  $P\text{-값} = P_{H_0}(X \leq x_{obs}) = F_{H_0}(x_{obs})$   
 3) **2-sided**:  $P\text{-값} = 2 \times P_{H_0}(X \geq |x_{obs}|) = 2[1 - F_{H_0}(|x_{obs}|)]$  ( $X=0$  좌우 대칭)  
 $\rightarrow X = F^{-1}(U)$  (단조 증가) 정리의 역에 의해  $P\text{-값} \sim \text{unif}(0,1)$  under 귀무가설  $H_0$

예시	분포	가설	유도
단일 이항 단측	$X_i \sim B(1, p)$	$H_0: p = p_0$ $H_1: p < p_0$	* 표본통계량: $S = \sum_{i=1}^n X_i \sim B(n, p)$ 1) 기각역 설정: 귀무가설 하에서 $S \sim B(n, p_0) \rightarrow \alpha = P_{p_0}[S \leq k]$ $\rightarrow 0.11 = P_{p_0}[S \leq 11] \quad (n = 20, p_0 = 0.7)$ 2) 검정력 함수: $\gamma(p) = P_p[S \leq 11]$ (단조 감소 of p) $\therefore H_0: p \geq p_0$ 로 확장 $\leftarrow \max_{p \geq p_0} P_p[S \leq k] = P_{p_0}[S \leq k]$ (단조성)
	대표본에서 $\frac{\hat{p} - p_0}{\sqrt{\hat{p}(1-\hat{p})/n}} \approx \frac{\hat{p} - p_0}{\sqrt{p(1-p)/n}} \xrightarrow{D} N(0, 1)$		
대표본			* 표본통계량: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \approx \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$
대표본 단측 (Upper)	$X_i \sim$ 미지 분포 1) 평균: $\mu$ 2) 분산: $\sigma^2$	$H_0: \mu = \mu_0$ $H_1: \mu > \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[ \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq z_{\alpha} \right] \approx 1 - \Phi(z_{\alpha})$ 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq z_{\alpha} \right] = P_{\mu} \left[ \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{\alpha} \right]$ $\approx 1 - \Phi \left( \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_{\alpha} \right) = \Phi \left( \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha} \right)$ (단조 증가 of $\mu$ ) * Power 증가: $n \uparrow$ , 효과크기 $(\mu - \mu_0) \uparrow$ , $\alpha \uparrow$ & $\sigma \downarrow$
대표본 단측 (Lower)		$H_0: \mu = \mu_0$ $H_1: \mu < \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[ \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \leq -z_{\alpha} \right] \approx \Phi(-z_{\alpha})$ 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \leq -z_{\alpha} \right] = P_{\mu} \left[ \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} - z_{\alpha} \right]$ $\approx \Phi \left( \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} - z_{\alpha} \right) = \Phi \left( -\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha} \right)$ (단조 감소 of $\mu$ ) * Power 증가: $n \uparrow$ , 효과크기 $(\mu - \mu_0) \uparrow$ , $\alpha \uparrow$ & $\sigma \downarrow$
대표본 양측		$H_0: \mu = \mu_0$ $H_1: \mu \neq \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[ \left  \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \right  \geq z_{\alpha/2} \right] \leftarrow$ (양측 동일 배분) 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[ \left  \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right  \geq z_{\alpha/2} \right]$ $\approx \Phi \left( \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha/2} \right) + \Phi \left( -\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha/2} \right)$ (U자 함수 of $\mu$ ) $\rightarrow (\mu_0)$ 에서 최소값
t-검정 정규성	$X_i \sim N(\mu, \sigma^2)$	$H_0: \mu = \mu_0$ $H_1: \mu \neq \mu_0$	* 표본통계량: $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ * t-분포는 $N(0,1)$ 보다 누워 있음 $\rightarrow$ "보수적" // 정규성 하 "정확"
2-표본 t-검정	$X_i \sim N(\mu_1, \sigma^2)$ $Y_i \sim N(\mu_2, \sigma^2)$ (정규, 등분산)	$H_0: \mu_1 = \mu_2$ $H_1: \mu_1 \neq \mu_2$	* 표본통계량: $T = \frac{(\bar{X} - \bar{Y}) - 0}{S_p \sqrt{(1/n_1) + (1/n_2)}} \sim t(n_1 + n_2 - 2)$ * $ T  \geq t_{0.025, n_1+n_2-2}$ 이면 $H_0$ 기각

가설  
검정

#### 4. 통계적 추론 – MLE / 신뢰구간 / 가설검정

자유도:  $n$ (확률표본)- $n$ (미지수 or 제약)

Pearson $\chi^2$ 검정	2 cells	1. 상황: $X_1 \sim b(n, p_1)$ , $X_2 = n - X_1$ , $p_2 = 1 - p_1 \Rightarrow Y = \frac{X_1 - np_1}{\sqrt{np_1(1-p_1)}} \xrightarrow{D} N(0,1)$ ; $Q_1 = Y^2 \xrightarrow{D} \chi^2(1)$ 2. 검정통계량: $Q_1 = \frac{(X_1 - np_1)^2}{np_1(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_1 - np_1)^2}{n(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} \xrightarrow{D} \chi^2(1)$
	k cells	1. 상황: $k$ 항; $n$ 회 다항분포 ( $p_k = 1 - \sum_{i=1}^{k-1} p_i$ & $x_k = n - \sum_{i=1}^{k-1} x_i$ ) 2. 검정통계량: $Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i} \xrightarrow{D} \chi^2(k-1) \quad \Leftarrow (k-1)\text{개 알면 나머지 1개 알}$
	적합도 검정	1) 귀무가설: $H_0: p_1 = p_{1,0}, p_2 = p_{2,0}, \dots, p_k = p_{k,0}$ 2) 검정통계량: $Q_{k-1} = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} = \sum_{i=1}^k \frac{(X_i - np_{i,0})^2}{np_{i,0}} \xrightarrow{D} \chi^2(k-1)$ (귀무가설 하)
	최소 $\chi^2$ 추정량	<예시> 정규분포 모수 추정 $N(\mu, \sigma^2)$ 1) 상황: 실수구간 $\rightarrow k$ 등분 ( $A_1, \dots, A_k$ ); $p_i = \int_{A_i} \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}(y-\mu)^2/\sigma^2\right] dy$ 2) 실제 $A_i$ 의 도수인 $X_i \rightarrow Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i} \xrightarrow{D} \chi^2(k-3)$ 최소화하는 $\hat{\mu}, \hat{\sigma}^2$
r x c cells	동질성 검정	1) 상황: 2개의 $k$ 항 다항분포 *각 모수: $(n_1, p_{11}, p_{21}, \dots, p_{k1}), (n_2, p_{12}, p_{22}, \dots, p_{k2})$ $\Rightarrow \sum_{j=1}^k \sum_{i=1}^2 \frac{(X_{ij} - n_j p_{ij})^2}{n_j p_{ij}} \xrightarrow{D} [\chi^2(k-1) + \chi^2(k-1)] = \chi^2(2k-2)$ 2) 귀무가설: $H_0: p_{11} = p_{12}, p_{21} = p_{22}, \dots, p_{k1} = p_{k2}$ (둘은 구간 별 비율이 동일) $\Rightarrow p_{m1} = p_{m2}$ 의 MLE: $\frac{X_{m1} + X_{m2}}{n_{m1} + n_{m2}}$ (총 $k-1$ 개 점추정값 필요) 3) 검정통계량: $\sum_{j=1}^k \sum_{i=1}^2 \frac{[X_{ij} - n_j \frac{(X_{i1} + X_{i2})}{n_{i1} + n_{i2}}]^2}{n_j \frac{(X_{i1} + X_{i2})}{n_{i1} + n_{i2}}} \xrightarrow{D} \chi^2(k-1)$ (귀무가설 하)
	독립성 검정	1) 상황: 확률실험 $n$ 회 결과 $\rightarrow$ 가로 (A) $a$ 항 / 세로 (B) $b$ 항 두 종류 범주로 구분 $\Rightarrow p_{ij} = P(A_i \cap B_j)$ , $X_{ij}$ 는 $A_i \cap B_j$ 도수 $\Rightarrow Q_{ab-1} = \sum_{j=1}^b \sum_{i=1}^a \frac{(X_{ij} - np_{ij})^2}{np_{ij}} \xrightarrow{D} \chi^2(ab-1)$ 2) 귀무가설: $H_0: P(A_i \cap B_j) = P(A_i)P(B_j)$ for all $(i, j)$ (속성 A, B는 독립) $\Rightarrow p_{i*} = P(A_i)$ 의 MLE: $\hat{p}_{i*} = \frac{X_{i*}}{n} = \frac{\sum_{j=1}^b X_{ij}}{n}$ [총 $(a-1) + (b-1)$ 개 점추정값 필요] 3) 검정통계량: $\sum_{j=1}^b \sum_{i=1}^a \frac{[X_{ij} - n \frac{(X_{i*})}{n} \frac{(X_{*j})}{n}]^2}{n \frac{(X_{i*})}{n} \frac{(X_{*j})}{n}} \xrightarrow{D} \chi^2[(a-1)(b-1)]$ (귀무가설 하)

\*비중심 카이제곱 분포:  $H_0$  외의 카이제곱 분포 (검정력 계산)

#### 4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

\* 몬테카를로 생성: 특정 "Known" 표본/분포 → 관측값 생성 (Resampling, Bayesian 등에서 중요)

1. 균등분포 (Uniform distribution):  $\text{unif}(a, b)$ ;  $\text{pdf} = 1/(b-a)$  ← R codes: `runif(횟수)`

unif(0,1)⇔CDF “관측치 생성”	$X = F^{-1}(U)$ 는 cdf $F(X)$ 따름 ⇔ 역: $Z = F(X) \sim \text{unif}(0,1)$	
	지수	$F(x) = 1 - e^{-x/\beta}, \quad (x > 0)$ $\therefore X = F^{-1}(U) = -\beta \ln(1 - U)$ 는 지수분포 생성
	푸아송	$m = \lambda w \rightarrow T_i \sim \exp(1/\lambda)$ 에 대해 $[X = k] \Leftrightarrow \sum_{i=1}^k T_i \leq w \ \& \ \sum_{i=1}^{k+1} T_i > w$ * 구간 $w$ 동안 난수로 $T_i$ 생성 $\rightarrow$ 횟수 카운트 (초기 $X = 0, T = 0$ ) 1) $\Delta T = -(1/\lambda) \ln(1 - U)$ 2) $T \leftarrow T + \Delta T$ 3) if $T \leq w$ : $X \leftarrow X + 1$ elif $T > w$ : return $X$
		정규 분포
채택-기각 (A-R) 알고리즘 (어려운 CDF)	$X = F^{-1}(U)$ 를 closed form 계산 불가. $\Leftarrow g(x)$ 이용: ① Easy ② $f(x)$ 유사 ③ $\frac{f(x)}{g(x)} \leq k$ (유계) ① $Y \sim g(y)$ & $U$ 생성 ② $U \leq \frac{f(Y)}{kg(Y)} \leq 1$ 이면 $X = Y$ , 아니면 ①로 돌아가 재 생성 $\Rightarrow$ 조금 더 넓은 $kg(x)$ 로 근사 ( $f(x) = cf_1(x)$ 와 $g(x) = dg_1(x)$ 적당히 상수배 하여 $k$ 무시 가능)	
	감마 CDF $\Gamma(\alpha, \beta)$	$Y_i \sim \Gamma(1,1) \rightarrow X = \sum_{i=1}^{\alpha} Y_i \sim \Gamma(\alpha, 1)$ ( $\alpha$ 정수: CDF 생성 쉬움) $X \sim \Gamma(\alpha, 1) \rightarrow \beta X \sim \Gamma(\alpha, \beta)$ ( $\alpha$ 실수 $\rightarrow$ 문제!) ① $X \sim \Gamma(\alpha, 1)$ & $Y \sim \Gamma([ \alpha ], 1/b)$ ② $\frac{f(x)}{g(x)} = b^{-[ \alpha ]} x^{\alpha - [ \alpha ]} e^{-(1-b)x} \leq b^{-[ \alpha ]} \left\{ \frac{\alpha - [ \alpha ]}{(1-b)e} \right\}^{\alpha - [ \alpha ]}$ (by $x$ 로 미분) ③ 위 식을 $b$ 로 미분 $\Rightarrow \frac{f(x)}{g(x)} \leq ([ \alpha ]/\alpha)^{-[ \alpha ]} \left\{ \frac{\alpha - [ \alpha ]}{(1 - [ \alpha ]/\alpha)e} \right\}^{\alpha - [ \alpha ]} = M$
		정규 CDF $N(0, 1)$
Monte Carlo t-검정 (오염된 정규)	$W \sim N(0,1^2)$ & $W \sim N(0, \sigma_c^2)$ ( $\epsilon: 0.25, \sigma_c = 25$ ) $\leftarrow W = Z \text{ or } \sigma_c Z; E(W) = 0$	
	* 가설: $H_0: \mu = 0, H_1: \mu > 0$ 1) $n = 20$ , 2) $t_{0.05, 19} = 1.729$	* 추정 알고리즘 ( $N$ : 시뮬레이션 수) 1) $n = 20$ 표본 생성 $\Leftarrow X$ (오염 정규; $\mu$ 모름) 분포 2) $T = (\bar{X} - \mu)/(S/\sqrt{n})$ 계산 $\rightarrow$ 1), 2) $N$ 번 반복 3) <b>유의수준 실험적 추정량: <math>\hat{\alpha} = I/N</math></b> ( $I: T > t_{0.05, 10}$ 도수) <b><math>SE = \sqrt{\hat{\alpha}(1 - \hat{\alpha})/N}</math></b> 예시) $\hat{\alpha} = 0.0412 \pm 0.0039$
Monte Carlo 적분	적분가능한 $g(x)$ 의 closed form 역도함수 ( $\approx$ 부정적분) 존재 $X \rightarrow$ 수치적 적분 $\int_a^b g(x) dx = (b-a) \int_a^b g(x) \left(\frac{1}{b-a}\right) dx = (b-a)E[g(X)] \Leftarrow X \sim \text{unif}(a, b)$ $\therefore \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n (b-a)g(X_i)$ 는 정적분의 unbiased estimator $\Leftarrow X_i \sim \text{unif}(a, b)$	

#### 4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

비교

- 1) 중심극한정리: 표본 통계량 ( $\hat{\theta}$ ) 의 pivotal statistic이 극한 정규분포따름  $\rightarrow$  모수  $\theta$  추정
- 2) 몬테카를로 기법:  $X$ 의 **known 분포 (CDF)**  $\rightarrow$  균등분포 난수추출기로 관측값  $X = F^{-1}(U)$  생성
- 3) 부트스트랩:  $X$ 의 **unknown 분포**  $\rightarrow$  표본 ( $X_1, \dots, X_n$ )의 EDF ( $\hat{F}_n$ )  $\rightarrow$  무작위 추출로  $X_i^*$  생성  
 $\hat{\theta}^*$ 의 분포  $\rightarrow \hat{\theta}$ 의 신뢰구간 추정  $\rightarrow \theta$ 의 근사적 신뢰구간

일반적인 통계적 추론에서는 estimator  $\rightarrow$  parameter를 추정함.

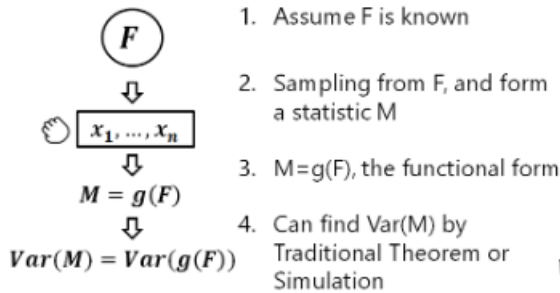
Standard error는 estimator의 자체적인 변동성 (표준편차) (e.g.  $SE(\bar{X}) = \sqrt{Var(\bar{X})} = \sigma/\sqrt{n}$ )

Estimated SE는 SE에 unknown parameter가 들어가 있을 때, 다른 estimator를 이용 ( $S/\sqrt{n}$ )

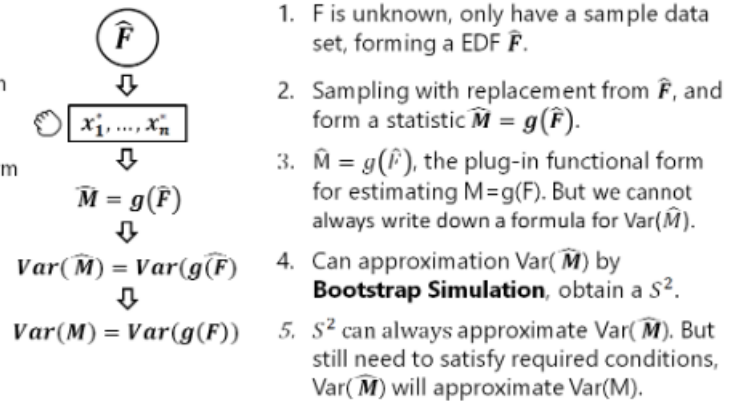
\*문제: ① 일반적인 확률변수 Y에 대해 분포 (PDF, CDF)를 알기 어렵고

② 통계량  $g(Y)$ 의 S.E.를  $\sigma/\sqrt{n}$ 처럼 정확한 수식으로 알아낼 수 있는 경우는 많지 않음.

##### In Real World



##### Bootstrap World



$$EDF \hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x) \Leftrightarrow (x \text{보다 작은 표본내 실현값 수}) / n \Leftrightarrow PMF \text{는 } \frac{1}{n} \text{ (for every } x_i)$$

원리

Statistical functional (통계적 범함수): 모수가 [분포함수]의 함수로 표현됨. (평균, 분산, 중위수, 백분위수, etc)

$$\text{e.g. } E(X) = \int x f dx = \int x dF, \quad Var(X) = \int x^2 dF - \left( \int x dF \right)^2$$

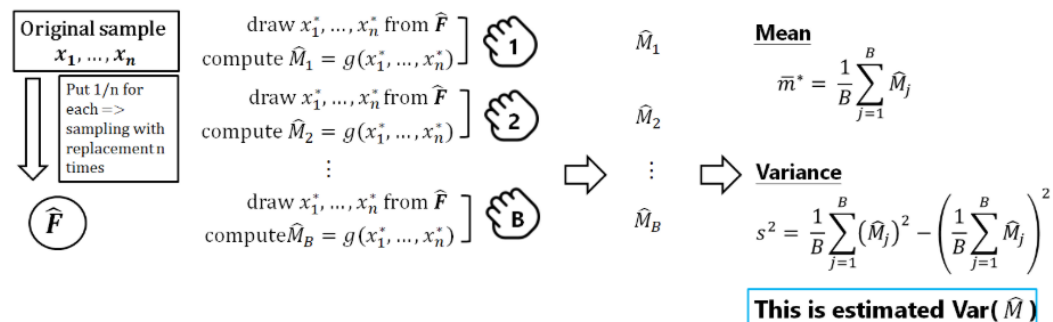
Plug-in principle:  $\hat{\theta} = g(\hat{F}) = \int r(x) d\hat{F} \Leftrightarrow \theta = g(F) = \int r(x) dF$  (전자는 후자의 plug-in estimate)

##### Form an EDF

##### Draw and calculate Statistic B times

##### Get B Statistic

##### Summarize



##### 2. Variance of $\hat{M}$ with $EDF \hat{F}$

$$s^2 = \frac{1}{B} \sum_{j=1}^B (\hat{M}_j)^2 - \left( \frac{1}{B} \sum_{j=1}^B \hat{M}_j \right)^2 \approx \text{Var}(\hat{M}; \hat{F}) \approx \text{Var}(M; F)$$

1. Bootstrap Variance Estimation

1. Simulation Error

3. Variance of M with true F

1번 simulation error는 결국 큰 수의 법칙에 의해 확률 수렴하므로  $B \uparrow$ 으로 최소화 가능

2번 approximation error는  $\hat{F}$ 이  $F$ 에 근사 ( $n \uparrow$ ) 하면 최소화 ( $n \uparrow$ 면 자연스럽게  $\hat{M} \xrightarrow{P} M$  성질도...)

Boot-  
strap  
기본

#### 4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

Boot-strap 응용	모평균 추정	$E(X_i^*) = \sum_{j=1}^n \frac{1}{n} X_j = \bar{X}, \quad \text{Var}(X_i^*) = \sum_{j=1}^n \frac{1}{n} (X_j - \bar{X})^2 = \frac{n}{n-1} S^2$ $E(\bar{X}_j^*) = \bar{X}, \quad \text{Var}(\bar{X}_j^*) = \frac{S^2}{n-1}$ <p>B회 시뮬레이션 평균 <math>\frac{1}{B} \sum_{i=1}^B \bar{X}_j^* \xrightarrow{P} E(\bar{X}_j^*) = \bar{X} \xrightarrow{P} \mu</math>, 분산 <math>\frac{1}{B} \sum_{i=1}^B (\bar{X}_j^*)^2 - \left( \frac{1}{B} \sum_{i=1}^B \bar{X}_j^* \right)^2 \xrightarrow{P} \text{Var}(\bar{X}_j^*) = \frac{S^2}{n-1} \xrightarrow{P} \frac{\sigma^2}{n}</math></p> <p>→ B 회 부트스트랩 <math>\bar{X}</math> 신뢰구간 (비모수적 counting) <math>\approx \left[ \bar{X} - z_{\alpha/2} \frac{S^2}{n}, \bar{X} + z_{\alpha/2} \frac{S^2}{n} \right] \approx [\mu \text{의 CLT 신뢰 구간}]</math></p> <p>- 위의 정규가정을 통한 <math>z_{\alpha/2}</math> 근사는 책 참고 4.9.1를 참조</p> <p>- 다른 모수 추정도 크게 다르지 않음. (<math>\bar{X}</math>처럼 precise한 분산식이 존재하지 않으면 시뮬레이션 효과 ↑)</p> <p>- 통계량의 분포가 다른 모수에 종속되지 않게 pivot화하면 부트스트랩 정확성 향상 가능</p>		
	Boot-strap 검정	<1표본 평균> $H_0: \mu = \mu_0$ $H_1: \mu > \mu_0$	1. 상황: 1) 검정통계량: $\bar{X}$ 2) $\hat{p} = P_{H_0}[\bar{X} \geq \bar{x}]$ 2. $H_0$ 가정 $\Rightarrow \mathbf{z}_i = \mathbf{x}_i - \bar{x} + \mu_0$ ( $E(z_i^*) = E(\bar{z}_j^*) = \mu_0$ ) $\Rightarrow$ 복원으로 n개 부트스트랩 3. <b>Empirical P-value 산출:</b> $\hat{p} = I/B$ ( $I: \{\bar{z}_j^* > \bar{x}\}$ )	
		<2표본 평균> $H_0: \mu_2 = \mu_1$ $H_1: \mu_2 > \mu_1$	1. 상황: 1) 검정통계량: $V = \bar{Y} - \bar{X}$ 2) $\hat{p} = P_{H_0}[V \geq \bar{y} - \bar{x}]$ 2. $H_0$ 가정 $\Rightarrow$ 표본 합침 ( $n = n_1 + n_2$ ) $\Rightarrow$ 복원으로 $(\mathbf{X}_i^*, n_1 \text{개}), (\mathbf{Y}_i^*, n_2 \text{개})$ 추출 3. <b>Empirical P-value 산출:</b> $\hat{p} = I/B$ ( $I: \{\bar{y}_i^* - \bar{x}_i^* > \bar{y} - \bar{x}\}$ ) * 부연: $H_0$ 가정 했기 때문에 생성값 $(\bar{y}_i^* - \bar{x}_i^*)$ 은 $H_0$ 하 통계량임.	
	Perm test	2표본 perm test: 통합 표본 ( $n=n_1+n_2$ )에서 비복원으로 추출된 x,y 모든 가능한 표본 → 검정		

## 5. 일치성 / 극한분포 ("통계학적 수렴")

중요한 부등식	1. <b>Markov:</b> $P[u(X) \geq c] \leq E[u(X)]/c$ (for $u(X) \geq 0, c > 0$ ; $E[u(X)]$ 존재 ) *증명: $E[u(x)] = \int_{-\infty}^{\infty} u(x)f(x)dx \geq \int_{u(x) \geq c} u(x)f(x)dx \geq c \int_{u(x) \geq c} f(x)dx = c P[u(x) \geq c]$ 2. <b>Chevyshev:</b> $P( X - \mu  \geq k\sigma) \leq 1/k^2$ (for $k > 0$ ; $X$ 가 $\mu, \sigma^2$ (유한) 가짐) *증명: Markov에서 $u(X) = (X - \mu)^2, c = k^2\sigma^2$													
확률 수렴	1. 정의: $X_n \xrightarrow{P} X \Leftrightarrow \forall \epsilon > 0, \lim_{n \rightarrow \infty} P[ X_n - X  \geq \epsilon] = 0$ ( $\Leftrightarrow \lim_{n \rightarrow \infty} P[ X_n - X  < \epsilon] = 1$ ) “함수열의 수렴” ( $X_n \xrightarrow{P} a$ , if $X$ 가 상수 $a \Rightarrow$ “퇴화확률변수, $p(a)=1$ , 나머지 0”)													
	2. 대수의 약법칙: iid $\{X_n\} \sim$ (평균: $\mu$ , 분산: $\sigma^2 < \infty$ ), $\bar{X}_n \xrightarrow{P} \mu$ *증명: By Chevyshev's ineq, $P[ \bar{X}_n - \mu  \geq \epsilon] \leq \sigma^2 / (n\epsilon^2) \rightarrow 0$ (when $n \rightarrow \infty$ )													
	3. 정리													
	<table><tr><td></td><td>정리</td><td>증명</td></tr><tr><td>선형</td><td>* <math>X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y</math> ① <math>(X_n + Y_n) \xrightarrow{P} (X + Y)</math> ② <math>aX_n \xrightarrow{P} aX</math></td><td>① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 <math>P[ (X_n + Y_n) - (X + Y)  \geq \epsilon] \leq P[ X_n - X  +  Y_n - Y  \geq \epsilon]</math> <math>\leq P[ X_n - X  \geq \epsilon/2] + P[ Y_n - Y  \geq \epsilon/2]</math></td></tr><tr><td>함수</td><td>* 받침 상 연속 <math>g(x)</math> ③ <math>X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)</math> ④ <math>X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)</math></td><td>① <math> g(x) - g(a)  \geq \epsilon \Rightarrow  x - a  \geq \delta</math> (<math>\epsilon &gt; 0, \delta &gt; 0</math>) <math>\therefore P[ g(X_n) - g(a)  \geq \epsilon] \leq P[ X_n - a  \geq \delta]</math></td></tr><tr><td>곱</td><td>* <math>X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y</math> ⑤ <math>X_n Y_n \xrightarrow{P} XY</math></td><td>* <math>X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY</math></td></tr></table>		정리	증명	선형	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ① $(X_n + Y_n) \xrightarrow{P} (X + Y)$ ② $aX_n \xrightarrow{P} aX$	① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 $P[ (X_n + Y_n) - (X + Y)  \geq \epsilon] \leq P[ X_n - X  +  Y_n - Y  \geq \epsilon]$ $\leq P[ X_n - X  \geq \epsilon/2] + P[ Y_n - Y  \geq \epsilon/2]$	함수	* 받침 상 연속 $g(x)$ ③ $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ ④ $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$	① $ g(x) - g(a)  \geq \epsilon \Rightarrow  x - a  \geq \delta$ ( $\epsilon > 0, \delta > 0$ ) $\therefore P[ g(X_n) - g(a)  \geq \epsilon] \leq P[ X_n - a  \geq \delta]$	곱	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ⑤ $X_n Y_n \xrightarrow{P} XY$	* $X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY$	
		정리	증명											
선형	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ① $(X_n + Y_n) \xrightarrow{P} (X + Y)$ ② $aX_n \xrightarrow{P} aX$	① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 $P[ (X_n + Y_n) - (X + Y)  \geq \epsilon] \leq P[ X_n - X  +  Y_n - Y  \geq \epsilon]$ $\leq P[ X_n - X  \geq \epsilon/2] + P[ Y_n - Y  \geq \epsilon/2]$												
함수	* 받침 상 연속 $g(x)$ ③ $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ ④ $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$	① $ g(x) - g(a)  \geq \epsilon \Rightarrow  x - a  \geq \delta$ ( $\epsilon > 0, \delta > 0$ ) $\therefore P[ g(X_n) - g(a)  \geq \epsilon] \leq P[ X_n - a  \geq \delta]$												
곱	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ⑤ $X_n Y_n \xrightarrow{P} XY$	* $X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY$												
4. 일치성: $T_n \xrightarrow{P} \theta$ 면 $\Leftrightarrow T_n$ 은 $\theta$ 의 일치 추정량 * $F(x; \theta)$ 에서 추출한 iid $\{X_1, \dots, X_n\}$ 의 통계량 $T_n$														
	<table><tr><td>분산 추정량</td><td>① <math>S_n^2 \xrightarrow{P} \sigma^2</math> (일치 &amp; 불편) ② <math>S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2</math> (일치 &amp; MLE)</td></tr><tr><td>균등분포 모수 추정량</td><td><math>X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}</math> <math>g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}</math> (<math>0 &lt; t \leq \theta</math>) <math>E(Y_n) = \int_0^\theta t \left( n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore</math> 최대값 <math>Y_n</math>은 <math>\theta</math>의 일치 추정량 <math>\bar{X}_n</math>은 <math>\theta/2</math>의 일치 추정량 <math>\Rightarrow 2\bar{X}_n</math>은 <math>\theta</math>의 일치 추정량</td></tr></table>	분산 추정량	① $S_n^2 \xrightarrow{P} \sigma^2$ (일치 & 불편) ② $S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2$ (일치 & MLE)	균등분포 모수 추정량	$X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}$ $g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}$ ( $0 < t \leq \theta$ ) $E(Y_n) = \int_0^\theta t \left( n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore$ 최대값 $Y_n$ 은 $\theta$ 의 일치 추정량 $\bar{X}_n$ 은 $\theta/2$ 의 일치 추정량 $\Rightarrow 2\bar{X}_n$ 은 $\theta$ 의 일치 추정량									
분산 추정량	① $S_n^2 \xrightarrow{P} \sigma^2$ (일치 & 불편) ② $S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2$ (일치 & MLE)													
균등분포 모수 추정량	$X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}$ $g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}$ ( $0 < t \leq \theta$ ) $E(Y_n) = \int_0^\theta t \left( n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore$ 최대값 $Y_n$ 은 $\theta$ 의 일치 추정량 $\bar{X}_n$ 은 $\theta/2$ 의 일치 추정량 $\Rightarrow 2\bar{X}_n$ 은 $\theta$ 의 일치 추정량													
분포 수렴	1. 정의: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F_X \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x)$ , ( $F: X$ 의 cdf, $F_n: X_n$ 의 cdf) “극한분포”													
	2. <b>t분포 <math>\Rightarrow</math> z분포</b> ( $n \rightarrow \infty$ ) ① $f_n(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{(n+1)}{2}}, \int_{-\infty}^t  f_n(y)  dy \leq \int_{-\infty}^t 10f_1(y) dy = \frac{10}{\pi} \tan^{-1} t < \infty$ (르벡 DCT) ② $\lim_{n \rightarrow \infty} F_n(t) = \lim_{n \rightarrow \infty} \int_{-\infty}^t f_n(x) dx = \int_{-\infty}^t \lim_{n \rightarrow \infty} f_n(x) dx = \int_{-\infty}^t \lim_{n \rightarrow \infty} \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{(n+1)}{2}} dx = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \Phi(t)$													
	3. 정리													
	<table><tr><td>① <math>X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X</math></td><td><a href="https://freshrimpsushi.tistory.com/175?category=696570">https://freshrimpsushi.tistory.com/175?category=696570</a></td></tr><tr><td>② <math>X_n \xrightarrow{P} b \Leftrightarrow X_n \xrightarrow{D} b</math></td><td>if 분포수렴 <math>\Rightarrow \lim_{n \rightarrow \infty} P[ X_n - b  \leq \epsilon] = \lim_{n \rightarrow \infty} F_{X_n}(b + \epsilon) - F_{X_n}(b - \epsilon) = 1 - 0 = 0</math></td></tr><tr><td>③ <math>X_n \xrightarrow{D} X \&amp; (A_n \xrightarrow{P} a, B_n \xrightarrow{P} b) \Rightarrow A_n + B_n X_n \xrightarrow{D} a + bX</math></td><td>&lt;Slutsky 정리&gt; e.g. <math>P_n - Q_n \xrightarrow{P} 0, Q_n \xrightarrow{D} X \Rightarrow P_n = (P_n - Q_n) + Q_n \xrightarrow{D} X</math></td></tr><tr><td>* 받침 상 연속 <math>g(x)</math> ④ <math>X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)</math></td><td><math>Z_n \xrightarrow{D} Z \Rightarrow Z_n^2 \xrightarrow{D} Z^2(1)</math></td></tr><tr><td>⑤ <math>X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)</math></td><td><math>Y_n \sim b(n, p) \Rightarrow \lim_{n \rightarrow \infty} M_n(t) = \lim_{n \rightarrow \infty} E(e^{tY_n}) = \lim_{n \rightarrow \infty} [(1-p) + (pe^t)]^n = e^{\mu(e^t-1)}</math> <math>\therefore</math> 이항분포 <math>b(n, p) \xrightarrow{D}</math> 푸아송분포 (<math>\mu = np</math>)</td></tr></table>	① $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$	<a href="https://freshrimpsushi.tistory.com/175?category=696570">https://freshrimpsushi.tistory.com/175?category=696570</a>	② $X_n \xrightarrow{P} b \Leftrightarrow X_n \xrightarrow{D} b$	if 분포수렴 $\Rightarrow \lim_{n \rightarrow \infty} P[ X_n - b  \leq \epsilon] = \lim_{n \rightarrow \infty} F_{X_n}(b + \epsilon) - F_{X_n}(b - \epsilon) = 1 - 0 = 0$	③ $X_n \xrightarrow{D} X \& (A_n \xrightarrow{P} a, B_n \xrightarrow{P} b) \Rightarrow A_n + B_n X_n \xrightarrow{D} a + bX$	<Slutsky 정리> e.g. $P_n - Q_n \xrightarrow{P} 0, Q_n \xrightarrow{D} X \Rightarrow P_n = (P_n - Q_n) + Q_n \xrightarrow{D} X$	* 받침 상 연속 $g(x)$ ④ $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$	$Z_n \xrightarrow{D} Z \Rightarrow Z_n^2 \xrightarrow{D} Z^2(1)$	⑤ $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$	$Y_n \sim b(n, p) \Rightarrow \lim_{n \rightarrow \infty} M_n(t) = \lim_{n \rightarrow \infty} E(e^{tY_n}) = \lim_{n \rightarrow \infty} [(1-p) + (pe^t)]^n = e^{\mu(e^t-1)}$ $\therefore$ 이항분포 $b(n, p) \xrightarrow{D}$ 푸아송분포 ( $\mu = np$ )			
① $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$	<a href="https://freshrimpsushi.tistory.com/175?category=696570">https://freshrimpsushi.tistory.com/175?category=696570</a>													
② $X_n \xrightarrow{P} b \Leftrightarrow X_n \xrightarrow{D} b$	if 분포수렴 $\Rightarrow \lim_{n \rightarrow \infty} P[ X_n - b  \leq \epsilon] = \lim_{n \rightarrow \infty} F_{X_n}(b + \epsilon) - F_{X_n}(b - \epsilon) = 1 - 0 = 0$													
③ $X_n \xrightarrow{D} X \& (A_n \xrightarrow{P} a, B_n \xrightarrow{P} b) \Rightarrow A_n + B_n X_n \xrightarrow{D} a + bX$	<Slutsky 정리> e.g. $P_n - Q_n \xrightarrow{P} 0, Q_n \xrightarrow{D} X \Rightarrow P_n = (P_n - Q_n) + Q_n \xrightarrow{D} X$													
* 받침 상 연속 $g(x)$ ④ $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$	$Z_n \xrightarrow{D} Z \Rightarrow Z_n^2 \xrightarrow{D} Z^2(1)$													
⑤ $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$	$Y_n \sim b(n, p) \Rightarrow \lim_{n \rightarrow \infty} M_n(t) = \lim_{n \rightarrow \infty} E(e^{tY_n}) = \lim_{n \rightarrow \infty} [(1-p) + (pe^t)]^n = e^{\mu(e^t-1)}$ $\therefore$ 이항분포 $b(n, p) \xrightarrow{D}$ 푸아송분포 ( $\mu = np$ )													



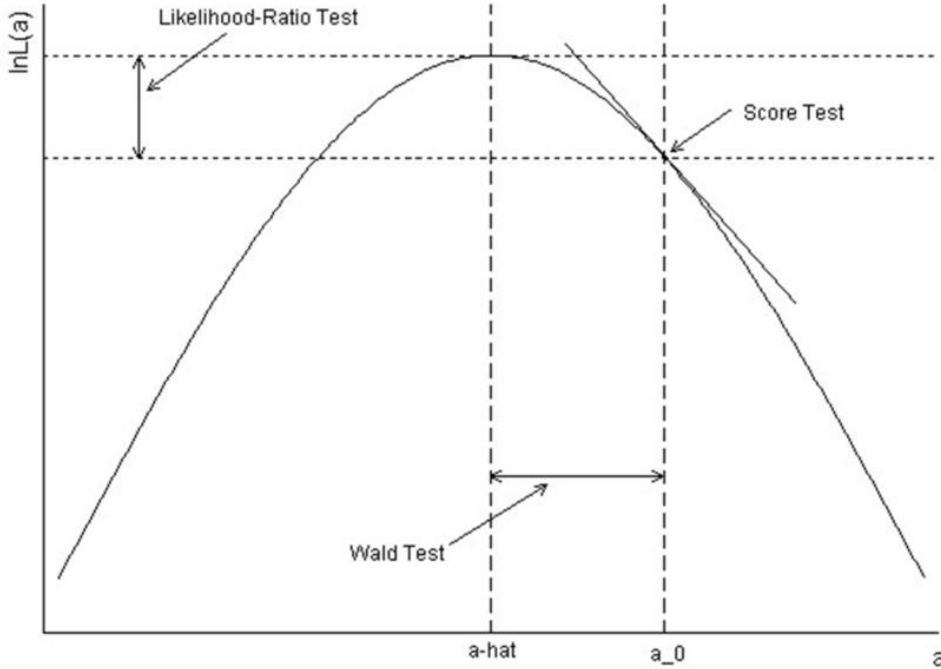
## 5. 일치성 / 극한분포 (“통계학적 수렴”)

<b>Δ-방법</b>	$\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$ 이고, $g(x)$ 가 $\theta$ 에서 미분 가능 & $g'(\theta) \neq 0$ 이면 $\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, g'(\theta)^2 \sigma^2)$ <b>[Δ-method를 잘 이용하면 모수에 종속되지 않는 통계량 분산 만들]</b> pf) 테일러 정리에 의해 $g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o( X_n - \theta )$ 이므로 $\sqrt{n}(g(X_n) - g(\theta)) = \sqrt{n}g'(\theta)(X_n - \theta) + o(\sqrt{n} X_n - \theta ) \xrightarrow{P} \sqrt{n}g'(\theta)(X_n - \theta) \xrightarrow{D} N(0, g'(\theta)^2 \sigma^2)$ (중간에 little-o를 0으로 확률수렴 시키는 전개는 확률 유계인 $Y_n$ 에 대해 $o(Y_n) \xrightarrow{P} 0$ 임을 이용)								
<b>중심 극한 정리 (CLT)</b>	1. 중심극한정리: $Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1) \leftarrow \text{iid } X_i \sim (\text{평균: } \mu, \text{분산: } \sigma^2)$ 2. 대표본 추론 통계량: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{D} N(0, 1) \quad \because S \xrightarrow{P} \sigma \Leftrightarrow \frac{S}{\sigma} \xrightarrow{P} 1, \text{CLT \& Slutsky에 의해 } \left(\frac{\sigma}{S}\right) \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$ 2. 증명: MGF 이용 (특성함수 $\varphi(t) = E(e^{itx})$ 이용해야 더 정확함) $m(t) := E[e^{t(X-\mu)}] = e^{-\mu t} M(t) \Rightarrow m(0) = 1, m'(0) = E(X - \mu) = 0, m''(0) = E[(X - \mu)^2] + m'(0)^2 = \sigma^2$ 테일러 정리에 의해 $m(t) = m(0) + m'(0)t + \frac{1}{2}m''(\xi)t^2 = 1 + \frac{1}{2}m''(\xi)t^2 = 1 + \frac{1}{2}\sigma^2 t^2 + \frac{1}{2}(m''(\xi) - \sigma^2)t^2, \xi \in [-t, t]$ $M(t; n) := E(e^{tZ_n}) = E\left(\exp\left(t \frac{(1/n)\sum X_i - \mu}{\sigma/\sqrt{n}}\right)\right) = E\left(\exp\left(t \frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}}\right)\right) = \prod_{i=1}^n E\left(\exp\left(t \frac{X_i - \mu}{\sigma\sqrt{n}}\right)\right)$ $= \left[E\left(\exp\left(\frac{t(X - \mu)}{\sigma\sqrt{n}}\right)\right)\right]^n = \left[m\left(\frac{t}{\sigma\sqrt{n}}\right)\right]^n, \quad -h < \frac{t}{\sigma\sqrt{n}} < h$ $M(t; n) = \left[m\left(\frac{t}{\sigma\sqrt{n}}\right)\right]^n = \left\{1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2}\right\}^n, \quad \xi \in \left[-\frac{t}{\sigma\sqrt{n}}, \frac{t}{\sigma\sqrt{n}}\right]$ $\therefore \lim_{n \rightarrow \infty} M(t; n) = \lim_{n \rightarrow \infty} \left\{1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2}\right\}^n = \lim_{n \rightarrow \infty} \left(1 + \frac{t^2}{2n}\right)^n = \exp\left(\frac{1}{2}t^2\right) \quad \because \lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0 \quad (\because \xi \rightarrow 0)$ $Z_n$ 의 mgf $M(t; n)$ 의 $n \rightarrow \infty$ 극한값은 $N(0, 1)$ 의 mgf $\exp\left(\frac{1}{2}t^2\right) \Rightarrow \therefore Z_n \xrightarrow{D} N(0, 1)$								
<b>다변량 분포 확장</b>	<table border="1"> <tr> <td data-bbox="165 1115 277 1373"> <b>수렴성 다변량 확장</b> </td><td data-bbox="277 1115 1560 1373">           1) 확률수렴: <math>\{X_n\} \in \mathbb{R}^p</math> 일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다.            즉, <math>X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j</math> (모든 <math>j = 1, \dots, p</math>에서 성립)            2) 분포수렴: <math>X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})</math>            ① <math>X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)</math> (corollary: <math>g(x) = x_j</math>로 두면 분포수렴이 주변 (marginal) 수렴 수반)            ② <math>X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)</math> </td></tr> <tr> <td data-bbox="165 1373 277 1653"> <b>다변량 표본</b> </td><td data-bbox="277 1373 1560 1653"> <math>\{X_n\} \in \mathbb{R}^p</math> 인 평균 <math>\mu</math>, 공분산행렬 <math>\Sigma</math> 인 iid 확률벡터열            ① 표본평균벡터: <math>\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T</math>            ② 표본공분산행렬: <math>S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); p \times p</math> 행렬  <math>\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma</math> (4차 적률 유한할 때 대수 약법칙)         </td></tr> <tr> <td data-bbox="165 1653 277 1709"> <b>CLT</b> </td><td data-bbox="277 1653 1560 1709"> <math>Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)</math> </td></tr> <tr> <td data-bbox="165 1709 277 1821"> <b>Δ방법</b> </td><td data-bbox="277 1709 1560 1821"> <math>\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})</math>  <math>\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)</math> </td></tr> </table>	<b>수렴성 다변량 확장</b>	1) 확률수렴: $\{X_n\} \in \mathbb{R}^p$ 일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다. 즉, $X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j$ (모든 $j = 1, \dots, p$ 에서 성립) 2) 분포수렴: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ ① $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$ (corollary: $g(x) = x_j$ 로 두면 분포수렴이 주변 (marginal) 수렴 수반) ② $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$	<b>다변량 표본</b>	$\{X_n\} \in \mathbb{R}^p$ 인 평균 $\mu$ , 공분산행렬 $\Sigma$ 인 iid 확률벡터열 ① 표본평균벡터: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T$ ② 표본공분산행렬: $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); p \times p$ 행렬 $\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma$ (4차 적률 유한할 때 대수 약법칙)	<b>CLT</b>	$Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$	<b>Δ방법</b>	$\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})$ $\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)$
<b>수렴성 다변량 확장</b>	1) 확률수렴: $\{X_n\} \in \mathbb{R}^p$ 일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다. 즉, $X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j$ (모든 $j = 1, \dots, p$ 에서 성립) 2) 분포수렴: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ ① $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$ (corollary: $g(x) = x_j$ 로 두면 분포수렴이 주변 (marginal) 수렴 수반) ② $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$								
<b>다변량 표본</b>	$\{X_n\} \in \mathbb{R}^p$ 인 평균 $\mu$ , 공분산행렬 $\Sigma$ 인 iid 확률벡터열 ① 표본평균벡터: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T$ ② 표본공분산행렬: $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); p \times p$ 행렬 $\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma$ (4차 적률 유한할 때 대수 약법칙)								
<b>CLT</b>	$Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$								
<b>Δ방법</b>	$\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})$ $\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)$								

## 6. 최대가능도방법 (Maximum Likelihood Methods)

MLE (R0)~(R2)	MLE 핵심	<p>(R0), (R1) 하에서 <math>\lim_{n \rightarrow \infty} P_{\theta_0} [L(\theta_0, \mathbf{X}) &gt; L(\theta, \mathbf{X})] = 1 \quad (\forall \theta \neq \theta_0)</math></p> <p><math>p f) \frac{1}{n} \sum_{i=1}^n \ln \left[ \frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] \xrightarrow{P} E_{\theta_0} \left( \ln \left[ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] \right) &lt; \ln E_{\theta_0} \left[ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right]</math> by 대수의 법칙, Jensen 부등식</p> <p><math>E_{\theta_0} \left[ \frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] = \int \frac{f(x; \theta)}{f(x; \theta_0)} f(x; \theta_0) dx = 1</math> (R1 공통 받침 하에서)</p> <p><math>\therefore \frac{1}{n} \sum_{i=1}^n \ln \left[ \frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] &lt; 0 \Leftrightarrow L(\theta_0, \mathbf{X}) &gt; L(\theta, \mathbf{X})</math></p> <p><math>\therefore</math> 근사적으로 <b>참값 <math>\theta_0</math>에서 우도함수 <math>L(\theta, \mathbf{X})</math>가 최대</b>가 된다. (<math>\hat{\theta} = \text{Argmax}[L(\theta)] \xrightarrow{P} \theta_0</math>)</p>	
	불변성	<p><math>\eta = g(\theta) \Leftrightarrow \hat{\eta} = g(\hat{\theta})</math></p> <p><math>p f) \textcircled{1} g \in 1\text{대}1 \text{ 함수: } \max L(\theta) = \max L(g^{-1}(\eta))</math> 이므로 <math>\hat{\theta} = g^{-1}(\hat{\eta})</math>에서 우도 최대화</p> <p><math>\textcircled{2} g \notin 1\text{대}1 \text{ 함수: } g^{-1}(\eta) := \{\theta: g(\theta) = \eta\}</math> 새로 정의 <math>\rightarrow \hat{\theta} \in g^{-1}(\hat{\eta})</math>에서 우도최대화</p>	
	추정 방정식	<p>*추정방정식 (estimating equation; EE): <math>\partial l(\theta) / \partial \theta = 0</math></p> <p>(R0)~(R2) 하에서 <math>\partial l(\theta) / \partial \theta = 0</math> 는 <math>\hat{\theta} \xrightarrow{P} \theta_0</math> 인 <math>\hat{\theta}</math>를 가짐</p> <p>(Corollary: EE가 유일해를 가지면 그 해는 <math>\hat{\theta} \xrightarrow{P} \theta_0</math>)</p>	
Cramér Rao Bound (R0)~(R4)	스코어 함수 & 피셔정보	<p><math>\textcircled{1}</math> Score 함수 <math>s(\theta) = \frac{\partial \ln f}{\partial \theta}</math></p> <p><math>\textcircled{2}</math> Fisher information <math>I(\theta) = \text{Var} \left( \frac{\partial \ln f}{\partial \theta} \right) = E \left[ \left( \frac{\partial \ln f}{\partial \theta} \right)^2 \right] = -E \left[ \frac{\partial^2 \ln f}{\partial \theta^2} \right]</math></p> <p><math>1 = \int_{-\infty}^{\infty} f dx \rightarrow</math> 양변 <math>\theta</math>로 i) 한번 미분 ii) 두번 미분 하면</p> <p>i) <math>0 = \int_{-\infty}^{\infty} (\partial f / \partial \theta) dx = \int_{-\infty}^{\infty} \frac{(\partial f / \partial \theta)}{f} f dx = \int_{-\infty}^{\infty} \left( \frac{\partial \ln f}{\partial \theta} \right) f dx \quad \therefore E \left( \frac{\partial \ln f}{\partial \theta} \right) = 0</math></p> <p>ii) <math>0 = \int_{-\infty}^{\infty} \frac{\partial^2 \ln f}{\partial \theta^2} f dx + \int_{-\infty}^{\infty} \left( \frac{\partial \ln f}{\partial \theta} \right) \left( \frac{\partial \ln f}{\partial \theta} \right) f dx \quad \therefore E \left[ \frac{\partial^2 \ln f}{\partial \theta^2} \right] + E \left[ \left( \frac{\partial \ln f}{\partial \theta} \right)^2 \right] = 0</math></p> <p>iid <math>[X_1, \dots, X_n]</math> 에 대해서</p> <p><math>\textcircled{1}</math> Score 함수 <math>s_n(\theta) = \frac{\partial l}{\partial \theta} = \frac{\partial \ln L}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta}</math></p> <p><math>\textcircled{2}</math> Fisher 정보 <math>I_n(\theta) = \text{Var} \left( \frac{\partial l}{\partial \theta} \right) = \text{Var} \left( \frac{\partial \ln L}{\partial \theta} \right) = n I(\theta)</math></p>	
	Cramér-Rao Bound (CRB)	<p><math>\textcircled{1} \text{Var}(T) \geq \frac{[\partial E(T) / \partial \theta]^2}{n I(\theta)}</math> for 임의의 통계량 <math>T = g(X_1, \dots, X_n)</math></p> <p><math>\textcircled{2} \text{Var}(T) \geq \frac{1}{n I(\theta)}</math> for 불편추정량 <math>T</math> (<math>\because E(T) = \theta</math>)</p> <p><math>p f) E(T) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} [T] f(x_1; \theta) \dots f(x_n; \theta) dx_1 \dots dx_n</math></p> <p><math>\Leftrightarrow \partial E(T) / \partial \theta = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} [T] \left[ \sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right] f(x_1; \theta) \dots f(x_n; \theta) dx_1 \dots dx_n, Z := \left[ \sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right]</math></p> <p><math>\Leftrightarrow \partial E(T) / \partial \theta = E(TZ) = E(T)E(Z) + \rho \sigma_T \sigma_Z = \rho \sqrt{\text{Var}(T)} \sqrt{n I(\theta)} \quad \therefore \rho^2 \leq 1 \Leftrightarrow \text{Var}(T) \geq \frac{[\partial E(T) / \partial \theta]^2}{n I(\theta)}</math></p>	
	효율성	<p>*효율성: 통계량 T의 효율성은 <math>\text{CRB}(T) / \text{Var}(T)</math></p> <p>* ARE (근사 상대효율성) <math>= e(T, W) = \frac{\text{Var}(W)}{\text{Var}(T)}</math> (if <math>T \xrightarrow{P} \theta_0, W \xrightarrow{P} \theta_0</math>이며 둘다 정규근사 될 때)</p>	
	MLE 정규근사 (R0)~(R5)	<p><math>\textcircled{1}</math> 정규 근사: <math>\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N \left( 0, \frac{1}{I(\theta_0)} \right)</math> for 유한 피셔정보 <math>I(\theta_0)</math> * <math>p f) l'(\hat{\theta})</math>를 <math>\theta_0</math> 테일러 전개 ...</p> <p><b><math>\Rightarrow</math> MLE의 근사 정규 신뢰 구간 구할 수 있음.</b></p> <p><math>\therefore \text{Var}(\hat{\theta}) \xrightarrow{P} \frac{1}{n I(\theta_0)}</math> (mle는 근사적으로 효율적 or mle의 분산은 CRB에 근사)</p> <p><math>\textcircled{2}</math> <math>\Delta</math>방법: <math>\sqrt{n}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{D} N \left( 0, \frac{g'(\theta_0)^2}{I(\theta_0)} \right)</math> (<math>g(x)</math>가 <math>\theta</math>에서 미분 가능 &amp; <math>g'(\theta) \neq 0</math> 이면)</p> <p><math>\textcircled{3}</math> 정규 근사: <math>\hat{\theta} - \theta_0 = \frac{1}{n I(\theta_0)} \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta_0)}{\partial \theta} + \frac{R_n}{\sqrt{n}} = -\frac{l'(\theta_0)}{l''(\theta_0)} + \frac{R_n}{\sqrt{n}} \quad (R_n \xrightarrow{P} 0)</math></p>	
	MLE Newton's	<p><math>\hat{\theta}_1 = \hat{\theta}_0 - \frac{l'(\hat{\theta}_0)}{l''(\hat{\theta}_0)}</math> 과정 반복 * <math>\hat{\theta}_0</math>이 일치 추정량이면 <math>\hat{\theta}_1</math>은 mle <math>\mathcal{L} \left( \xrightarrow{P} N \left( 0, \frac{1}{I(\theta_0)} \right) \right)</math></p>	

## 6. 최대가능도방법 (Maximum Likelihood Methods)

최대 가능도 검정 (ML tests)	전개	<p>우도비 (LR): <math>\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})}</math> (<math>\Lambda \leq c</math> 에서 기각)</p> <p><math>-\frac{1}{n}l''(\theta_0) \xrightarrow{P} I(\theta_0)</math>, <math>\frac{l'(\theta_0)}{\sqrt{n}} = \sqrt{n}(\hat{\theta} - \theta_0)I(\theta_0) + R_n</math> 이므로</p> <p><math>l(\hat{\theta}) = l(\theta_0) + (\hat{\theta} - \theta_0)l'(\theta_0) + \frac{1}{2}(\hat{\theta} - \theta_0)l''(\theta_n^*)</math> 의 미분계수 항들에 대입해주면</p> <p><math>-2 \ln \Lambda = 2[l(\hat{\theta}) - l(\theta_0)] = \left[ \sqrt{nI(\theta_0)}(\hat{\theta} - \theta_0) \right]^2 + R_n^*</math> (<math>R_n^* \xrightarrow{P} 0</math>)</p> <p><math>\therefore -2 \ln \Lambda \xrightarrow{D} \chi^2(1) \leftarrow \sqrt{nI(\theta_0)}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0,1)</math></p>	
	우도비 검정	$\chi_L^2 = -2 \ln \Lambda$	$\chi^2 \geq \chi_{\alpha}^2(1)$ 에서 단측 검정 기각역 ( $H_0: \theta = \theta_0, H_1: \theta \neq \theta_0$ )
	Wald 검정	$\chi_W^2 = \left[ \sqrt{nI(\hat{\theta})}(\hat{\theta} - \theta_0) \right]^2$	
	Score 검정	$\chi_R^2 = \left( \frac{l'(\theta_0)}{\sqrt{nI(\theta_0)}} \right)^2$	
	<div></div> <p>have the following relationship <math>Wald \geq LR \geq score</math> (Johnston and DiNardo 1997 p. 150). That is, the Wald test statistic will always be greater than the LR test statistic, which will, in turn, always be greater than the test statistic from the score test. When computing power was much more limited, and many models took a long time to run, being able to approximate the LR test using a single model was a fairly major advantage. Today, for most of the models researchers are likely to want to compare, computational time is not an issue, and we generally recommend running the likelihood ratio test in most situations. This is not to say that one should never use the Wald or score tests. For example, the Wald test is commonly used to perform multiple degree of freedom tests on sets of dummy variables used to model categorical predictor variables in regression (for more information see our webbooks on Regression with <a href="#">Stata</a>, <a href="#">SPSS</a>, and <a href="#">SAS</a>, specifically Chapter 3 – Regression with Categorical Predictors.) The advantage of the score test is that it can be used to search for omitted variables when the number of candidate variables is large.</p>		
정칙 조건	<p>(R0): pdf <math>f(x; \theta)</math>는 서로 distinct 하다. i.e. <math>\theta_1 \neq \theta_2 \Rightarrow f(x; \theta_1) \neq f(x; \theta_2)</math></p> <p>(R1): pdf <math>f(x; \theta)</math>는 모든 <math>\theta</math>에 대해 공통된 support를 갖는다. (<math>\theta</math>에 의존적이지 않다.)</p> <p>(R2): <math>\theta_0</math> (참값) <math>\in \Omega</math></p> <p>(R3): pdf <math>f(x; \theta)</math>는 <math>\theta</math>로 두 번 미분 가능</p> <p>(R4): <math>\int f(x; \theta)dx</math>는 <math>\theta</math>로 두 번 미분 가능</p> <p>(R5): pdf <math>f(x; \theta)</math>는 <math>\theta</math>로 세 번 미분 가능, 모든 <math>\theta</math>에 대해 <math> \partial^3 \ln f / \partial \theta^3  \leq M(x)</math> (<math>E_{\theta_0}[M(X)] &lt; \infty</math>) in <math>\theta_0</math> 근방 <math>\forall x</math></p>		
Regularity conditions			

## 6. 최대가능도방법 (Maximum Likelihood Methods)

\*정칙조건  $\sim(R9)$  까지 추가됨. (기존 정칙의 다변량 확장)

맨위 "MLE 핵심" 정리는 벡터  $\theta = [\theta_1, \dots, \theta_p]^T \in \mathbb{R}^p$ 에 대해서도 똑같이 성립함.  $\Leftrightarrow \nabla l(\theta) = \mathbf{0}$ 의 해 구하기

다중 모수 추정	피셔정보량	$\nabla \ln f(X; \theta) = \left( \frac{\partial \ln f(X; \theta)}{\partial \theta_1}, \dots, \frac{\partial \ln f(X; \theta)}{\partial \theta_p} \right)^T$ 피셔 정보량: $\mathbf{I}(\theta) = \text{Cov}(\nabla \ln f(X; \theta)) = -E \left[ \frac{\partial^2}{\partial \theta_j \partial \theta_k} \ln f \right]_{jk} = E \left[ \left( \frac{\partial \ln f}{\partial \theta_j} \right) \left( \frac{\partial \ln f}{\partial \theta_k} \right) \right]_{jk}$
	피셔정보량 (표본 n 확장)	$\nabla l = \nabla \ln L = \sum_{i=1}^n \nabla \ln f$ 피셔 정보량: $\mathbf{I}_n(\theta) = \text{Cov}(\nabla l) = \text{Cov}(\nabla \ln L) = n\mathbf{I}(\theta)$
	CRB	$\text{Var}(T_j) \geq \frac{1}{n} [\mathbf{I}^{-1}(\theta)]_{jj}$ ( $T_j$ 가 $\theta_j$ 의 불편 추정량)
	정규근사	$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1}(\theta_0)) \Rightarrow \sqrt{n}(\hat{\theta}_j - \theta_j) \xrightarrow{D} N(0, [\mathbf{I}^{-1}(\theta_0)]_{jj})$
	$\Delta$ 방법	$\sqrt{n}(\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta_0)) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{B}[\mathbf{I}^{-1}(\theta_0)]\mathbf{B}^T)$ ( $\mathbf{g}$ 는 $\mathbb{R}^p \rightarrow \mathbb{R}^k$ 로의 변환 ( $k \leq p$ ); 미분행렬 $\mathbf{B} = \left[ \frac{\partial g_i}{\partial \theta_j} \right]$ 이 연속, $\mathbf{B} \neq \mathbf{0}$ in $\theta_0$ 근방)

다중모수	다중 모수 검정	예 시	기 본	$H_0: \theta \in \omega, H_1: \theta \in (\omega^c \cap \Omega)$ ( $\Omega$ : p차원 전체 모수 공간; $\omega$ : p-q차원 귀무가설 모수공간 ( $q$ : 제약된 모수 개수)) 우도비 (LR): $\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \frac{\max_{\theta \in \omega} L(\theta)}{\max_{\theta \in \Omega} L(\theta)}$ $\chi_L^2 = -2 \ln \Lambda \xrightarrow{D} \chi^2(q)$ (Wald, Score 검정통계량도 가능)
			정규 $\mu$	$H_0: \mu = \mu_0, H_1: \mu \neq \mu_0 \quad \{X_n\} \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ $L(\hat{\Omega}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\hat{\sigma}^2} \right\} = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left( -\frac{n}{2} \right)$ $L(\hat{\omega}) = \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} \exp \left( -\frac{n}{2} \right) \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$ $\left( \frac{1}{\Lambda} \right)^{\frac{2}{n}} = \left( \frac{L(\hat{\Omega})}{L(\hat{\omega})} \right)^{\frac{2}{n}} = \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = 1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = 1 + \frac{1}{n-1} \left\{ \frac{(\bar{X} - \mu_0)^2}{S/\sqrt{n}} \right\}$ $\left( \frac{1}{\Lambda} \right)^{\frac{2}{n}} \geq c' \Leftrightarrow  T  \geq c^* = \sqrt{(c' - 1)(n-1)} \quad \therefore \text{양측 t검정과 동치}$
			다항 p	$H_0: p_1 = p_2, H_1: p_1 \neq p_2$ (유력후보1 vs 유력후보2 vs 나머지 군소후보) 3항 베르누이 $(X_{i1}, X_{i2}) \sim p_1^{x_1} p_2^{x_2} (1 - p_1 - p_2)^{1-x_1-x_2} \quad (X_{i1}, X_{i2}) \in \{(0,0), (0,1), (1,0)\}$ $\hat{p}_j = \frac{\sum_{i=1}^n X_{ij}}{n} \quad \text{for } j = 1, 2 \quad (\text{표본: } \{(X_{n1}, X_{n2})\})$ LR $\frac{1}{\Lambda} = \left( \frac{2\hat{p}_1}{\hat{p}_1 + \hat{p}_2} \right)^{n\hat{p}_1} \left( \frac{2\hat{p}_2}{\hat{p}_1 + \hat{p}_2} \right)^{n\hat{p}_2}, \quad -2 \ln \Lambda > \chi_{\alpha}^2(1) \text{에서 기각}$ Wald $\begin{bmatrix} \hat{p}_1 \\ \hat{p}_2 \end{bmatrix} \stackrel{a}{\sim} N_2 \left( \begin{bmatrix} p_1 \\ p_2 \end{bmatrix}, \frac{1}{n} \begin{bmatrix} p_1(1-p_1) & -p_1p_2 \\ -p_1p_2 & p_2(1-p_2) \end{bmatrix} \right)$ $W = \hat{p}_1 - \hat{p}_2 = g \left( \begin{bmatrix} \hat{p}_1 \\ \hat{p}_2 \end{bmatrix} \right), \quad \Delta \text{방법에서 } \mathbf{B} = \left[ \frac{\partial g_i}{\partial p_j} \right] = [1, -1]$ $\text{Var}(W) = \frac{1}{n} \mathbf{B} \mathbf{I}^{-1} \mathbf{B}^T = \frac{p_1 + p_2 - (p_1 - p_2)^2}{n}$ $\therefore W \stackrel{a}{\sim} N \left( p_1 - p_2, \frac{p_1 + p_2 - (p_1 - p_2)^2}{n} \right) \Rightarrow \text{근사 Z 검정 or 카이제곱}$
			2표본 이항 p	$H_0: p_1 = p_2, H_1: p_1 \neq p_2, \quad \{X_{n1}\} \stackrel{\text{iid}}{\sim} B(1, p_1), \quad \{Y_{n2}\} \stackrel{\text{iid}}{\sim} B(1, p_2)$ Wald $\hat{p}_1 \stackrel{a}{\sim} N \left( p_1, \frac{p_1(1-p_1)}{n_1} \right), \quad \hat{p}_2 \stackrel{a}{\sim} N \left( p_2, \frac{p_2(1-p_2)}{n_2} \right), \quad \text{Cov}(\hat{p}_1, \hat{p}_2) = 0$ $\hat{p}_1 - \hat{p}_2 \stackrel{a}{\sim} N \left( p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} \right) \& \text{Slutsky } (\hat{p}_1 \xrightarrow{P} p_1, \hat{p}_2 \xrightarrow{P} p_2)$ $\Rightarrow \text{근사 Z 검정 or 카이제곱}$

## 7. 충분성 (Sufficiency) – 통계량의 성질

통계량 Review	통계량	① 점추정: $\theta \in \Omega$ 에 대한 추정량 $\hat{\theta}$ *통계량 (Statistic): $T = T(X_1, \dots, X_n)$ (표본에 대한 함수) ② 95% CI: $0.95 = P_{\theta}[\theta \in (\hat{\theta}_L, \hat{\theta}_U)]$ * $\theta \in (\hat{\theta}_L, \hat{\theta}_U)$ 인 베르누이 사건 $\sim B(1, 0.95)$
	성질	1) 일치추정량: $T_n \xrightarrow{P} \theta$ 면 $\Leftrightarrow T_n$ 은 $\theta$ 의 일치 추정량 2) 불편추정량: $E(T) = \theta \Leftrightarrow T$ 는 $\theta$ 의 불편 추정량 (bias = 0) ① <b>MVUE</b> : 분산 최소인 불편추정량 (UE) $\rightarrow$ 유일 ② <b>CRB</b> : $\text{Var}(T) \geq 1/\{nI(\theta)\}$ 3) MLE: $\hat{\theta} = \text{Argmax}[L(\theta)] = \text{Argmax}[\prod_{i=1}^n f(x_i, \theta)]$ ① MLE는 근사적으로 효율적 ② $\hat{\theta} \stackrel{a}{\sim} N\left(\theta_0, \frac{1}{nI(\theta_0)}\right) \Rightarrow Z$ or $\chi^2$ 화 하면 Wald statistic 4) $ARE(T_1, T_2) = \frac{\text{Var}(T_2)}{\text{Var}(T_1)}$
	Bias MSE	1) $\text{bias}(\hat{\theta}) = E(\hat{\theta} - \theta) = E(\hat{\theta}) - \theta$ * $\text{bias}(g(\hat{\theta})) = E(g(\hat{\theta}) - g(\theta))$ 2) Mean square error (MSE): $\text{mse}(\hat{\theta}) = E\{(\hat{\theta} - \theta)^2\} = \text{Var}(\hat{\theta}) + \{\text{bias}(\hat{\theta})\}^2$ 3) Mean absolute error (MAE): $\text{mse}(\hat{\theta}) = E\{ \hat{\theta} - \theta \}$
	적률 추정법 (MoM)	r차 표본적률 $\xrightarrow{P}$ r차 모적률 ( $\Rightarrow$ 연립하여 모수 추정량 구함; 일반적으로 비선형) ex) $\{X_i\} \stackrel{iid}{\sim} \text{Gamma}(k, \theta)$ $m_1 = \frac{\sum_{i=1}^n X_i}{n} = \hat{k}\hat{\theta}$ , $m_2 = \frac{\sum_{i=1}^n X_i^2}{n} = \hat{k}(\hat{\theta})^2 + (\hat{k}\hat{\theta})^2$ $\hat{\theta} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n\bar{X}} = \left(\frac{n-1}{n}\right) \frac{S^2}{\bar{X}} = \frac{S_{mle}^2}{\bar{X}}$ , $\hat{k} = \frac{n(\bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \left(\frac{n}{n-1}\right) \frac{\bar{X}}{S^2} = \frac{\bar{X}^2}{S_{mle}^2}$
충분성	정의	$Y = u(X_1, \dots, X_n)$ 에 대해 $X Y$ 가 $\theta$ 와 무관함 $\Leftrightarrow Y$ 가 $\theta$ 에 대한 모든 정보 다 포함 (e.g. $Y = \sum_{i=1}^n X_i$ ) $\frac{\prod_{i=1}^n f(x_i, \theta)}{f_Y(y; \theta)} = H(x_1, \dots, x_n)$ ( $f_Y$ : Y의 pdf)
	Neyman-Fisher	$[Y \text{가 } \theta \text{의 SS}] \Leftrightarrow \prod_{i=1}^n f(x_i, \theta) = f_Y(y; \theta) H(x_1, \dots, x_n) = g(y; \theta) h(x_1, \dots, x_n)$ (임의의 $g, h$ 로 인수분해)
	Rao-Blackwell	$\theta$ 의 충분통계량 $Y_1$ , 불편추정량 $Y_2$ 에 대해, 새로운 불편추정량 $\varphi(Y_1) = E(Y_2 Y_1)$ $E(\varphi(Y_1)) = E[E(Y_2 Y_1)] = E(Y_2) = \theta$ 2) $\text{Var}(\varphi(Y_1)) = \text{Var}(E(Y_2 Y_1)) \leq \text{Var}(Y_2)$ $\therefore$ New UE $\varphi(Y_1) = E(Y_2 Y_1)$ 는 Old UE $Y_2$ 보다 분산이 작다. *실전: $E(\varphi(Y_1)) = \theta$ 인 $\varphi(Y_1)$ 찾기
	Lehmann-Scheffe	① 통계량 $Y$ 는 <b>complete (완비)</b> if 모든 $\theta$ 에서 $E(h(Y)) = 0 \Rightarrow h(t) = 0$ 만 가능함 ② 레만-셰페: CSS인 $Y_1$ 으로 Rao-Blackwellization $\rightarrow \varphi(Y_1) = E(Y_2 Y_1)$ 는 유일한 <b>MVUE</b> of $\theta$ pdf CSS인 $Y_1$ 에 대해 불편추정량 $\varphi(Y_1), \psi(Y_1)$ 존재 $\Rightarrow E(\varphi(Y_1) - \psi(Y_1)) = \theta - \theta = 0$ 완비족 $\{f_{Y_1}(y; \theta); \theta \in \Omega\}$ 에 대해 위 등식은 $\varphi(Y_1) = \psi(Y_1)$ 에서만 성립 (더 이상 분산 못 줄임)
	지수족 Exponential Family	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta(\theta))]$ ( $x \in S$ ) ( $\eta = \eta(\theta)$ 는 자연 모수) *정칙: 1) $S$ 가 $\theta$ 에 종속 X, 2) $\eta(\theta)$ 연속, 3) (연속이면) $H(x)$ 연속 in $\{K'(x) \neq 0\}$ ① 지수족: 이산 (포아송, 이항, 기하, 음이항, 다항 등) / 연속 (감마, 베타, 정규 등) ② $Y = \sum_{i=1}^n T(x)$ 는 $\theta$ 의 CSS ③ $E(T(X)) = A'(\eta)$ , $\text{Var}(T(X)) = A''(\eta)$
	결합 충분통계량 (다중모수)	$\mathbf{Y} = (Y_1, \dots, Y_m)^T \in \mathbb{R}^m$ & $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \mathbb{R}^p$ 에 대해 (일반적으로 $m = p$ ) $\prod_{i=1}^n f(x_i, \boldsymbol{\theta}) = f_Y(\mathbf{y}; \boldsymbol{\theta}) H(x_1, \dots, x_n) = g(\mathbf{y}; \boldsymbol{\theta}) h(x_1, \dots, x_n)$ *순서통계량 $\mathbf{Y} = (Y_1, \dots, Y_n)^T$ ; $Y_1 < \dots < Y_n \rightarrow$ 모든 연속분포의 결합충분통계량
	보조통계량 (Ancillary)	$A = a(X_1, \dots, X_n)$ 가 $\theta$ 와 무관 ex) 정규분포 iid의 $S^2$ : $\mu$ 에 대해 ancillary 1) Basu 정리: $\{Y \text{가 } \theta \text{의 CSS}\} \& \{Z \text{가 } \theta \text{의 ancillary}\} \Leftrightarrow \{Y \text{와 } Z \text{는 독립}\}$ ex) $\bar{X} \perp S^2, \{X_i\} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ 2) ① 위치불변: $Z = u(W_1 + \theta, \dots, W_n + \theta) = u(W_1, \dots, W_n)$ ex) $S^2, \max\{X_i\} - \min\{X_i\}, \frac{1}{n} \sum_{i=1}^n  X_i - Q_2 $ ② 척도불변: $Z = u(\theta W_1, \dots, \theta W_n) = u(W_1, \dots, W_n)$ ex) $X_1/(X_1 + X_2), X_1^2 / \sum_{i=1}^n X_i^2, \min\{X_i\} / \max\{X_i\}$ ③ 위치척도불변: $Z = u(\theta_1 W_1 + \theta_2, \dots, \theta_1 W_n + \theta_2) = u(W_1, \dots, W_n)$ ex) $(X_i - \bar{X})/S^2$
	MLE	$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i, \theta) = f_Y(y; \theta) H(x_1, \dots, x_n) \rightarrow L$ 과 $f_Y$ 동시에 극대화 by $\theta$ ① MLE $\hat{\theta}$ 이 유일 $\Leftrightarrow \hat{\theta}$ 는 충분통계량 $Y$ 의 함수 $\therefore \hat{\theta} = \text{argmax}(L(\theta, \mathbf{x})) = \text{argmax}(f_Y(y; \theta))$ ② MLE $\hat{\theta}$ 가 충분통계량 $\Leftrightarrow \hat{\theta}$ 는 최소 충분통계량 (MSS) *최소충분: reduced from 다른 충분통계량

## 7. 충분성 (Sufficiency) – 통계량의 성질

지수족 확장	지수족	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta(\theta))] \quad (x \in S) \quad (\eta = \eta(\theta) \text{는 자연 모수})$ *정칙: 1) $S$ 가 $\theta$ 에 종속 $\mathbf{X}$ , 2) $\eta(\theta)$ 연속, 3) (연속이면) $H(\mathbf{x})$ 연속 in $\{K'(x) \neq 0\}$ ① 지수족: 이산 (포아송, 이항, 기하, 음이항, 다항 등) / 연속 (감마, 베타, 정규 등) ② $Y = \sum_{i=1}^n T(x)$ 는 $\theta$ 의 CSS      ③ $E(T(X)) = A'(\eta)$ , $\text{Var}(T(X)) = A''(\eta)$					
	다변량 확장	1변수 1모수	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta)]$				
		1변수 다중모수	$f(x; \boldsymbol{\theta}) = \exp[\boldsymbol{\eta}(\boldsymbol{\theta}) \cdot \mathbf{T}(x) + H(x) - A(\boldsymbol{\eta})]$				
		다변량 다중모수	$f(\mathbf{x}; \boldsymbol{\theta}) = \exp[\boldsymbol{\eta}(\boldsymbol{\theta}) \cdot \mathbf{T}(\mathbf{x}) + H(\mathbf{x}) - A(\boldsymbol{\eta})]$				
		기대값	$\nabla A(\boldsymbol{\eta}) = E[\mathbf{T}(\mathbf{x})]$ , $\mathbf{H}[A(\boldsymbol{\eta})] = \text{Cov}(\mathbf{T}(\mathbf{x}))$ $\nabla A(\boldsymbol{\eta}_{mle}) = \frac{1}{n} \sum_{i=1}^n \mathbf{T}(\mathbf{x}_i)$				
	예시	분포	모수 $\theta$	자연모수 $\eta$	역모수	$\mathbf{T}(\mathbf{x})$	$A(\boldsymbol{\eta})$
		베르누이	$p$	$\ln \frac{p}{1-p}$	$\frac{1}{1+e^{-\eta}}$  * logistic function	$x$	$\ln(1+e^\mu)$
		이항					$n \ln(1+e^\mu)$
		푸아송	$m$	$\ln m$	$e^\eta$	$x$	$e^\eta$
		음이항( $r$ )	$p$	$\ln(1-p)$	$1-e^\eta$	$x$	$-r \ln(1-e^\mu)$
		다항( $n$ )	$\begin{bmatrix} p_1 \\ \vdots \\ p_{k-1} \end{bmatrix}$	$\begin{bmatrix} \ln \frac{p_1}{p_k} \\ \vdots \\ \ln \frac{p_{k-1}}{p_k} \end{bmatrix}$	$\begin{bmatrix} \frac{\exp(\eta_1)}{1 + \sum_{j=1}^{k-1} \exp(\eta_j)} \\ \vdots \\ \frac{\exp(\eta_{k-1})}{1 + \sum_{j=1}^{k-1} \exp(\eta_j)} \end{bmatrix}$  * softmax function	$\begin{bmatrix} x_1 \\ \vdots \\ x_{k-1} \end{bmatrix}$	$n \ln(1 + \sum_{j=1}^{k-1} \exp(\eta_j))$
		감마	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \alpha-1 \\ -\frac{1}{\beta} \end{bmatrix}$	$\begin{bmatrix} \eta_1+1 \\ -\frac{1}{\eta_2} \end{bmatrix}$	$\begin{bmatrix} \ln x \\ x \end{bmatrix}$	$\ln \Gamma(\eta_1+1) - (\eta_1+1) \ln(-\eta_2)$
		지수	$\beta$	$-\frac{1}{\beta}$	$-\frac{1}{\eta}$	$x$	$-\ln(-\eta)$
		카이제곱	$\nu$	$\frac{\nu}{2}-1$	$2(\eta+1)$	$\ln x$	$\ln \Gamma(\eta+1) + (\eta+1) \ln 2$
		베타	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \eta_1 \\ \eta_2 \end{bmatrix}$	$\begin{bmatrix} \ln x \\ \ln(1-x) \end{bmatrix}$	$\ln B(\alpha, \beta) = \ln \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
		정규 기지 $\sigma^2$	$\mu$	$\frac{\mu}{\sigma^2}$	$\sigma^2 \eta$	$x$	$\frac{1}{2} \sigma^2 \eta^2$
		정규 미지 $\sigma^2$	$\begin{bmatrix} \mu \\ \sigma^2 \end{bmatrix}$	$\begin{bmatrix} \frac{\mu}{\sigma^2} \\ -\frac{1}{2\sigma^2} \end{bmatrix}$	$\begin{bmatrix} -\frac{\eta_1}{2\eta_2} \\ -\frac{1}{2\eta_2} \end{bmatrix}$	$\begin{bmatrix} x \\ x^2 \end{bmatrix}$	$-\frac{\eta_1^2}{4\eta_2} - \frac{1}{2} \ln(-2\eta_2)$
		다변량 정규	$\begin{bmatrix} \boldsymbol{\mu} \\ \boldsymbol{\Sigma} \end{bmatrix}$	$\begin{bmatrix} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} \\ -\frac{1}{2} \boldsymbol{\Sigma}^{-1} \end{bmatrix}$	$\begin{bmatrix} -\frac{1}{2} \boldsymbol{\eta}_2^{-1} \boldsymbol{\eta}_1 \\ -\frac{1}{2} \boldsymbol{\eta}_2^{-1} \end{bmatrix}$	$\begin{bmatrix} \mathbf{x} \\ \mathbf{xx}^T \end{bmatrix}$	$-\frac{1}{4} \boldsymbol{\eta}_1^T \boldsymbol{\eta}_2^{-1} \boldsymbol{\eta}_1 - \frac{1}{2} \ln  -2\boldsymbol{\eta}_2 $