


1. 확률, 확률분포

<div>++조건 부 확률</div> <div>독립성</div>	<p>$C_1 \subset S$ 에서 C_1을 새로운 표본 공간으로 설정 $\rightarrow C_2 \subset S$에 대해</p> <p>1. $P(C_2 C_1) = P(C_1 \cap C_2 C_1) = \frac{P(C_1 \cap C_2)}{P(C_1)} \Leftrightarrow P(C_1 \cap C_2) = P(C_2 C_1) P(C_1)$</p> <p>2. Bayes ($C_i$는 상호 배반=disjoint, S의 partition)</p> <p>1) Law of total prob: $P(A) = \sum P(A \cap C_i) = \sum P(A C_i) P(C_i)$</p> <p>2) Bayes' theorem: $P(C_i A) = \frac{P(A \cap C_i)}{P(A)} = \frac{P(A C_i) P(C_i)}{\sum P(A C_i) P(C_i)}$</p> <p>① $P(C_i)$: C_i 사전확률 (prior)</p> <p>② $P(C_i A)$: C_i 사후확률 (posterior) \leftarrow 표본 A에서 관찰된 C_i</p> <p>3) 독립성: $P(A \cap B \cap C) = P(A)P(B)P(C)$ 이면 A,B,C는 statistically independent</p>
<div>확률 변수</div>	<p>1. Prob mass function; PMF (discrete) \rightarrow CDF of PMF: $F(x) = P((-\infty, x]) = \sum_{(-\infty, x]} p(x)$</p> <p>*변환: $p_y(y) = p_x(w(y))$; for 일대일 함수 $x = w(y)$</p> <p>2. Prob density function; PDF (continuous) >0</p> <p>1) $F(x) = \int_{-\infty}^x f(t)dt \Leftrightarrow 2) \frac{d}{dx} F(x) = f(x)$ (F는 f의 CDF)</p> <p>3) $P([a, b]) = \int_a^b f(x)dx = F(b) - F(a)$</p> <p>*변환: X가 pdf f_X on S_X & Y가 pdf f_Y on S_Y; 1-on-1 $w(y) = x$</p> <p>$\rightarrow f_Y(y) = f_X(w(y)) dx/dy \Leftrightarrow f_Y(y) = f_X(w(y)) \text{abs}(J)$ (Jacobian: $J = w'(y)$ / $J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{vmatrix}$) *$J$는 행렬식</p> <p>* Support(받침): PDF $\neq 0$인 space // *CDF는 유일 for PDF, PMF</p>
<div>기대값</div>	<p>1. 조건: $E(X)$ 존재 \Leftrightarrow ① 연속 pdf 존재 ② $\int_{-\infty}^{\infty} x f(x)dx < \infty$ (이산 pmf 존재 $\rightarrow \sum x_i p_i(x) < \infty$)</p> <p>2. 기대값: 1) $E(X) = \int_{-\infty}^{\infty} x f(x)dx$ 2) $E(X) = \sum x_i p(x_i)$</p> <p>3. $y = g(x)$: 1) $E(g(x)) = \int_{-\infty}^{\infty} g(x)f(x)dx$ & $E(g(x)) = \sum g(x_i)p(x_i)$</p> <p>2) $E(k_1g_1(x) + k_2g_2(x)) = k_1E(g_1(x)) + k_2E(g_2(x))$</p> <p>1. 평균: $\mu = E(X)$</p> <p>2. 분산: $\sigma^2 = Var(X) = E[(X - \mu)^2] = E(X^2) - \mu^2 = M''(0) - M'(0)^2$ *$Var(aX + b) = a^2Var(X)$</p> <p>3. 적률생성함수 (MGF) *조건: $t \in (-h, h)$ for $\forall h > 0 \leftarrow 0$을 포함하는 개구간에서 mgf 존재</p> <p>1) $M(t) = E(e^{tx}) \rightarrow M_X(0)^{(r)} = E(X^r)$ *분포의 r차 moment</p> <p>① $M(0)^{(r)} = \frac{d^r}{dt^r} \int_{-\infty}^{\infty} e^{tx} f(x)dx \Big _{t=0} = \int_{-\infty}^{\infty} \frac{d^r}{dt^r} e^{tx} f(x)dx \Big _{t=0} = \int_{-\infty}^{\infty} x^r e^{tx} f(x)dx \Big _{t=0} = \int_{-\infty}^{\infty} x^r f(x)dx = E(X^r)$</p> <p>② $M(0)^{(r)} = \frac{d^r}{dt^r} \sum e^{tx_i} p(x_i) \Big _{t=0} = \sum \frac{d^r}{dt^r} e^{tx_i} p(x_i) = \sum x_i^r e^{tx_i} p(x_i) \Big _{t=0} = \sum x_i^r p(x_i) = E(X^r)$</p> <p>2) 성질 ① MGF의 유일성: $M_X(t) = M_Y(t) \Leftrightarrow X = Y$ (pdf 동일)</p> <p>② $M_{X+\alpha}(t) = e^{at} M_X(t) \quad \because M_{X+\alpha}(t) = E(e^{t(x+\alpha)}) = e^{at} E(e^{tx}) = e^{at} M_X(t)$</p> <p>③ $M_{\alpha X}(t) = M_X(at) \quad \because M_{\alpha X}(t) = E(e^{t(\alpha X)}) = E(e^{(at)X}) = M_X(at)$</p> <p>④ $M_{aX+b}(t) = e^{bt} M_X(at)$</p> <p>⑤ $M_Y(t) = \prod M_{X_i}(k_i t), t < \min(h_i)$ (for $Y = \sum k_i X_i$, X_i는 모두 독립)</p> <p>$\because M_Y(t) = E(\exp(tY)) = E(\exp(t \sum k_i X_i)) = E(\prod \exp(tk_i X_i)) = \prod E(\exp(tk_i X_i))$</p> <p>⑥ $M_Y(t) = [M(t)]^n$ (for $Y = \sum X_i$, X_i는 iid 확률변수)</p>
<div>중요한 부등식</div>	<p>1. $E(X^m)$이 존재하면 $\rightarrow E(X^k)$ 존재 for $k \leq m$</p> <p>*증명: $E(X^k) = \int_{-\infty}^{\infty} x ^k f(x)dx = \int_{ x \leq 1} x ^k f(x)dx + \int_{ x \geq 1} x ^k f(x)dx \leq \int_{ x \leq 1} f(x)dx + \int_{ x \geq 1} x ^m f(x)dx$</p> <p>$\leq \int_{-\infty}^{\infty} f(x)dx + \int_{-\infty}^{\infty} x ^m f(x)dx \leq 1 + E(X^m) \therefore$ 유한함</p> <p>2. Markov: $P[u(X) \geq c] \leq E[u(X)]/c$ (for $u(X) \geq 0, c > 0$; $E[u(X)]$ 존재)</p> <p>*증명: $E[u(x)] = \int_{-\infty}^{\infty} u(x)f(x)dx \geq \int_{u(x) \geq c} u(x)f(x)dx \geq c \int_{u(x) \geq c} f(x)dx = c P[u(x) \geq c]$</p> <p>*직관: 평균 나이의 5배 보다 나이 많은 사람의 확률한계 $\rightarrow P[X \geq 5\mu] \leq \frac{1}{5}$</p> <p>3. Chebyshev: $P(X - \mu \geq k\sigma) \leq 1/k^2$ (for $k > 0$; X가 μ, σ^2(유한) 가짐)</p> <p>*증명: Markov에서 $u(X) = (X - \mu)^2, c = k^2\sigma^2$</p>

2-1. 이변량분포

이변수	<p>1) Joint CDF: $F(x, y) = P(\{X \leq x\} \cap \{Y \leq y\})$ * $\mathbf{X} = (X, Y)^T \in D$; Random vector X</p> <p>* $P((a_1, a_2] \times (b_1, b_2]) = F(a_2, b_2) - F(a_1, b_2) - F(a_2, b_1) + F(a_1, b_1) = \int_{b_1}^{b_2} \int_{a_1}^{a_2} f(x, y) dx dy$</p> <p>2) Joint PMF: $\sum_y \sum_x p(x, y) = 1$</p> <p>3) Joint PDF: $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(x, y) dy dx$ ($\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$) $\Leftrightarrow \frac{\partial^2(F)}{\partial x \partial y} = f(x, y)$</p> <p>4) Marginal dist: 한 변수의 효과만 봄; 다른 변수는 $(-\infty, \infty)$ 전부 포괄 * $F_X(x) = P(\{X \leq x\}) = P(\{X \leq x\} \cap \{-\infty < Y < \infty\})$ ① PMF of x: $F_X(x) = \sum_{(-\infty, x]} \{\sum_{y \in (-\infty, \infty)} p(x, y)\} \rightarrow p_X(x) = \sum_{y \in (-\infty, \infty)} p(x, y)$ ② PDF of x: $F_X(x) = \int_{-\infty}^x \{\int_{-\infty}^{\infty} f(x, y) dy\} dx \rightarrow f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$</p>
이변수 기대값	<p>* $E(g(X, Y))$ 존재 조건 $\Leftrightarrow E(g(X, Y)) < \infty$</p> <p>기대값: $E(g(X, Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$ (이산형: $E(g(X, Y)) = \sum \sum g(x, y) p(x, y)$)</p> <p>1) $E(k_1 g_1 + k_2 g_2) = k_1 E(g_1) + k_2 E(g_2)$ 2) $E(\mathbf{X}) = [E(X) \ E(Y)]^T = [\int_{-\infty}^{\infty} x f(x, y) dx dy \ \int_{-\infty}^{\infty} y f(x, y) dx dy]^T$</p> <p>3) $M(t_1, t_2) = E(\exp(t_1 X + t_2 Y)) \rightarrow \mathbf{t} = (t_1, t_2)^T$에 대해 $M(\mathbf{t}) = E(\exp(\mathbf{t}^T \mathbf{X}))$ $E(X^k Y^m) = \frac{\partial^{k+m}}{\partial t_1^k \partial t_2^m} M(0, 0) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^k y^m \exp(t_1 x + t_2 y) f(x, y) dx dy$</p>
이변수 변환	<p>* 변환 조건: 1) $\mathbf{X} = (X_1, X_2)$의 받침 S 2) $S \rightarrow T$ 사상하는 일대일 대응: $y_1 = u_1(x_1, x_2)$ & $y_2 = u_2(x_1, x_2)$ 3) $T \rightarrow S$ 사상하는 위 대응 역: $x_1 = w_1(y_1, y_2)$ & $x_2 = w_2(y_1, y_2)$</p> <p>1. 이산형 변환: $p_Y(y_1, y_2) = p_X[w_1(y_1, y_2), w_2(y_1, y_2)]$ for $(y_1, y_2) \in T$ & 나머지 pmf 0 * $X_1, X_2 \rightarrow Y$로만 변환 시, dummy 변수를 하나 더 만들어 Y_2로 지정해주고 marginal Y dist를 구 함</p> <p>2. 연속형 변환: $f_Y(y_1, y_2) = f_X[w_1(y_1, y_2), w_2(y_1, y_2)] J$ for $(y_1, y_2) \in T$ & 나머지 pdf 0 * MGF 이용 변환: $E(\exp(tY)) = E(\exp(t(X_1 + X_2))) \rightarrow$ MGF 유일성으로 Y의 PMF/PDF 구함</p>
조건부	<p>1. 조건부 PMF: $p_{2 1}(x_2 x_1) = \frac{p(x_1, x_2)}{p_1(x_1)}$</p> <p>2. 조건부 PDF: $f_{2 1}(x_2 x_1) = \frac{f(x_1, x_2)}{f_1(x_1)}$ (f_1는 $f_{1,2}$의 marginal 분포, 직관적으로는 $f_1(x_1)$는 스케일러) 1) $P(a < Y < b X = x) = \int_a^b f_{Y X}(y x) dy$ & $P(c < X < d Y = y) = \int_c^d f_{X Y}(x y) dx$ 2) $P(-\infty < Y < \infty X = x) = \int_{-\infty}^{\infty} f_{Y X}(y x) dy = \int_{-\infty}^{\infty} \frac{f(x, y)}{f_X(x)} dy = \frac{1}{f_X(x)} \int_{-\infty}^{\infty} f(x, y) dy = 1$ 3) 조건부 기대값: $E(\mathbf{u}(Y) x) = \int_{-\infty}^{\infty} u(y) f_{Y X}(y x) dy \rightarrow \mathbf{x}$의 함수 ① 조건부 평균: $E(Y x) = \int_{-\infty}^{\infty} y f_{Y X}(y x) dy$ ② 조건부 분산: $\text{Var}(Y x) = E(Y^2 x) - [E(Y x)]^2$</p> <p>* 정리: μ_Y 추정 $\leftarrow E(Y X)$이 Y보다 더 신뢰도 높음 (Rao & Blackwell) 1) $E[E(Y X)] = E(Y)$ 2) $\text{Var}(E(Y X)) \leq \text{Var}(Y)$ * Y 분산 유한 * 증명: $E(Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dy dx = \int_{-\infty}^{\infty} [\int_{-\infty}^{\infty} y f_{Y X}(y x) dy] f_X(x) dx = \int_{-\infty}^{\infty} E(Y X) f_X(x) dx = E(E(Y X))$</p>
공분산 / 상관 계수	<p>1. 공분산: $\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - E(X)E(Y)$ * 독립이면 $\text{Cov}(X, Y) = 0 \Leftrightarrow E(XY) = E(X)E(Y)$</p> <p>2. 상관계수: $\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \sigma_{XY} / (\sigma_X \sigma_Y)$ ($-1 \leq \rho \leq 1$) $\rightarrow y = a + bx$ ($b > 0$)에 ρ의 강도로 집중 ($0 < \rho \leq 1$)</p> <p>3. 선형조건부평균: $E(Y X) = a + bx \rightarrow E(Y X) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X)$ & $E(\text{Var}(Y X)) = \sigma_Y^2 (1 - \rho^2)$ * 회귀분석 모회귀계수 $\beta = \rho(\sigma_Y / \sigma_X) = \text{Cov}(X, Y) / \text{Var}(X)$; * X, Y 분산 유한</p>
독립	<p>* 정의: $f(x, y) = f_X(x) f_Y(y) \Leftrightarrow X, Y$는 독립 [$x \in (a, b)$ & $y \in (c, d)$] (받침이 수평/수직선 box에 존재해야 함)</p> <p>1. 조건부 증명: $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \int_{-\infty}^{\infty} f_{Y X}(y x) f_X(x) dx = f_{Y X}(y x) \int_{-\infty}^{\infty} f_X(x) dx = f_{Y X}(y x)$</p> <p>2. 동치류 1) $f(x, y) = f_X(x) f_Y(y)$ 2) $F(x, y) = F_X(x) F_Y(y)$ * 증명: $\partial^2 F / \partial x \partial y = f_X(x) f_Y(y)$ 3) $P(a < X < b, c < Y < d) = P(a < X < b) P(c < Y < d)$ * 증명: $P(a < X < b, c < Y < d) = F(b, d) - F(a, d) - F(b, c) + F(a, c) = [F_X(b) - F_X(a)][F_Y(d) - F_Y(c)]$ 4) $E[u(X)v(Y)] = E[u(X)] E[v(Y)] \Rightarrow E(XY) = E(X)E(Y) \Leftrightarrow \text{Cov}(X, Y) = 0$ 5) $M(t_1, t_2) = M(t_1, 0) M(0, t_2)$ * 증명: $M(t_1, t_2) = E(e^{t_1 X + t_2 Y}) = E(e^{t_1 X}) E(e^{t_2 Y}) = M(t_1, 0) M(0, t_2)$ * $M(t_1, 0)$는 f_X의 MGF ($\because M(t_1, 0) = E(e^{t_1 X}) = \int_{-\infty}^{\infty} e^{t_1 x} [\int_{-\infty}^{\infty} f(x, y) dy] dx = \int_{-\infty}^{\infty} e^{t_1 x} f_X(x) dx$)</p>



2-2. 다변량분포

다변수	<p>* $\mathbf{x} = (x_1, x_2, \dots, x_p)^T = (X_1(c), X_2(c), \dots, X_p(c))^T$ for 확률 실험 $c \in C$</p> <p>1. 결합 확률 함수들</p> <p>1) Joint CDF: $F(\mathbf{x}) = P[\{X_1 \leq x_1\} \cap \{X_2 \leq x_2\} \cap \dots \cap \{X_p \leq x_p\}]$</p> <p>2) Joint PMF $F(\mathbf{x}) = \sum_{w_1 \leq x_1} \dots \sum_{w_p \leq x_p} p(w_1, \dots, w_p)$</p> <p>3) Joint PDF: $F(\mathbf{x}) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_p} f(x_1, \dots, x_p) dx_p \dots dx_1 \quad (\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_p \dots dx_1 = 1)$ $\Leftrightarrow \frac{\partial^p \{F(\mathbf{x})\}}{\partial x_1 \dots \partial x_p} = f(\mathbf{x})$</p>
	<p>2. Marginal/Conditional</p> <p>1) $f_1(x_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_2 \dots dx_p$ $\rightarrow f_{2, \dots, p 1}(x_2, \dots, x_p x_1) = \frac{f(\mathbf{x})}{f_1(x_1)}$</p> <p>2) $f_{2,4,5}(x_2, x_4, x_5) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(\mathbf{x}) dx_1 dx_3 dx_6 \quad \leftarrow \mathbf{x} = (x_1, x_2, x_3, x_4, x_5, x_6)^T$ $\rightarrow f_{1,3,6 2,4,5}(x_1, x_3, x_6 x_2, x_4, x_5) = \frac{f(\mathbf{x})}{f_{2,4,5}(x_2, x_4, x_5)}$</p>
	<p>3. 기대값</p> <p>1) $E(u(\mathbf{x})) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(x_1, \dots, x_p) dx_1 \dots dx_p$ (존재성: $\exists E(u(\mathbf{x}))$) *이산: $E(u(\mathbf{x})) = \sum_{x_1} \dots \sum_{x_p} u(x_1, \dots, x_p)$</p> <p>2) $E(\sum k_i Y_i) = \sum k_i E(Y_i)$</p> <p>3) $E[u(X_2, \dots, X_p) x_1] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(x_2, \dots, x_p) f_{2, \dots, p 1}(x_2, \dots, x_p x_1) dx_2 \dots dx_p$</p>
	<p>4. 독립: $E(\prod u_i(X_i)) = \prod E(u_i(X_i))$ 등 동치류 (f, F, P, E, M) *iid (independent and identically distributed): 여러 확률 변수가 서로 독립 & 동일한 분포</p>
	<p>5. 변환: \mathbf{X}의 받침 S에 대해, $\mathbf{X} \Leftrightarrow \mathbf{Y}$가 일대일이 되는 S_1, \dots, S_k의 부분 공간 상 각각의 야코비안 J_i 정의</p> $g(\mathbf{y}) = \sum_{i=1}^k J_i f[w_{1i}(\mathbf{y}), \dots, w_{pi}(\mathbf{y})]$
Random matrix	<p>* Random matrix $\mathbf{W} = [W_{ij}]$, W_{ij} ($1 \leq i \leq m$, $1 \leq j \leq n$)</p> <p>1. $E(\mathbf{W}) = [E(W_{ij})]$ (일렬로 배열하여 $m \times n$의 벡터로 생각)</p> <p>1) $E[\mathbf{A}\mathbf{W} + \mathbf{B}\mathbf{V}] = \mathbf{A}E[\mathbf{W}] + \mathbf{B}E[\mathbf{V}]$ (\mathbf{A}, \mathbf{B}: $k \times m$ 상수 행렬, \mathbf{W}, \mathbf{V}: $m \times n$ 확률 행렬)</p> <p>2) $E[\mathbf{A}\mathbf{W}\mathbf{B}] = \mathbf{A}E(\mathbf{W})\mathbf{B}$ (\mathbf{A}: $k \times m$, \mathbf{W}: $m \times n$, \mathbf{B}: $n \times l$)</p> <p>2. 분산-공분산 행렬 (Variance-Covariance matrix) *$\mathbf{X} = (X_1, X_2, \dots, X_p)^T$; 모든 VCM는 양의 반정부호(psd)</p> <p>1) 정의: $\text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = [\sigma_{ij}]$ ($\boldsymbol{\mu} = E(\mathbf{X})$) $\rightarrow \sigma_i^2 = \text{Var}(X_i)$ & $\sigma_{ij} = \text{Cov}(X_i, X_j)$</p> <p>2) 정리 ① $\text{Cov}(\mathbf{X}) = E(\mathbf{X}\mathbf{X}^T) - \boldsymbol{\mu}\boldsymbol{\mu}^T$ ($\sigma_i^2 < \infty$) ② $\text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A}\text{Cov}(\mathbf{X})\mathbf{A}^T$ ($\sigma_i^2 < \infty$, \mathbf{A}: $m \times p$) $\because \text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A}E(\mathbf{X}\mathbf{X}^T)\mathbf{A}^T - \mathbf{A}E(\mathbf{X})E(\mathbf{X})^T\mathbf{A}^T$</p> <p>3. MGF: $M(\mathbf{t}) = E[\exp(\mathbf{t}^T \mathbf{X})] = E[\prod_{i=1}^p \exp(t_i X_i)]$ (*X_i 독립 $\rightarrow M(\mathbf{t}) = M(t_1, \dots, 0) \dots M(0, \dots, t_p) = \prod_{i=1}^p E[\exp(t_i X_i)]$)</p> <p>1) $M_Y(\mathbf{t}) = \prod M_{X_i}(\mathbf{t})$ ($\mathbf{Y} = \sum \mathbf{X}_i$, 각 $\mathbf{X}_i \in \mathbb{R}^n$은 독립) *다변량 MGF는 스칼라</p> <p>2) $M_Y(\mathbf{t}) = e^{\mathbf{b}^T \mathbf{t}} M_X(\mathbf{A}^T \mathbf{t})$ ($\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$; \mathbf{A}: $m \times p$; $\mathbf{t} \in \mathbb{R}^m$; $\mathbf{b} \in \mathbb{R}^m$)</p> <p>3. 선형결합: $T = \sum_{i=1}^n a_i X_i$, $W = \sum_{i=1}^m b_i Y_i$</p> <p>1) $E(T) = \sum_{i=1}^n a_i E(X_i)$ (*$E[X_i] < \infty$) $\because E(X_1 + X_2) = \int \int (x_1 + x_2) f(x_1, x_2) dx_1 dx_2 = E(X_1) + E(X_2)$</p> <p>2) $\text{Cov}(T, W) = \sum \sum a_i b_j \text{Cov}(X_i, Y_j)$ (*$E[X_i^2] < \infty$, $E[Y_j^2] < \infty$)</p> <p>① $\text{Var}(T) = \text{Cov}(T, T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$ (*$E[X_i^2] < \infty$)</p> <p>② $\text{Var}(T) = \text{Cov}(T, T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i)$ (*X_1, \dots, X_n이 유한 분산, 독립)</p> <p>3) 표본 추정량: X_1, \dots, X_n이 μ, σ^2 가지는 iid 확률변수</p> <p>① 표본평균: $\bar{X} = \sum_{i=1}^n X_i / n$ & 표본분산: $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1) = \sum X_i^2 - n\bar{X}^2 / (n-1)$</p> <p>② $E(\bar{X}) = \sum_{i=1}^n E(X_i) / n = n\mu / n = \mu$ & $\text{Var}(\bar{X}) = \sum_{i=1}^n (\frac{1}{n})^2 \text{Var}(X_i) = n(\frac{1}{n})^2 \sigma^2 = \sigma^2 / n$</p> <p>③ $E(S^2) = \sum E(X_i^2) - nE(\bar{X}^2) / (n-1) = \frac{n(\mu^2 + \sigma^2) - n(\mu^2 + \frac{\sigma^2}{n})}{n-1} = \sigma^2$ $(\bar{X}, S^2 \text{는 독립 by Student's 정리})$</p>

3-1. 주요 분포: 이산

이항 분포	<p>* Bernoulli experiment: 성공/실패로 서로 배반인 확률 실험</p> <p>* Bernoulli trial: 베르누이 실험을 독립적으로 반복 (성공 확률 p 동일)</p> <p>* Bernoulli distribution의 유도: $X(\text{성공})=1, X(\text{실패})=0 \rightarrow \text{PMF: } p(x) = p^x(1-p)^{1-x} \quad * \mu = p, \sigma^2 = p(1-p)$</p>
	<p>* Binomial distribution (이항분포): n회 반복한 베르누이 시행에서 성공한 총 횟수 분포</p> <p>1. PMF: $p(x) = \binom{n}{x} p^x (1-p)^{n-x} \sim b(n, p) \quad (x = 0, 1, \dots, n)$</p> <p>2. MGF: $M(t) = \sum e^{tx} p(x) = [(1-p) + (pe^t)]^n \quad (t \in \mathbb{R})$</p> <p>3. 기대값 1) $\mu = np$ $* \mu = M'(0) = n[(1-p) + pe^t]^{n-1}(pe^t) _{t=0} = np$</p> <p style="margin-left: 150px;">2) $\sigma^2 = np(1-p)$ $* \sigma^2 = M''(0) - (M'(0))^2 = n(n-1)p^2 + np - (np)^2 = np(1-p)$</p> <p>4. 가법성: $Y = \sum X_i, X_i \sim B(n_i, p) \rightarrow Y \sim B(\sum n_i, p)$ (증명) $M_Y(t) = \prod M_{X_i}(t) = \prod [(1-p) + (pe^t)]^{n_i} = [(1-p) + (pe^t)]^{\sum n_i}$</p> <p>* $p(x)$가 성공확률(= 평균) p인 Bernoulli분포 $\leftrightarrow X \sim B(1, p)$ $\rightarrow Y = \sum_{i=1}^{20} X_i$ (iid)에 대해 $p(y)$는 20회 시행 중 평균 20p회 성공하는 Bernoulli $\leftrightarrow Y \sim B(20, p)$</p>
	<p>* Multinomial distribution (다항분포)</p> <p>1. PMF: $p(x_1, \dots, x_{k-1}) = \frac{n!}{(x_1)! \dots (x_k)!} (p_1)^{x_1} \dots (p_k)^{x_k} \rightarrow p_k = 1 - \sum_{i=1}^{k-1} p_i \text{ \& } x_k = n - \sum_{i=1}^{k-1} x_i$</p> <p>2. MGF: $M(t_1, \dots, t_{k-1}) = (p_1 e^{t_1} + \dots + p_{k-1} e^{t_{k-1}} + p_k)^n$</p>
	<p>* R codes 1) <code>dbinom(k, n, p): P(X=k)</code> 2) <code>pbinom(k, n, p): P(X≤k)</code></p>
	<p>* Negative binomial distribution (음이항분포): X번 실패 후 r번 성공 (베르누이 시행) *r번 성공시 나감</p> <p>1. PMF: $p(x) = \binom{x+r-1}{r-1} p^r (1-p)^x$ 2. MGF: $M(t) = p^r [1 - (1-p)e^t]^{-r} \quad (e^t < 1/(1-p))$ \Leftrightarrow [이항: $x+(r-1)$번 중 $(r-1)$번 성공] $\times [p]$ $* \binom{-n}{k} = (-n)(-n-1)\dots(-n-k+1)/k! = (-1)^k \binom{n+k-1}{k}$</p>
	<p>* Geometric distribution (기하 분포): X번 실패 후 처음 성공 (베르누이 시행) $\Leftrightarrow r=1$인 음이항분포</p> <p>1. PMF: $p(x) = p(1-p)^x$ 2. MGF: $M(t) = p[1 - (1-p)e^t]^{-1}$</p>
Poisson 분포	<p>* Hypergeometric distribution (초기하분포)</p> <p>1. PMF: $p(x) = \frac{\binom{D}{x} \binom{N-D}{n-x}}{\binom{N}{n}}$ $* N$개 중 D개가 성공 & 비복원추출: n번 시행 $\rightarrow x$번 성공 확률</p> <p>2. 기대값: 1) $\mu = n \left(\frac{D}{N}\right)$ 2) $\sigma^2 = n \left(\frac{D}{N}\right) \left(1 - \frac{D}{N}\right) \frac{(N-n)}{(N-1)}$ $N \gg n$이면 이항분포로 근사 가능</p>
	<p>* Poisson process: 일정한 구간 (시간, 공간)에서 독립적으로 발생하는 event를 생성하는 과정 (비기역성)</p> <p>* Poisson postulate: 짧은 구간 h ($h \rightarrow 0$)에 대해</p> <p>1) $g(1, h) = \lambda h + o(h)$ $* g(x, w)$는 구간 길이 w 내에 x회 발생 확률</p> <p>2) $\sum_{x=2}^{\infty} g(x, h) = o(h)$ (\approx 미소 구간 h에 둘 이상은 본질적 불가) $* \lim_{h \rightarrow 0} o(h)/h = 0$ (little-o)</p> <p>3) 겹치지 않는 구간 \rightarrow 확률적으로 독립 $\therefore g(x, w) = \frac{e^{-\lambda w} (\lambda w)^x}{x!}$</p>
	<p>1. PMF: $p(x) = \frac{e^{-\mu} \mu^x}{x!} \quad (x = 0, 1, 2, \dots)$ ($* \sum p(x) = e^{-\mu} \sum \left(\frac{\mu^x}{x!}\right) = e^{-\mu} e^{\mu} = 1$) \leftarrow 주어진 시간에 x회 발생 분포</p> <p>2. 기댓값: $\mu = \sigma^2 = \lambda w$ (λ 단위 길이당 발생률, w: 주어진 영역 크기)</p> <p>3. MGF: $M(t) = e^{\mu(e^t-1)} \quad (t \in \mathbb{R})$</p> <p>4. 가법성: $Y = \sum X_i, X_i \sim \text{Poi}(m_i) \rightarrow Y \sim \text{Poi}(\sum m_i)$ (증명) $M_Y(t) = \prod M_{X_i}(t) = \prod e^{m_i(e^t-1)} = e^{(\sum m_i)(e^t-1)}$</p>
	<p>* $p(x)$가 주어진 100초당 평균 μ회 발생 Poisson $\leftrightarrow X \sim \text{Poi}(\mu)$ $\rightarrow Y = \sum_{i=1}^{20} X_i$ (iid)에 대해 $p(y)$는 $Y \sim \text{Poi}(20\mu)$ ($* \text{두 가지 해석: } 20 \times 100 \text{초로 확장 or } 20\lambda \text{ 발생률로 중첩}$)</p> <p>* 이항분포 $b(n, p) \xrightarrow{D} \text{푸아송분포 } (\mu = np)$ (MGF의 극한으로 분포수렴 증명 / 짧은 간격의 n회 베르누이)</p> <p>* R codes 1) <code>dpois(k, m): P(X=k)</code> 2) <code>ppois(k, m): P(X≤k)</code></p>

3-2. 주요 분포: 감마 연관 분포

Γ 분포	<p>* 감마함수: $\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y} dy$ ($\alpha > 0$)</p> <p>* $\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1) \rightarrow \Gamma(n) = (n - 1)!$ for 자연수 n * $\Gamma(1) = 1, \Gamma(1/2) = \sqrt{\pi}$</p> <p>* 스텔링 근사: $\Gamma(k + 1) \approx \sqrt{2\pi k} \left(\frac{k}{e}\right)^k$</p>
	<p>* Gamma distribution (감마분포): $\alpha (\in \mathbb{R})$ 번째 Poisson event 발생까지 걸리는 대기 시간</p> <p>1. PDF: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \sim \Gamma(\alpha, \beta)$ ($0 \leq x < \infty$) (감마함수 식에 $y = x/\beta$ 대입; $\alpha > 0$ & $\beta > 0$)</p> <p>2. 기댓값: 1) $\mu = \alpha\beta$, 2) $\sigma^2 = \alpha\beta^2$</p> <p>3. MGF: $M(t) = 1/(1 - \beta t)^\alpha$ ($t < 1/\beta$)</p> <p>4. 가법성: $Y = \sum X_i, X_i \sim \Gamma(\alpha_i, \beta) \rightarrow Y \sim \Gamma(\sum \alpha_i, \beta)$ (증명) $M_Y(t) = \prod M_{X_i}(t) = \prod (1 - \beta t)^{-\alpha_i} = (1 - \beta t)^{-\sum \alpha_i}$</p> <p>5. 스칼라배: $X \sim \Gamma(\alpha, \beta) \Rightarrow kX \sim \Gamma(\alpha, k\beta)$ (*증명: 야코비안 변수변환)</p> <p>6. 유도: k번 Poisson event 발생까지 시간을 T_i로 분할 \rightarrow 각 $T_i \sim \Gamma(1, \frac{1}{\lambda}) \rightarrow Y = \sum_{i=1}^k T_i \sim \Gamma(k, \frac{1}{\lambda})$ (*Erlang 분포: 자연수 k인 감마 분포)</p>
	<p>* R codes 1) dgamma (x, shape=a, scale=b): f(X=x) 2) pgamma (x, shape=a, scale=b): P(X≤x)</p>
지수 분포	<p>* Exponential distribution (지수분포): 1번째 Poisson event 발생까지 대기 시간 = $\Gamma(1, \beta)$</p> <p>1. PDF: $f(x) = \frac{1}{\beta} e^{-x/\beta}$ 2. 기댓값: 1) $\mu = \beta$, 2) $\sigma^2 = \beta^2$</p> <p>3. 유도: W가 첫 번째 Poisson event 까지 걸린 시간 \rightarrow w시간 내 푸아송 사건 없을 확률: $P(W > w) = \frac{e^{-\lambda w} (\lambda w)^0}{0!} = e^{-\lambda w} \Leftrightarrow P(0 < W < w) = 1 - e^{-\lambda w}$ $\therefore f(w) = \lambda e^{-\lambda w}$ ($\beta = 1/\lambda$)</p>
χ^2 분포	<p>* Chi-square distribution (카이제곱 분포): 자유도 r에 대해, $\chi^2(r) = \Gamma(\frac{r}{2}, 2)$</p> <p>1. PDF: $f(x) = \frac{1}{\Gamma(\frac{r}{2}) 2^{\frac{r}{2}}} x^{\frac{r}{2}-1} e^{-\frac{x}{2}} \sim \chi^2(r)$ ($0 \leq x < \infty$)</p> <p>2. 기댓값: 1) $\mu = r$, 2) $\sigma^2 = 2r$ 3. MGF: $M(t) = 1/(1 - 2t)^{r/2}$ ($t < 1/2$)</p> <p>4. $E(X^k) = 2^k \frac{\Gamma(\frac{r}{2} + k)}{\Gamma(\frac{r}{2})}$, $k > -\frac{r}{2}$</p> <p>5. 가법성 (corollary): $Y = \sum X_i, X_i \sim \chi^2(r_i) \rightarrow Y \sim \chi^2(\sum r_i)$</p>
	<p>* R codes 1) dchisq (x,r): f(X=x) 2) pchisq (x,r): P(X≤x)</p>
β 분포	<p>* 베타함수: $B(\alpha, \beta) = \int_0^1 y^{\alpha-1} (1-y)^{\beta-1} dy$ ($\alpha > 0, \beta > 0$)</p> <p>① $B(\alpha, \beta) = B(\beta, \alpha)$, ② $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$</p> <p>* 결합 PDF: $h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-(x_1+x_2)}$; $0 \leq x_1 < \infty, 0 \leq x_2 < \infty$ (X_1, X_2 독립)</p> <p>* $Y_1 = X_1/(X_1 + X_2)$ & $Y_2 = X_1 + X_2 \rightarrow Y_1$에 대한 marginal distribution이 beta(α, β)</p> <p>1. PDF: $f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$ ($0 < x < 1$)</p>
	<p>* R codes 1) dbeta(x,a,b): f(X=x) 2) pbeta (x,a,b): P(X≤x)</p>
Dirichlet 분포 (β 확장)	<p>* 결합 PDF: $h(x_1, \dots, x_{k+1}) = \prod_{i=1}^{k+1} \frac{1}{\Gamma(\alpha_i)} x_i^{\alpha_i-1} e^{-x_i}$; $0 \leq x_i < \infty$ (X_1, \dots, X_k 독립)</p> <p>* $Y_i = \frac{X_i}{\sum_{i=1}^{k+1} X_i}$ ($i = 1, 2, \dots, k$) & $Y_{k+1} = \sum_{i=1}^{k+1} X_i \rightarrow Y_1, \dots, Y_k$에 대한 marginal dist이 Dirichlet($\alpha_1, \dots, \alpha_{k+1}$)</p> <p>1. PDF: $g(y_1, \dots, y_{k+1}) = \frac{\Gamma(\alpha_1 + \dots + \alpha_{k+1})}{\Gamma(\alpha_1) \dots \Gamma(\alpha_{k+1})} y_1^{\alpha_1-1} \dots y_k^{\alpha_k-1} [1 - (y_1 + \dots + y_k)]^{\alpha_{k+1}-1}$ ($0 \leq y_k, \sum_{i=1}^k y_i < 1$)</p>

3-3. 주요 분포: 정규 분포

정규 분포	<p>*표준정규분포: $I = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz \rightarrow 0 < \exp\left(-\frac{z^2}{2}\right) < \exp(- z + 1)$ 유계 ($\int_{-\infty}^{\infty} e^{- z +1} dz = 2e$)</p> <p>$\rightarrow I^2 = \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \exp\left(-\frac{x^2+y^2}{2}\right) dx dy = \frac{1}{2\pi} \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta = 1 \quad \therefore f(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right)$</p> <p>*정규분포: $X = \sigma Z + \mu$ 로 변수 변환 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$</p> <p>*Bell shape 분포: location 모수 (μ), scale 모수 (σ^2) vs. 감마분포 등: shape 모수 (α), scale 모수 (β)</p>
	<p>*표준 정규 분포 $N(0, 1^2)$</p> <p>1. PDF: $\phi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \quad (-\infty < z < \infty)$</p> <p>2. MGF: $M(t) = \exp\left(\frac{1}{2}t^2\right), t \in \mathbb{R}$ 3. 기대값: $E(Z) = 0, \text{Var}(Z) = 1$</p> <p>4. $E(Z^k) = \frac{k!}{2^{\frac{k}{2}} \left(\frac{k}{2}\right)!} \quad (k \text{가 짝수}), \quad E(Z^k) = 0 \quad (k \text{가 홀수}) \quad * M(t) = \exp\left(\frac{1}{2}t^2\right) = \sum_{m=0}^{\infty} \left(\frac{t^2}{2}\right)^m / m!$</p>
	<p>*정규 분포 $N(\mu, \sigma^2)$</p> <p>1. PDF: $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} \quad (-\infty < x < \infty, \sigma > 0)$</p> <p>2. MGF: $M(t) = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right), t \in \mathbb{R} \quad (\because M_X(t) = M_{\sigma Z + \mu}(t) = e^{\mu t} M(\sigma t) = e^{\mu t + \frac{1}{2}\sigma^2 t^2})$</p> <p>3. 기대값: $E(Z) = \mu, \text{Var}(Z) = \sigma^2$</p> <p>4. $E(X^k) = E[(\sigma Z + \mu)^k] = \sum_{j=0}^k \binom{k}{j} \sigma^j E(Z^j) \mu^{k-j}$</p> <p>5. 가법성: $Y = \sum a_i X_i, X_i \sim N(\mu_i, \sigma_i^2) \rightarrow Y \sim N[\sum(a_i \mu_i), \sum(a_i \sigma_i)^2]$ *두 모수에 대한 가법성 (증명) $M_Y(t) = \prod M_{a_i X_i}(t) = \prod M_{X_i}(a_i t) = \prod \exp\left(\mu_i(a_i t) + \frac{1}{2}\sigma_i^2(a_i t)^2\right) = \exp\left(\left(\sum a_i \mu_i\right)t + \frac{1}{2}\left(\sum a_i^2 \sigma_i^2\right)t^2\right)$</p> <p>6. Corollary: $\bar{X} = \sum_{i=1}^n X_i / n, X_i \sim N(\mu, \sigma^2) \text{ (iid)} \rightarrow \bar{X} \sim N(\mu, \sigma^2/n)$ *X_i가 iid 정규분포 $\rightarrow \bar{X}$ 무조건 정규분포</p>
	<p>* 정리: $Z^2 \sim \chi^2(1)$</p> <p>pf) $W = Z^2$ 일 때, $F(x) = P(W \leq x) = P(Z^2 \leq x) = P(-\sqrt{x} \leq Z \leq \sqrt{x}), x \geq 0$</p> <p>$\rightarrow z = \sqrt{w}$ 변환 시, $F(x) = 2 \int_0^{\sqrt{x}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz = \int_0^x \frac{1}{\sqrt{2\pi w}} \exp\left(-\frac{w}{2}\right) dw$</p> <p>$\rightarrow f(x) = \frac{1}{\sqrt{2\pi}} x^{-\frac{1}{2}} e^{-\frac{x}{2}} = \frac{1}{\Gamma(\frac{1}{2}) 2^{1/2}} x^{\frac{1}{2}-1} e^{-\frac{x}{2}} \sim \chi^2(1) \quad (0 \leq x < \infty)$</p>
	<p>* 따름 정리: $Y = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ (가법성 of χ^2 using MGF; for iid $Z \sim N(0, 1^2)$)</p>
	<p>* Contaminated normal distribution: 대부분 $Z \sim N(0, 1^2)$, 일부 outlier $\sim N(0, \sigma_c^2)$ (오염 비율: ε)</p> <p>1) $W = KZ + (1-K)\sigma_c Z$ for $K = \begin{cases} 1 & \text{확률 } 1-\varepsilon \\ 0 & \text{확률 } \varepsilon \end{cases}$ (Z, K는 독립)</p> <p>$F_W(w) = P(W \leq w) = P(W \leq w, I=1) + P(W \leq w, I=0) = P(Z \leq w)(1-\varepsilon) + P\left(Z \leq \frac{w}{\sigma_c}\right)\varepsilon = (1-\varepsilon)\Phi(w) + \varepsilon\Phi\left(\frac{w}{\sigma_c}\right)$</p> <p>① PDF: $f_W(w) = (1-\varepsilon)\phi(w) + \frac{\varepsilon}{\sigma_c}\phi\left(\frac{w}{\sigma_c}\right)$ ② $E(W) = 0, \text{Var}(W) = 1 + \varepsilon(\sigma_c^2 - 1)$</p> <p>2) $X = a + bW \quad (b > 0)$</p> <p>① PDF: $f_X(x) = (1-\varepsilon)\phi\left(\frac{x-a}{b}\right) + \frac{\varepsilon}{\sigma_c b}\phi\left(\frac{x-a}{b\sigma_c}\right)$ ② $E(W) = a, \text{Var}(W) = b^2[1 + \varepsilon(\sigma_c^2 - 1)]$</p>
	<p>* R codes 1) <code>dnorm(x,a,b): f(X=x)</code> 2) <code>pnorm(x,a,b): P(X≤x)</code> (평균 a, 표준편차 b)</p>

3-3. 주요 분포: 정규 분포

다변량 정규 분포	<p>* $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p)$ / $\mathbf{z} = (Z_1, \dots, Z_p)^T \in \mathbb{R}^p \sim \text{iid } N(0,1)$</p> <p>1) PDF: $f_{\mathbf{Z}}(\mathbf{z}) = \left(\frac{1}{2\pi}\right)^{p/2} \exp\left(-\frac{1}{2}\mathbf{z}^T\mathbf{z}\right)$ pf $f_{\mathbf{Z}}(\mathbf{z}) = \prod \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z_i^2\right) = \left(\frac{1}{2\pi}\right)^{p/2} \exp\left(-\frac{1}{2}\sum z_i^2\right) \quad \because \text{각 } Z_i \text{는 독립}$</p> <p>2) MGF: $M_{\mathbf{Z}}(\mathbf{t}) = \exp\left(\frac{1}{2}\mathbf{t}^T\mathbf{t}\right)$ ($\mathbf{t} \in \mathbb{R}^p$) pf $M_{\mathbf{Z}}(\mathbf{t}) = E\{\exp(\mathbf{t}^T\mathbf{Z})\} = E\{\prod \exp(t_i Z_i)\} = \prod E\{\exp(t_i Z_i)\} = \exp\left(\frac{1}{2}\sum t_i^2\right)$</p> <p>3) 기대값: $E[\mathbf{Z}] = \mathbf{0}$, $\text{Cov}[\mathbf{Z}] = \mathbf{I}_p$</p>	
	<p>* $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ / $\text{Cov}[\mathbf{X}] = \boldsymbol{\Sigma}$가 psd (양반정치)</p> <p>$\Leftrightarrow p$개의 <u>의존관계</u>인 정규분포 확률변수의 <u>결합 분포</u></p> <p>0) 변환: $\mathbf{X} = \boldsymbol{\Sigma}^{1/2} \mathbf{Z} + \boldsymbol{\mu}$ & $\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu})$</p> <p>1) PDF: $f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \boldsymbol{\Sigma} ^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T (\boldsymbol{\Sigma}^{-1})(\mathbf{x} - \boldsymbol{\mu})\right\}$</p> <p>2) MGF: $M_{\mathbf{X}}(\mathbf{t}) = \exp\left\{\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T (\boldsymbol{\Sigma}) \mathbf{t}\right\}$, ($\mathbf{t} \in \mathbb{R}^p$)</p> <p>3) 기대값: $E[\mathbf{X}] = \boldsymbol{\mu}$, $\text{Cov}[\mathbf{X}] = \boldsymbol{\Sigma}$</p>	<p><유도> $\boldsymbol{\Sigma}$가 psd & 대칭 \rightarrow EVD 가능</p> <p>$\boldsymbol{\Sigma} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda} \boldsymbol{\Gamma}$ ($\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$; $\lambda_1 \geq \dots \geq \lambda_p$)</p> <p>$\boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda}^{1/2} \boldsymbol{\Gamma}$, $\boldsymbol{\Sigma}^{-1/2} = \boldsymbol{\Gamma}^T \boldsymbol{\Lambda}^{-1/2} \boldsymbol{\Gamma}$ (if $\boldsymbol{\Sigma}$ is pd)</p> <p>$E[\mathbf{X}] = E[\boldsymbol{\Sigma}^{1/2} \mathbf{Z}] + \boldsymbol{\mu} = \boldsymbol{\Sigma}^{1/2} E[\mathbf{Z}] + \boldsymbol{\mu} = \boldsymbol{\mu}$</p> <p>$\text{Cov}[\mathbf{X}] = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = E[(\boldsymbol{\Sigma}^{1/2} \mathbf{Z})(\boldsymbol{\Sigma}^{1/2} \mathbf{Z})^T]$</p> <p>$= \left(\boldsymbol{\Sigma}^{1/2}\right) E(\mathbf{Z}\mathbf{Z}^T) \left(\boldsymbol{\Sigma}^{1/2}\right)^T = \boldsymbol{\Sigma} \quad * E[\mathbf{Z}\mathbf{Z}^T] = \text{Cov}(\mathbf{Z}) + \mathbf{0} = \mathbf{I}_p$</p>
	<p>1-1. Theorem * $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$; $\mathbf{A}: m \times p, \mathbf{b} \in \mathbb{R}^m$</p> <p>$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \rightarrow \mathbf{Y} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)$ (MGF로 증명)</p>	<p><MGF 유도></p> <p>$M_{\mathbf{X}}(\mathbf{t}) = \exp(\mathbf{t}^T \boldsymbol{\mu}) M_{\mathbf{Z}}\left\{\left(\boldsymbol{\Sigma}^{1/2}\right)^T \mathbf{t}\right\}$</p> <p>$= \exp(\mathbf{t}^T \boldsymbol{\mu}) \exp\left\{(1/2)[(\boldsymbol{\Sigma}^{1/2})^T \mathbf{t}]^T [(\boldsymbol{\Sigma}^{1/2})^T \mathbf{t}]\right\}$</p> <p>$= \exp(\mathbf{t}^T \boldsymbol{\mu}) \exp\left\{(1/2)\mathbf{t}^T (\boldsymbol{\Sigma}^{1/2})^T (\boldsymbol{\Sigma}^{1/2}) \mathbf{t}\right\} = e^{\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T (\boldsymbol{\Sigma}) \mathbf{t}}$</p>
	<p>1-2. Corollary (m개 변수에 대한 <u>주변 분포</u>)</p> <p>* $\mathbf{X} \rightarrow \mathbf{X}_1 \in \mathbb{R}^m, \mathbf{X}_2 \in \mathbb{R}^q$ ($p = m + q$) 분할</p> <p>- $\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}$</p> <p>- $\mathbf{A} = [\mathbf{I}_m \quad \mathbf{0}_{mq}] \rightarrow \mathbf{X}_1 = \mathbf{A}\mathbf{X}$</p> <p>$\rightarrow \mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \rightarrow \mathbf{X}_1 \sim N_m(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$</p> <p>($\because \mathbf{A}\boldsymbol{\mu} = \boldsymbol{\mu}_1, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = [\mathbf{I}_m \quad \mathbf{0}_{mq}] \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I}_m \\ \mathbf{0}_{mq} \end{bmatrix} = \boldsymbol{\Sigma}_{11}$)</p>	
	<p>2. 주변분포 독립성: $\mathbf{X}_1, \mathbf{X}_2$ 독립 $\Leftrightarrow \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21} = \mathbf{0}$</p> <p>pf) $M_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{t}_1, \mathbf{t}_2) = \exp\left\{\mathbf{t}_1^T \boldsymbol{\mu}_1 + \mathbf{t}_2^T \boldsymbol{\mu}_2 + \frac{1}{2} \begin{bmatrix} \mathbf{t}_1 & \mathbf{t}_2 \end{bmatrix} \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{t}_1 \\ \mathbf{t}_2 \end{bmatrix}\right\}$</p> <p>$M_{\mathbf{X}_1}(\mathbf{t}_1)M_{\mathbf{X}_2}(\mathbf{t}_2) = \exp\left\{\mathbf{t}_1^T \boldsymbol{\mu}_1 + \mathbf{t}_2^T \boldsymbol{\mu}_2 + \frac{1}{2}(\mathbf{t}_1^T \boldsymbol{\Sigma}_{11} \mathbf{t}_1 + \mathbf{t}_2^T \boldsymbol{\Sigma}_{22} \mathbf{t}_2)\right\} \therefore M_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{t}_1, \mathbf{t}_2) = M_{\mathbf{X}_1}(\mathbf{t}_1)M_{\mathbf{X}_2}(\mathbf{t}_2) \Leftrightarrow \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21} = \mathbf{0}$</p>	
	<p>3. 조건부 분포: $\mathbf{X}_1 \mathbf{X}_2 \sim N_m(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21})$ ($\boldsymbol{\Sigma}$는 양정치)</p> <p>pf) $\mathbf{W} = \mathbf{X}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \mathbf{X}_2 \rightarrow \begin{bmatrix} \mathbf{W} \\ \mathbf{X}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{I}_m & -\boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \\ \mathbf{0}_{qm} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}$ ($\mathbf{A} = \begin{bmatrix} \mathbf{I}_m & -\boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \\ \mathbf{0}_{qm} & \mathbf{I}_q \end{bmatrix}$)</p> <p>$\begin{bmatrix} \mathbf{W} \\ \mathbf{X}_2 \end{bmatrix} \sim N_p(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T); \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T = \begin{bmatrix} \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} & \mathbf{0}_{mq} \\ \mathbf{0}_{qm} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \rightarrow \mathbf{W}, \mathbf{X}_2 \text{ 독립}$</p> <p>$\mathbf{W} \mathbf{X}_2 = \mathbf{W} \sim N_m(\boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}) \rightarrow \mathbf{X}_1 \mathbf{X}_2 \sim N_m(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21})$</p>	
	<p>4. 카이 제곱: $W = (\mathbf{X} - \boldsymbol{\mu})^T (\boldsymbol{\Sigma}^{-1})(\mathbf{X} - \boldsymbol{\mu}) = \mathbf{Z}^T \mathbf{Z} \sim \chi^2(p)$ ($\boldsymbol{\Sigma}$는 양정치)</p> <p>pf) $W = \mathbf{Z}^T \mathbf{Z} = \sum_{i=1}^p Z_i^2 \sim \chi^2(p)$ * 가법성 of χ^2 using MGF; for iid $Z \sim N(0,1^2) \rightarrow \sum_{i=1}^p [(X_i - \mu_i)/\sigma_i]^2 \sim \chi^2(p)$</p>	
PCA 기본	<p>* Bivariate normal distribution (이변량 정규 분포)</p> <p>1) 기댓값: $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}, \sigma_{12} = \rho \sigma_1 \sigma_2$</p> <p>2) PDF: $f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right)\right]\right\}$</p> <p>3) 조건부 분포: $Y X \sim N[\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)]$</p>	
	<p>$\mathbf{Y} = \boldsymbol{\Gamma}\mathbf{X} = (\mathbf{PC}_1, \mathbf{PC}_2, \dots, \mathbf{PC}_p)^T \rightarrow \mathbf{PC}_1 = \mathbf{v}_1^T \mathbf{X}$ (\mathbf{v}_1: $\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}$의 λ_1 대응 고유벡터)</p> <p>pf) $\mathbf{Y} \sim N_p(\boldsymbol{\Gamma}\boldsymbol{\mu}, \boldsymbol{\Gamma}\boldsymbol{\Sigma}\boldsymbol{\Gamma}^T) = N_p(\boldsymbol{\Gamma}\boldsymbol{\mu}, \boldsymbol{\Lambda}) \rightarrow \text{TV}(\mathbf{X}) = \sum \sigma_i^2 = \text{tr}(\boldsymbol{\Sigma}) = \text{tr}(\boldsymbol{\Lambda}) = \sum \lambda_i = \text{TV}(\mathbf{Y})$</p> <p>어떤 $\ \mathbf{a}\ ^2 = 1, \mathbf{a} = \sum_{j=1}^p a_j \mathbf{v}_j$ $\Leftrightarrow \mathbf{a}^T \mathbf{v}_1 = a_1$</p> <p>$\rightarrow \text{Var}(\mathbf{a}^T \mathbf{X}) = \text{Cov}(\mathbf{a}^T \mathbf{X}) = \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a} = (\boldsymbol{\Gamma} \mathbf{a})^T \boldsymbol{\Lambda} (\boldsymbol{\Gamma} \mathbf{a}) = \sum_i \lambda_i (\mathbf{a}^T \mathbf{v}_i)^2 = \sum_i \lambda_i a_i^2 \leq \lambda_1 = \text{Var}(Y_1)$, 등호조건: $\mathbf{a} = \mathbf{v}_1$</p> <p>$\therefore Y_1 = \mathbf{v}_1^T \mathbf{X}$ (고유벡터 \mathbf{v}_1으로 총 데이터 \mathbf{X} 사영): 총분산 $\sum \lambda_i$ 중 최대 분산 λ_1 을 설명하는 \mathbf{PC}_1</p> <p>$\rightarrow \mathbf{X} = \boldsymbol{\Gamma}^T \mathbf{Y}$ 에서 $X_k = (v_{1k})\mathbf{PC}_1 + (v_{2k})\mathbf{PC}_2 + \dots$ (각 v_{ik}는 X_k의 \mathbf{PC}_i에 대한 PC score)</p>	

3-4. 주요 분포: t-분포, F-분포

t-분포	<p>Joint PDF: $h(w, v) = \left\{ \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}w^2\right) \right\} \left\{ \frac{1}{\Gamma\left(\frac{r}{2}\right) 2^{\frac{r}{2}}} v^{\frac{r}{2}-1} e^{-\frac{v}{2}} \right\} \quad w \in (-\infty, \infty), v \in (0, \infty); \text{서로 독립}$</p> <p>$T = \frac{W}{\sqrt{V/r}}$ 일때 $t = \frac{w}{\sqrt{v/r}}, u = v$로 변환 시 $J = \frac{\sqrt{u}}{\sqrt{r}} \rightarrow g(t, u)$ 에서 T의 marginal PDF $g_1(w) = \int_0^\infty g(t, u) du$</p> <p>$T = \frac{W}{\sqrt{V/r}} \leftarrow W \sim N(0, 1^2), V \sim \chi^2(r); \text{서로 독립}$</p> <p>1. PDF: $f(x) = \frac{\Gamma\left(\frac{r+1}{2}\right)}{\sqrt{r\pi} \Gamma\left(\frac{r}{2}\right)} \left(1 + \frac{x^2}{r}\right)^{-\frac{(r+1)}{2}}, \quad x \in \mathbb{R}$</p> <p>2. 기대값: $E(T) = 0 \ (r > 1), \quad \text{Var}(T) = \frac{r}{r-2} \ (r > 2)$ $* E(T^k) = E\left[W^k \left(\frac{V}{r}\right)^{-k/2}\right] = E(W^k) E\left[\left(\frac{V}{r}\right)^{-k/2}\right] = \frac{1}{r^{k/2}} E(W^k) E(V^{-k/2})$ $= E(W^k) \left(\frac{r}{2}\right)^{\frac{k}{2}} \frac{\Gamma\left(\frac{r-k}{2}\right)}{\Gamma\left(\frac{r}{2}\right)}, \quad r > k$ (Cauchy 분포: $df = 1$인 t 분포, $f(x) = \frac{1}{\pi(1+x^2)}$)</p> <p>3. Student's theorem *iid $X_i \sim N(\mu, \sigma^2) \ n \uparrow$ [직관: σ^2를 모르나, $X_i \sim N(\mu, \sigma^2) \rightarrow \bar{X}, S$로 μ 정확 추정]</p> <p>1) $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad 2) T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \leftarrow T = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right) / \sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}$</p> <p>pf) $V = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^n \left(\frac{(X_i - \bar{X}) + (\bar{X} - \mu)}{\sigma}\right)^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2 = \frac{(n-1)S^2}{\sigma^2} + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2$ $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n), \quad \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2 \sim \chi^2(1) \rightarrow \bar{X}, S^2 \text{ 독립; 양변 mgf 취하면 } (1-2t)^{-\frac{n-1}{2}} = E\left(\exp\left\{\frac{(n-1)S^2}{\sigma^2}\right\} t\right)$</p> <p>* R codes 1) dt(x,r): f(X=x) 2) pt(x,r): P(X≤x) (자유도 r) // 3) qt(0.975,r): 97.5%인 t값</p>	
F-분포	<p>$F = \frac{U/r_1}{V/r_2} \leftarrow U \sim \chi^2(r_1), V \sim \chi^2(r_2); \text{서로 독립}$</p> <p>1. PDF: $f(x) = \frac{1}{B\left(\frac{r_1}{2}, \frac{r_2}{2}\right)} \left(\frac{r_1}{r_2}\right)^{\frac{r_1}{2}} \left(1 + \frac{r_1}{r_2}x\right)^{-\frac{r_1+r_2}{2}} x^{\frac{r_1}{2}-1} \quad 0 < x < \infty$</p> <p>2. 기대값: $E(F) = \frac{r_2}{r_2-2} \ (r_2 > 2)$ $* E(F^k) = E\left[\left(\frac{U/r_1}{V/r_2}\right)^k\right] = \left(\frac{r_2}{r_1}\right)^k E(U^k) E(V^{-k})$ $= \left(\frac{r_2}{r_1}\right)^k \frac{\Gamma\left(\frac{r_1+k}{2}\right) \Gamma\left(\frac{r_2-k}{2}\right)}{\Gamma\left(\frac{r_1}{2}\right) \Gamma\left(\frac{r_2}{2}\right)} \quad (r_2 > 2k)$</p> <p>* R codes 1) df(x,a,b): f(X=x) 2) pf(x,a,b): P(X≤x) (자유도 a,b) // 3) qf(0.975,a,b): 97.5%인 F값</p>	

3-5. 혼합 분포

혼합 분포	<p>1. 혼합분포: $f(x) = \sum_{i=1}^k p_i f_i(x)$ (각각 받침 S_i, 평균 μ_i, 분산 $\sigma_i^2, \sum_{j=1}^k p_j = 1$)</p> <p>1) $E(X) = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} x f_i(x) dx = \sum_{i=1}^k p_i \mu_i = \bar{\mu}$</p> <p>2) $\text{Var}(X) = \sum_{i=1}^k p_i \sigma_i^2 + \sum_{i=1}^k p_i (\mu_i - \bar{\mu})^2$ $* \text{Var}(X) = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} (x - \bar{\mu})^2 f_i(x) dx = \sum_{i=1}^k p_i \int_{-\infty}^{\infty} (x - \mu_i)^2 f_i(x) dx + \sum_{i=1}^k p_i (\mu_i - \bar{\mu})^2 \int_{-\infty}^{\infty} f_i(x) dx$</p> <p>2. 응용: 유한 개로 제한할 필요 X</p> <p>1) 감마(θ, α, β)+푸아송(x, θ) \rightarrow 음이항 분포</p> <p>$p(x) = \int_0^\infty \left[\frac{1}{\Gamma(\alpha)\beta^\alpha} \theta^{\alpha-1} e^{-\theta/\beta} \right] \left[\frac{e^{-\theta} \theta^x}{x!} \right] d\theta = \frac{1}{\Gamma(\alpha)\beta^\alpha x!} \int_0^\infty \theta^{\alpha+x-1} e^{-\theta(a+\beta)/\beta} d\theta = \frac{\Gamma(\alpha+x)}{\Gamma(\alpha)x!} \frac{\beta^x}{(1+\beta)^{\alpha+x}}$ $\rightarrow p(x) = \frac{(r+x-1)!}{(r-1)!} \frac{p^r (1-p)^x}{x!}, \quad \alpha = r \in \mathbb{Z}^+, \quad \beta = \frac{1-p}{p}$</p> <p>2) 베이지안 추론: $h(x) = \int_{\theta} g(\theta) f(x \theta) d\theta; \quad g(\theta): \text{Conjugate prior}, \quad h(x): \text{무조건부}$</p> <p>① $X \theta \sim N(0, 1/\theta), \theta \sim \Gamma(r/2, 2/r) \rightarrow X \sim t(r)$ ② 이항분포 (p모름) \rightarrow 베타분포 $\beta(p)$로 추출 $\int_0^1 p(x p) g(p) dp$</p>	
-------	--	--

4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

표본 / 통계량	* 표본 \rightarrow 1) 분포 $f(x), p(x)$ 의 추론 // 2) θ 추론 $\leftarrow f(x), p(x)$ 는 알고 있음 (X_i : 확률변수, x_i : 실현값)		
	1. 확률 표본 (Random sample): iid $[X_1, \dots, X_n]$		
	2. 통계량 (Statistic): $T = T(X_1, \dots, X_n)$ (표본에 대한 함수) $\rightarrow \theta \in \Omega$ 에 대한 추정량이면 T : 점추정량 (point estimator), 실현값 t : 점추정값 (point estimate)		
	3. 불편추정량 (Unbiased estimator): $E(T) = \theta$ [$E(\bar{X}) = \mu$, $E(S^2) = \sigma^2$]		
	4. Maximum likelihood estimator (mle) 1) 가능도 함수: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ \leftarrow MLE: $\hat{\theta} = \text{Argmax}[L(\theta)]$ 2) 로그우도 함수: $l(\theta) = \sum_{i=1}^n \ln f(x_i, \theta)$ \leftarrow MLE: $\hat{\theta} = \text{Argmax}[l(\theta)] \leftarrow \partial l / \partial \theta = 0$		
지수	$l(\beta) = \sum_{i=1}^n \ln \frac{1}{\beta} e^{-\frac{x_i}{\beta}} = -\frac{1}{\beta} \sum x_i - n \ln \beta = -n \left(\frac{1}{\beta} \bar{X} + \ln \beta \right) \rightarrow \frac{\partial l}{\partial \beta} = n \left(\frac{\bar{X}}{\beta^2} - \frac{1}{\beta} \right) \rightarrow \hat{\beta} = \bar{X}$ (also 불편)		
	$l(p) = \sum_{i=1}^n \ln p^{x_i} (1-p)^{1-x_i} = n \bar{X} \ln p + (n - n \bar{X}) \ln(1-p) \rightarrow \frac{\partial l}{\partial p} = n \left(\frac{\bar{X}}{p} - \frac{1 - \bar{X}}{1-p} \right) \rightarrow \hat{p} = \bar{X}$ (also 불편)		
	$l(\mu, \sigma) = -\frac{n}{2} \ln 2\pi - n \ln \sigma - \frac{1}{2} \sum \left(\frac{x_i - \mu}{\sigma} \right)^2 \rightarrow \nabla l(\mu, \sigma) = \left[\frac{1}{\sigma} \sum \left(\frac{x_i - \mu}{\sigma} \right), -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum (x_i - \mu)^2 \right]^T$ $\rightarrow \hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$		
CLT	1) Pivot 확률변수: (추정량-모수)/표준오차 2) 중심극한정리: $Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0,1) \leftrightarrow$ 근사적으로 $N(0,1)$ 에 수렴 cf) $X \sim N(\mu, \sigma^2)$ 이면 정확히 정규분포		
신뢰 구간	*신뢰구간: 모수 θ 가 추정량 $\hat{\theta}$ 에서 얼마나 벗어났는가? 1. 신뢰구간: $1 - \alpha = P_\theta[\theta \in (\hat{\theta}_L, \hat{\theta}_U)] \rightarrow 100(1-\alpha)\%$ 신뢰구간 (같은 신뢰계수 \rightarrow 구간 길이 최소화) *해석: 모수 θ 가 추정량 $(\hat{\theta}_L, \hat{\theta}_U)$ 구간에 있는 사건 $\sim B(1, 1 - \alpha)$ (95% CI: θ 가 $(\hat{\theta}_L, \hat{\theta}_U)$ 에 평균 19회/20회)		
	2. 평균 신뢰 구간 ($z_{\alpha/2}$: 상위 $\alpha/2$ 에서 z 값) $\leftrightarrow (z_{\alpha/2} = \xi_{1-\alpha/2} \leftrightarrow F(z_{\alpha/2}) = F(\xi_{1-\alpha/2}) = 1 - \alpha/2)$		
	상황	가정	Pivot statistic
	대표본 (근사;CLT)	평균 μ 분산 σ^2	$Z = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0,1)$ 중심극한정리
	t-구간 정규성 (정확)	$X_i \sim N(\mu, \sigma^2)$	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} (df = n - 1)$
신뢰 구간	3. 평균 차이 $(\bar{X} - \bar{Y})$ 신뢰 구간 * $E(\bar{X} - \bar{Y}) = \mu_1 - \mu_2$, $\text{Var}(\bar{X} - \bar{Y}) = (\sigma_1^2/n_1) + (\sigma_2^2/n_2)$		
	상황	가정	Pivot statistic
	대표본 (근사;CLT)	평균 $\mu_1 - \mu_2$ 분산 $(\sigma_1^2/n_1) + (\sigma_2^2/n_2)$	$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{(\sigma_1^2/n_1) + (\sigma_2^2/n_2)}} \sim N(0,1)$
	t-통계량 정규성 (등분산)	$X_i \sim N(\mu_1, \sigma^2)$ $Y_i \sim N(\mu_2, \sigma^2)$	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{(1/n_1) + (1/n_2)}} (df = n_1 + n_2 - 2)$ $S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{(n_1 - 1) + (n_2 - 1)}$
	t-통계량 정규성 (이분산)	$X_i \sim N(\mu_1, \sigma_1^2)$ $Y_i \sim N(\mu_2, \sigma_2^2)$	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{(\sigma_1^2/n_1) + (\sigma_2^2/n_2)}} (df = \text{Welch's, } df < \text{round}(df))$

4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

4. 비율 차이 (극한 표준정규분포; CLT)

1) 가정: $X \sim b(1, p_1), Y \sim b(1, p_2) \rightarrow \hat{p}_1 = \bar{X}, \hat{p}_2 = \bar{Y} \quad \therefore E(\hat{p}_1) = p_1, \text{Var}(\hat{p}_1) = p_1(1 - p_1)/n_1$

상황	가정	Pivot statistic
대표본 (근사; CLT)	평균 $p_1 - p_2$ 분산 $\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}$	$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \sim N(0,1)$

5. 이산형 모수

1) $F_T(T; \theta)$: 통계량 T 의 cdf; θ 에 대해 단조 감소 \rightarrow 신뢰 구간: $F_T(T_{n-1}; \underline{\theta}) = 1 - \alpha_2, F_T(T_n; \bar{\theta}) = \alpha_1$

2) **Bisection algorithm**: 순감소 $g(x) = d \in g([a, b]) \rightarrow$ 1) if $g\{(a+b)/2\} > d \rightarrow$ 구간 $[(a+b)/2, b]$ 재설정
 \rightarrow 2) if $g\{(a+b)/2\} < d \rightarrow$ 구간 $[a, (a+b)/2]$ 재설정

상황	조건	유도
Binomial	$X \sim b(1, p)$ $n = 30, \bar{x} = 0.60$ $T = n\bar{X} \sim b(30, p)$ ($T_{n-1} = 17, T_n = 18$)	① 하한: $\text{pbinom}(17, 30, 0.4) = 0.9787, \text{pbinom}(17, 30, 0.45) = 0.9286$ $\rightarrow \text{pbinom}(17, 30, \mathbf{0.434}) \approx 0.95$ ② 상한: $\text{pbinom}(18, 30, 0.7) = 0.1593, \text{pbinom}(18, 30, 0.8) = 0.0094$ $\rightarrow \text{pbinom}(18, 30, \mathbf{0.747}) \approx 0.05$ $\therefore p$ 의 90% CI: [0.434, 0.747]
Poisson	$X \sim \text{Poi}(\mu)$ $n = 25, \bar{x} = 5$ $T = n\bar{X} \sim \text{Poi}(25\mu)$ ($T_{n-1} = 124, T_n = 125$)	① 하한: $\text{ppois}(124, 25 \times 4) = 0.9912, \text{ppois}(124, 25 \times 4.4) = 0.9145$ $\rightarrow \text{ppois}(124, 25 \times \mathbf{4.287}) \approx 0.95$ ② 상한: $\text{ppois}(125, 25 \times 5.5) = 0.1330, \text{ppois}(125, 25 \times 6) = 0.0204$ $\rightarrow \text{ppois}(125, 25 \times \mathbf{5.8}) \approx 0.05$ $\therefore \mu$ 의 90% CI: [4.287, 5.8]

*정의: $(Y_1 < \dots < Y_n) \leftarrow [X_1, \dots, X_n]$ 재배열 *강점: 분포에 종속되지 않음.

1. PDF: $g(y_1, \dots, y_n) = \frac{n!}{n!} f(y_1) \dots f(y_n)$ (on $a < y_1 < \dots < y_n < b$) pf) $g(y_1, \dots, y_n) = \sum_{i=1}^n |J_i| f(y_1) \dots f(y_n)$

2. Marginal PDF 1) $g_k(y_k) = \frac{n!}{(k-1)!(n-k)!(1)!} [F(y_k)]^{k-1} [1 - F(y_k)]^{n-k} f(y_k)$

pf) $g_k(y_k) = \int_a^{y_k} \dots \int_a^{y_2} \int_{y_k}^b \dots \int_{y_{n-1}}^b n! f(y_1) \dots f(y_n) dy_n \dots dy_{k+1} dy_1 \dots dy_{k-1} \quad (y_n \rightarrow y_{k+1}; y_1 \rightarrow y_{k-1})$

2) $g_{ij}(y_i, y_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!(1)!(1)!} [F(y_i)]^{i-1} [F(y_j) - F(y_i)]^{j-i-1} [1 - F(y_j)]^{n-j} f(y_i) f(y_j)$

3. Quantile (분위수): cdf $F(\xi_p) = p \leftrightarrow \xi_p = F^{-1}(p), \quad k = \text{floor}[p(n+1)]$

1) $F(Y_k)$ 는 $\frac{k}{n+1}$ 의 불편추정량: $E(F(Y_k)) = \int_a^b F(y_k) g_k(y_k) dy_k = \int_0^1 \frac{n!}{(k-1)!(n-k)!} z^k (1-z)^{n-k} dz = \frac{k}{n+1}$

2) Quartile: 1분위수 ($Q_1 = Y_{[0.25(n+1)]}$) \Leftrightarrow 중위수 ($Q_2 = Y_{[0.5(n+1)]}$) \Leftrightarrow 3분위수 ($Q_3 = Y_{[0.75(n+1)]}$)

*중위수: 홀수 \rightarrow 중간값 $Y_{(n+1)/2}$ / 짝수 $\rightarrow (Y_{(n/2)} + Y_{(n/2)+1})/2$

\rightarrow Box plot: $h = 1.5(Q_3 - Q_1), LF = Q_1 - h, UF = Q_3 + h$ (LF, UF 바깥: 이상값; 정규분포상 $P \leq 0.007$)

3) Q-Q plot: 표본의 순서통계량 $(Y_1, Y_2, \dots, Y_{50}) \Leftrightarrow$ 이론적 분위수 $(Z_{0.02}, Z_{0.04}, \dots, Z_{1.00}) \leftarrow$ any 분포

4) 신뢰구간: $1 - \alpha = P(Y_i < \xi_p < Y_j) = \sum_{w=i}^{j-1} \binom{n}{w} p^w (1-p)^{n-w} \leftarrow p = F(\xi_p) \quad (\text{중위수: } p = 1/2)$

4. 통계적 추론 – MLE / 신뢰구간 / 가설검정

- 1) 가설 정의: $H_0: \theta \in \omega_0$ (Null) vs. $H_1: \theta \in \omega_1$ (alternative) $\leftarrow X \sim f(x; \theta)$ 에 대해 $\theta \in \Omega = (\omega_0 \cup \omega_1)$, 분할
- 2) 가설 검정: 표본 $(X_1, \dots, X_n) \in C \rightarrow H_1$ 채택 (기각역 $C \subset D = \text{span}\{(X_1, \dots, X_n)\}$)
표본 $(X_1, \dots, X_n) \notin C \rightarrow H_0$ 유지
- 3) 유의 수준: $\alpha = \max_{\theta \in \omega_0} P_{\theta}[(X_1, \dots, X_n) \in C]$ (복합귀무가설에 대해 모든 null 모수 \rightarrow 기각역에 속할 확률 최대)
* 1종 오류: H_0 참, but 기각 $\rightarrow H_1$ 채택 (=FP) \therefore 유의수준(α): 1종 오류 범할 최대 확률
- 4) 검정력: $\gamma(\theta) = P_{\theta}[(X_1, \dots, X_n) \in C], \theta \in \omega_1 \rightarrow$ 유의 수준과 다르게 대립가설 모수에 따라 달라짐
① 2종 오류: H_0 거짓, but 유지 $\rightarrow H_0$ 유지 (=FN) $\therefore \beta$: 2종 오류 범할 확률 (under given $\theta \in \omega_1$)
② 검정력: H_0 거짓 \rightarrow 알맞게 H_1 채택 (TP)
- 5) P-값: 1) **Upper tail**: $P\text{-값} = P_{H_0}(X \geq x_{obs}) = 1 - F_{H_0}(x_{obs})$
2) **Lower tail**: $P\text{-값} = P_{H_0}(X \leq x_{obs}) = F_{H_0}(x_{obs})$
3) **2-sided**: $P\text{-값} = 2 \times P_{H_0}(X \geq |x_{obs}|) = 2[1 - F_{H_0}(|x_{obs}|)]$ ($X=0$ 좌우 대칭)
 $\rightarrow X = F^{-1}(U)$ (단조 증가) 정리의 역에 의해 $P\text{-값} \sim \text{unif}(0,1)$ under 귀무가설 H_0

예시	분포	가설	유도
단일 이항 단측	$X_i \sim B(1, p)$	$H_0: p = p_0$ $H_1: p < p_0$	* 표본통계량: $S = \sum_{i=1}^n X_i \sim B(n, p)$ 1) 기각역 설정: 귀무가설 하에서 $S \sim B(n, p_0) \rightarrow \alpha = P_{p_0}[S \leq k]$ $\rightarrow 0.11 = P_{p_0}[S \leq 11] \quad (n = 20, p_0 = 0.7)$ 2) 검정력 함수: $\gamma(p) = P_p[S \leq 11]$ (단조 감소 of p) $\therefore H_0: p \geq p_0$ 로 확장 $\leftarrow \max_{p \geq p_0} P_p[S \leq k] = P_{p_0}[S \leq k]$ (단조성)
	대표본에서 $\frac{\hat{p} - p_0}{\sqrt{\hat{p}(1-\hat{p})/n}} \approx \frac{\hat{p} - p_0}{\sqrt{p(1-p)/n}} \xrightarrow{D} N(0, 1)$		
대표본			* 표본통계량: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \approx \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$
대표본 단측 (Upper)	$X_i \sim$ 미지 분포 1) 평균: μ 2) 분산: σ^2	$H_0: \mu = \mu_0$ $H_1: \mu > \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq z_{\alpha} \right] \approx 1 - \Phi(z_{\alpha})$ 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq z_{\alpha} \right] = P_{\mu} \left[\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{\alpha} \right]$ $\approx 1 - \Phi \left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_{\alpha} \right) = \Phi \left(\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha} \right)$ (단조 증가 of μ) * Power 증가: $n \uparrow$, 효과크기 $(\mu - \mu_0) \uparrow$, $\alpha \uparrow$ & $\sigma \downarrow$
대표본 단측 (Lower)		$H_0: \mu = \mu_0$ $H_1: \mu < \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \leq -z_{\alpha} \right] \approx \Phi(-z_{\alpha})$ 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \leq -z_{\alpha} \right] = P_{\mu} \left[\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} - z_{\alpha} \right]$ $\approx \Phi \left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} - z_{\alpha} \right) = \Phi \left(-\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha} \right)$ (단조 감소 of μ) * Power 증가: $n \uparrow$, 효과크기 $(\mu - \mu_0) \uparrow$, $\alpha \uparrow$ & $\sigma \downarrow$
대표본 양측		$H_0: \mu = \mu_0$ $H_1: \mu \neq \mu_0$	1) 기각역 설정: $\alpha = P_{\mu_0} \left[\left \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \right \geq z_{\alpha/2} \right] \Leftarrow$ (양측 동일 배분) 2) 검정력 함수: $\gamma(\mu) = P_{\mu} \left[\left \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right \geq z_{\alpha/2} \right]$ $\approx \Phi \left(\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha/2} \right) + \Phi \left(-\frac{\sqrt{n}(\mu - \mu_0)}{\sigma} - z_{\alpha/2} \right)$ (U자 함수 of μ) $\rightarrow (\mu_0$ 에서 최소값)
t-검정 정규성	$X_i \sim N(\mu, \sigma^2)$	$H_0: \mu = \mu_0$ $H_1: \mu \neq \mu_0$	* 표본통계량: $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ * t-분포는 $N(0,1)$ 보다 누워 있음 \rightarrow "보수적" // 정규성 하 "정확"
2-표본 t-검정	$X_i \sim N(\mu_1, \sigma^2)$ $Y_i \sim N(\mu_2, \sigma^2)$ (정규, 등분산)	$H_0: \mu_1 = \mu_2$ $H_1: \mu_1 \neq \mu_2$	* 표본통계량: $T = \frac{(\bar{X} - \bar{Y}) - 0}{S_p \sqrt{(1/n_1) + (1/n_2)}} \sim t(n_1 + n_2 - 2)$ * $ T \geq t_{0.025, n_1+n_2-2}$ 이면 H_0 기각

가설
검정

4. 통계적 추론 – MLE / 신뢰구간 / 가설검정

Pearson χ^2 검정	자유도: n(확률표본)-n(미지수 or 제약)	
	2 cells	<p>1. 상황: $X_1 \sim b(n, p_1)$, $X_2 = n - X_1$, $p_2 = 1 - p_1 \Rightarrow Y = \frac{X_1 - np_1}{\sqrt{np_1(1-p_1)}} \xrightarrow{D} N(0,1)$; $Q_1 = Y^2 \xrightarrow{D} \chi^2(1)$</p> <p>2. 검정통계량: $Q_1 = \frac{(X_1 - np_1)^2}{np_1(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_1 - np_1)^2}{n(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} \xrightarrow{D} \chi^2(1)$</p>
	k cells	<p>1. 상황: k항; n회 다항분포 ($p_k = 1 - \sum_{i=1}^{k-1} p_i$ & $x_k = n - \sum_{i=1}^{k-1} x_i$)</p> <p>2. 검정통계량: $Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i} \xrightarrow{D} \chi^2(k-1) \quad \Leftarrow (k-1)\text{개 알면 나머지 1개 앞}$</p>
	적합도 검정	<p>1) 귀무가설: $H_0: p_1 = p_{1,0}, p_2 = p_{2,0}, \dots, p_k = p_{k,0}$</p> <p>2) 검정통계량: $Q_{k-1} = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} = \sum_{i=1}^k \frac{(X_i - np_{i,0})^2}{np_{i,0}} \xrightarrow{D} \chi^2(k-1)$ (귀무가설 하)</p>
	최소 χ^2 추정량	<p><예시> 정규분포 모수 추정 $N(\mu, \sigma^2)$</p> <p>1) 상황: 실수구간 \rightarrow k등분 (A_1, \dots, A_k); $p_i = \int_{A_i} \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}(y-\mu)^2/\sigma^2\right] dy$</p> <p>2) 실제 A_i의 도수인 $X_i \rightarrow Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i} \xrightarrow{D} \chi^2(k-3)$ 최소화하는 $\hat{\mu}, \hat{\sigma}^2$</p>
r x c cells	동질성 검정	<p>1) 상황: 2개의 k항 다항분포 *각 모수: $(n_1, p_{11}, p_{21}, \dots, p_{k1}), (n_2, p_{12}, p_{22}, \dots, p_{k2})$</p> <p>$\Rightarrow \sum_{j=1}^2 \sum_{i=1}^k \frac{(X_{ij} - n_j p_{ij})^2}{n_j p_{ij}} \xrightarrow{D} [\chi^2(k-1) + \chi^2(k-1)] = \chi^2(2k-2)$</p> <p>2) 귀무가설: $H_0: p_{11} = p_{12}, p_{21} = p_{22}, \dots, p_{k1} = p_{k2}$ (둘은 구간 별 비율이 동일)</p> <p>$\Rightarrow p_{m1} = p_{m2}$의 MLE: $\frac{X_{m1} + X_{m2}}{n_{m1} + n_{m2}}$ (총 k-1개 점추정값 필요)</p> <p>3) 검정통계량: $\sum_{j=1}^2 \sum_{i=1}^k \frac{[X_{ij} - n_j \frac{(X_{i1} + X_{i2})}{n_{i1} + n_{i2}}]^2}{n_j \frac{(X_{i1} + X_{i2})}{n_{i1} + n_{i2}}} \xrightarrow{D} \chi^2(k-1)$ (귀무가설 하)</p>
	독립성 검정	<p>1) 상황: 확률실험 n회 결과 \rightarrow 가로 (A) a항 / 세로 (B) b항 두 종류 범주로 구분</p> <p>$\Rightarrow p_{ij} = P(A_i \cap B_j)$, X_{ij}는 $A_i \cap B_j$ 도수</p> <p>$\Rightarrow Q_{ab-1} = \sum_{j=1}^b \sum_{i=1}^a \frac{(X_{ij} - np_{ij})^2}{np_{ij}} \xrightarrow{D} \chi^2(ab-1)$</p> <p>2) 귀무가설: $H_0: P(A_i \cap B_j) = P(A_i)P(B_j)$ for all (i, j) (속성 A, B는 독립)</p> <p>$\Rightarrow p_{i*} = P(A_i)$의 MLE: $\hat{p}_{i*} = \frac{X_{i*}}{n} = \frac{\sum_{j=1}^b X_{ij}}{n}$ [총 (a-1) + (b-1)개 점추정값 필요]</p> <p>3) 검정통계량: $\sum_{j=1}^b \sum_{i=1}^a \frac{[X_{ij} - n \frac{(X_{i*})}{n} \frac{(X_{*j})}{n}]^2}{n \frac{(X_{i*})}{n} \frac{(X_{*j})}{n}} \xrightarrow{D} \chi^2[(a-1)(b-1)]$ (귀무가설 하)</p>
비중심 분포	비중심 χ^2	<p>$Y = \sum_{i=1}^n \left(\frac{X_i^2}{\sigma^2}\right), \quad X_i \sim N(\mu_i, \sigma^2) \quad * \mu_i = 0 \text{이면 } Y \sim \chi^2(n)$</p> <p>$M(t) = E[\exp(tX_i^2/\sigma^2)] = \frac{1}{(1-2t)^{n/2}} \exp\left[\frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)}\right] = \frac{1}{(1-2t)^{n/2}} \exp\left[\frac{t}{1-2t} \theta\right] \quad \left(t < \frac{1}{2}\right)$</p> <p>$Y = \sum_{i=1}^n \left(\frac{X_i^2}{\sigma^2}\right) \sim \chi^2(n, \theta) \quad \left(\theta = \frac{\sum_{i=1}^n \mu_i^2}{\sigma^2}\right) \quad p.f.) \text{ MGF 적분 활용} \rightarrow \text{치환 하여 정규분포 PDF 꼴로 정리}$</p>
		* R codes 1) dchisq(x,r,a): f(X=x) 2) pchisq(x,r,a): P(X≤x)
	비중심 F	<p>$U \sim \chi^2(n_1, \theta) \text{ \& } V \sim \chi^2(n_2) \quad * U, V \text{는 독립}$</p> <p>$Y = \frac{U/n_1}{V/n_2} \sim F(n_1, n_2, \theta)$</p>

4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

* 몬테카를로 생성: 특정 "Known" 표본/분포 → 관측값 생성 (Resampling, Bayesian 등에서 중요)

1. 균등분포 (Uniform distribution): $\text{unif}(a, b)$; $\text{pdf} = 1/(b-a)$ ← R codes: `runif(횟수)`

unif(0,1)⇔CDF “관측치 생성”	지수	$F(x) = 1 - e^{-x/\beta}, \quad (x > 0)$ $\therefore X = F^{-1}(U) = -\beta \ln(1 - U)$ 는 지수분포 생성	
	푸아송	$m = \lambda w \rightarrow T_i \sim \exp(1/\lambda)$ 에 대해 $[X = k] \Leftrightarrow \sum_{i=1}^k T_i \leq w \ \& \ \sum_{i=1}^{k+1} T_i > w$ * 구간 w 동안 난수로 T_i 생성 \rightarrow 횟수 카운트 (초기 $X = 0, T = 0$) 1) $\Delta T = -(1/\lambda) \ln(1 - U)$ 2) $T \leftarrow T + \Delta T$ 3) if $T \leq w$: $X \leftarrow X + 1$ elif $T > w$: return X	
		정규 분포	<Box & Muller (1958)> \rightarrow 일반화: Marsaglia & Bray (1964) $X_1 = (-2 \ln Y_1)^{1/2} \cos(2\pi Y_2); X_2 = (-2 \ln Y_1)^{1/2} \sin(2\pi Y_2) \leftarrow Y_1, Y_2 \sim \text{unif}(0,1)$ $f(X_1, X_2) = J g(Y_1, Y_2) = \frac{1}{2\pi} \exp \left[-\frac{1}{2}(x_1^2 + x_2^2) \right]$
	채택-기각 (A-R) 알고리즘 (어려운 CDF)	$X = F^{-1}(U)$ 를 closed form 계산 불가. $\Leftarrow g(x)$ 이용: ① Easy ② $f(x)$ 유사 ③ $\frac{f(x)}{g(x)} \leq k$ (유계) ① $Y \sim g(y)$ & U 생성 ② $U \leq \frac{f(Y)}{kg(Y)} \leq 1$ 이면 $X = Y$, 아니면 ①로 돌아가 재 생성 \Rightarrow 조금 더 넓은 $kg(x)$ 로 근사 ($f(x) = cf_1(x)$ 와 $g(x) = dg_1(x)$ 적당히 상수배 하여 k 무시 가능)	
감마 CDF $\Gamma(\alpha, \beta)$		$Y_i \sim \Gamma(1,1) \rightarrow X = \sum_{i=1}^{\alpha} Y_i \sim \Gamma(\alpha, 1)$ (α 정수: CDF 생성 쉬움) $X \sim \Gamma(\alpha, 1) \rightarrow \beta X \sim \Gamma(\alpha, \beta)$ (α 실수 \rightarrow 문제!) ① $X \sim \Gamma(\alpha, 1)$ & $Y \sim \Gamma([\alpha], 1/b)$ ② $\frac{f(x)}{g(x)} = b^{-[\alpha]} x^{\alpha - [\alpha]} e^{-(1-b)x} \leq b^{-[\alpha]} \left\{ \frac{\alpha - [\alpha]}{(1-b)e} \right\}^{\alpha - [\alpha]}$ (by x 로 미분) ③ 위 식을 b 로 미분 $\Rightarrow \frac{f(x)}{g(x)} \leq ([\alpha]/\alpha)^{-[\alpha]} \left\{ \frac{\alpha - [\alpha]}{(1 - [\alpha]/\alpha)e} \right\}^{\alpha - [\alpha]} = M$	
		정규 CDF $N(0, 1)$	① Y~Cauchy (역 CDF 알려짐) $\rightarrow X \sim N(0,1)$ ② $\frac{\phi(x)}{g(x)} = \frac{(2\pi)^{-1/2} \exp\{-x^2/2\}}{\{\pi(1+x^2)\}^{-1}} \Rightarrow \frac{\phi_1(x)}{g_1(x)} = (1+x^2) \exp\{-x^2/2\} \leq 2e^{-1/2} = M$
Monte Carlo t-검정 (오염된 정규)	$W \sim N(0,1^2)$ & $W \sim N(0, \sigma_c^2)$ ($\epsilon: 0.25, \sigma_c = 25$) $\leftarrow W = Z$ or $\sigma_c Z$; $E(W) = 0$		
	* 가설: $H_0: \mu = 0, H_1: \mu > 0$ 1) $n = 20$, 2) $t_{0.05, 19} = 1.729$	* 추정 알고리즘 (N : 시뮬레이션 수) 1) $n = 20$ 표본 생성 $\Leftarrow X$ (오염 정규; μ 모름) 분포 2) $T = (\bar{X} - \mu)/(S/\sqrt{n})$ 계산 \rightarrow 1), 2) N 번 반복 3) 유의수준 실험적 추정량: $\hat{\alpha} = I/N$ ($I: T > t_{0.05, 10}$ 도수) SE = $\sqrt{\hat{\alpha}(1 - \hat{\alpha})/N}$ 예시) $\hat{\alpha} = 0.0412 \pm 0.0039$	
Monte Carlo 적분	적분가능한 $g(x)$ 의 closed form 역도함수 (\approx 부정적분) 존재 $X \rightarrow$ 수치적 적분 $\int_a^b g(x) dx = (b-a) \int_a^b g(x) \left(\frac{1}{b-a} \right) dx = (b-a)E[g(X)] \Leftarrow X \sim \text{unif}(a, b)$ $\therefore \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n (b-a)g(X_i)$ 는 정적분의 unbiased estimator $\Leftarrow X_i \sim \text{unif}(a, b)$		

4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

비교

- 1) 중심극한정리: 표본 통계량 ($\hat{\theta}$) 의 pivotal statistic이 극한 정규분포따름 \rightarrow 모수 θ 추정
- 2) 몬테카를로 기법: X 의 **known 분포 (CDF)** \rightarrow 균등분포 난수추출기로 관측값 $X = F^{-1}(U)$ 생성
- 3) 부트스트랩: X 의 **unknown 분포** \rightarrow 표본 (X_1, \dots, X_n)의 EDF (\hat{F}_n) \rightarrow 무작위 추출로 X_i^* 생성
 $\hat{\theta}^*$ 의 분포 $\rightarrow \hat{\theta}$ 의 신뢰구간 추정 $\rightarrow \theta$ 의 근사적 신뢰구간

일반적인 통계적 추론에서는 estimator \rightarrow parameter를 추정함.

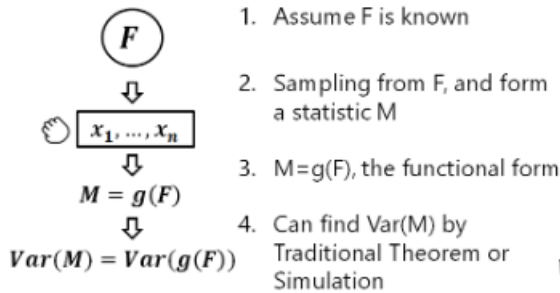
Standard error는 estimator의 자체적인 변동성 (표준편차) (e.g. $SE(\bar{X}) = \sqrt{Var(\bar{X})} = \sigma/\sqrt{n}$)

Estimated SE는 SE에 unknown parameter가 들어가 있을 때, 다른 estimator를 이용 (S/\sqrt{n})

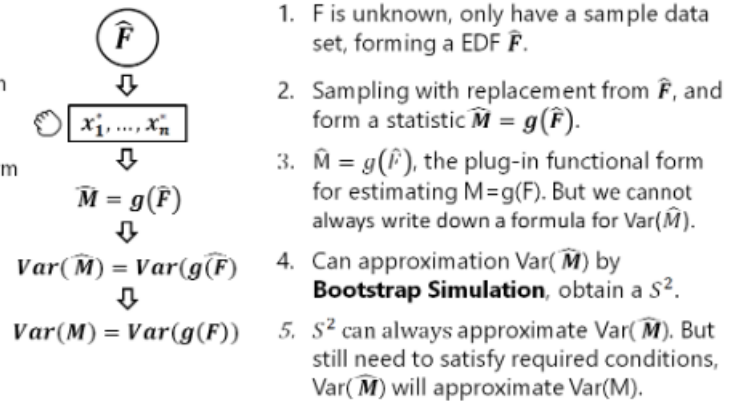
*문제: ① 일반적인 확률변수 Y에 대해 분포 (PDF, CDF)를 알기 어렵고

② 통계량 $g(Y)$ 의 S.E.를 σ/\sqrt{n} 처럼 정확한 수식으로 알아낼 수 있는 경우는 많지 않음.

In Real World



Bootstrap World



$$EDF \hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x) \Leftrightarrow (x \text{보다 작은 표본내 실현값 수}) / n \Leftrightarrow PMF \text{는 } \frac{1}{n} \text{ (for every } x_i)$$

원리

Statistical functional (통계적 범함수): 모수가 [분포함수]의 함수로 표현됨. (평균, 분산, 중위수, 백분위수, etc)

$$\text{e.g. } E(X) = \int x f dx = \int x dF, \quad Var(X) = \int x^2 dF - \left(\int x dF \right)^2$$

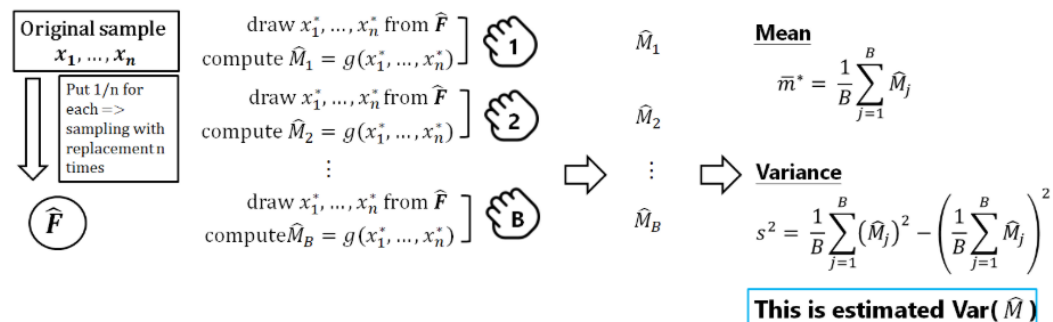
Plug-in principle: $\hat{\theta} = g(\hat{F}) = \int r(x) d\hat{F} \Leftrightarrow \theta = g(F) = \int r(x) dF$ (전자는 후자의 plug-in estimate)

Form an EDF

Draw and calculate Statistic B times

Get B Statistic

Summarize



2.Variance of \hat{M} with $EDF \hat{F}$

$$s^2 = \frac{1}{B} \sum_{j=1}^B (\hat{M}_j)^2 - \left(\frac{1}{B} \sum_{j=1}^B \hat{M}_j \right)^2 \approx \text{Var}(\hat{M}; \hat{F}) \approx \text{Var}(M; F)$$

1. Bootstrap Variance Estimation

1. Simulation Error

3. Variance of M with true F

1번 simulation error는 결국 큰 수의 법칙에 의해 확률 수렴하므로 $B \uparrow$ 으로 최소화 가능

2번 approximation error는 \hat{F} 이 F 에 근사 ($n \uparrow$) 하면 최소화 ($n \uparrow$ 면 자연스럽게 $\hat{M} \xrightarrow{P} M$ 성질도...)

Boot-
strap
기본

4. 통계적 추론 - MLE / 신뢰구간 / 가설검정

Boot-strap 응용	모평균 추정	$E(X_i^*) = \sum_{j=1}^n \frac{1}{n} X_j = \bar{X}, \quad \text{Var}(X_i^*) = \sum_{j=1}^n \frac{1}{n} (X_j - \bar{X})^2 = \frac{n}{n-1} S^2$ $E(\bar{X}_j^*) = \bar{X}, \quad \text{Var}(\bar{X}_j^*) = \frac{S^2}{n-1}$ <p>B회 시뮬레이션 평균 $\frac{1}{B} \sum_{i=1}^B \bar{X}_j^* \xrightarrow{P} E(\bar{X}_j^*) = \bar{X} \xrightarrow{P} \mu$, 분산 $\frac{1}{B} \sum_{i=1}^B (\bar{X}_j^*)^2 - \left(\frac{1}{B} \sum_{i=1}^B \bar{X}_j^* \right)^2 \xrightarrow{P} \text{Var}(\bar{X}_j^*) = \frac{S^2}{n-1} \xrightarrow{P} \frac{\sigma^2}{n}$</p> <p>→ B 회 부트스트랩 \bar{X} 신뢰구간 (비모수적 counting) $\approx \left[\bar{X} - z_{\alpha/2} \frac{S^2}{n}, \bar{X} + z_{\alpha/2} \frac{S^2}{n} \right] \approx [\mu \text{의 CLT 신뢰 구간}]$</p> <p>- 위의 정규가정을 통한 $z_{\alpha/2}$ 근사는 책 참고 4.9.1를 참조</p> <p>- 다른 모수 추정도 크게 다르지 않음. (\bar{X}처럼 precise한 분산식이 존재하지 않으면 시뮬레이션 효과 ↑)</p> <p>- 통계량의 분포가 다른 모수에 종속되지 않게 pivot화하면 부트스트랩 정확성 향상 가능</p>		
		Boot-strap 검정	<1표본 평균> $H_0: \mu = \mu_0$ $H_1: \mu > \mu_0$	1. 상황: 1) 검정통계량: \bar{X} 2) $\hat{p} = P_{H_0}[\bar{X} \geq \bar{x}]$ 2. H_0 가정 $\Rightarrow \mathbf{z}_i = \mathbf{x}_i - \bar{\mathbf{x}} + \boldsymbol{\mu}_0$ ($E(z_i^*) = E(\bar{z}_j^*) = \mu_0$) \Rightarrow 복원으로 n개 부트스트랩 3. Empirical P-value 산출: $\hat{p} = I/B$ ($I: \{\bar{z}_j^* > \bar{x}\}$)
	<2표본 평균> $H_0: \mu_2 = \mu_1$ $H_1: \mu_2 > \mu_1$		1. 상황: 1) 검정통계량: $V = \bar{Y} - \bar{X}$ 2) $\hat{p} = P_{H_0}[V \geq \bar{y} - \bar{x}]$ 2. H_0 가정 \Rightarrow 표본 합침 ($n = n_1 + n_2$) \Rightarrow 복원으로 $(\mathbf{X}_i^*, n_1 \text{개}), (\mathbf{Y}_i^*, n_2 \text{개})$ 추출 3. Empirical P-value 산출: $\hat{p} = I/B$ ($I: \{\bar{y}_i^* - \bar{x}_i^* > \bar{y} - \bar{x}\}$) * 부연: H_0 가정 했기 때문에 생성값 $(\bar{y}_i^* - \bar{x}_i^*)$ 은 H_0 하 통계량임.	
	Perm test	2표본 perm test: 통합 표본 ($n=n_1+n_2$)에서 비복원으로 추출된 x,y 모든 가능한 표본 → 검정		

5. 일치성 / 극한분포 ("통계학적 수렴")

중요한 부등식	1. Markov: $P[u(X) \geq c] \leq E[u(X)]/c$ (for $u(X) \geq 0, c > 0$; $E[u(X)]$ 존재) *증명: $E[u(x)] = \int_{-\infty}^{\infty} u(x)f(x)dx \geq \int_{u(x) \geq c} u(x)f(x)dx \geq c \int_{u(x) \geq c} f(x)dx = c P[u(x) \geq c]$ 2. Chevyshev: $P(X - \mu \geq k\sigma) \leq 1/k^2$ (for $k > 0$; X 가 μ, σ^2 (유한) 가짐) *증명: Markov에서 $u(X) = (X - \mu)^2, c = k^2\sigma^2$			
확률 수렴	1. 정의: $X_n \xrightarrow{P} X \Leftrightarrow \forall \epsilon > 0, \lim_{n \rightarrow \infty} P[X_n - X \geq \epsilon] = 0$ ($\Leftrightarrow \lim_{n \rightarrow \infty} P[X_n - X < \epsilon] = 1$) “함수열의 수렴” $(X_n \xrightarrow{P} a, \text{ if } X \text{가 상수 } a \Rightarrow \text{“퇴화확률변수, } p(a)=1, \text{ 나머지 } 0\text{”})$			
	2. 대수의 약법칙: iid $\{X_n\} \sim (\text{평균: } \mu, \text{분산: } \sigma^2 < \infty), \bar{X}_n \xrightarrow{P} \mu$ *증명: By Chevyshev's ineq, $P(\bar{X}_n - \mu \geq \epsilon) \leq \sigma^2 / (n\epsilon^2) \rightarrow 0$ (when $n \rightarrow \infty$)			
	3. 정리			
	선형	<table><tr><td>* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ① $(X_n + Y_n) \xrightarrow{P} (X + Y)$ ② $aX_n \xrightarrow{P} aX$</td><td>① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 $P[(X_n + Y_n) - (X + Y) \geq \epsilon] \leq P[X_n - X + Y_n - Y \geq \epsilon]$ $\leq P[X_n - X \geq \epsilon/2] + P[Y_n - Y \geq \epsilon/2]$</td></tr></table>	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ① $(X_n + Y_n) \xrightarrow{P} (X + Y)$ ② $aX_n \xrightarrow{P} aX$	① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 $P[(X_n + Y_n) - (X + Y) \geq \epsilon] \leq P[X_n - X + Y_n - Y \geq \epsilon]$ $\leq P[X_n - X \geq \epsilon/2] + P[Y_n - Y \geq \epsilon/2]$
	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ① $(X_n + Y_n) \xrightarrow{P} (X + Y)$ ② $aX_n \xrightarrow{P} aX$	① P는 집합오염에 단조 (=공간 커지면 확률 커짐); 삼각부등식 $P[(X_n + Y_n) - (X + Y) \geq \epsilon] \leq P[X_n - X + Y_n - Y \geq \epsilon]$ $\leq P[X_n - X \geq \epsilon/2] + P[Y_n - Y \geq \epsilon/2]$		
함수	<table><tr><td>* 받침 상 연속 $g(x)$ ③ $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ ④ $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$</td><td>① $g(x) - g(a) \geq \epsilon \Rightarrow x - a \geq \delta$ ($\epsilon > 0, \delta > 0$) $\therefore P[g(X_n) - g(a) \geq \epsilon] \leq P[X_n - a \geq \delta]$</td></tr></table>	* 받침 상 연속 $g(x)$ ③ $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ ④ $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$	① $ g(x) - g(a) \geq \epsilon \Rightarrow x - a \geq \delta$ ($\epsilon > 0, \delta > 0$) $\therefore P[g(X_n) - g(a) \geq \epsilon] \leq P[X_n - a \geq \delta]$	
* 받침 상 연속 $g(x)$ ③ $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ ④ $X_n \xrightarrow{P} X \Rightarrow g(X_n) \xrightarrow{P} g(X)$	① $ g(x) - g(a) \geq \epsilon \Rightarrow x - a \geq \delta$ ($\epsilon > 0, \delta > 0$) $\therefore P[g(X_n) - g(a) \geq \epsilon] \leq P[X_n - a \geq \delta]$			
곱	<table><tr><td>* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ⑤ $X_n Y_n \xrightarrow{P} XY$</td><td>* $X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY$</td></tr></table>	* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ⑤ $X_n Y_n \xrightarrow{P} XY$	* $X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY$	
* $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y$ ⑤ $X_n Y_n \xrightarrow{P} XY$	* $X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2 \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY$			
	4. 일치성: $T_n \xrightarrow{P} \theta$ 면 $\Leftrightarrow T_n$ 은 θ 의 일치 추정량 * $F(x; \theta)$ 에서 추출한 iid $\{X_1, \dots, X_n\}$ 의 통계량 T_n			
	분산 추정량	<table><tr><td>① $S_n^2 \xrightarrow{P} \sigma^2$ (일치 & 불편)</td><td>② $S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2$ (일치 & MLE)</td></tr></table>	① $S_n^2 \xrightarrow{P} \sigma^2$ (일치 & 불편)	② $S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2$ (일치 & MLE)
	① $S_n^2 \xrightarrow{P} \sigma^2$ (일치 & 불편)	② $S_{mle}^2 = \frac{n-1}{n} S_n^2 \xrightarrow{P} \sigma^2$ (일치 & MLE)		
균등분포 모수 추정량	<table><tr><td>$X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}$ $g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}$ ($0 < t \leq \theta$) $E(Y_n) = \int_0^\theta t \left(n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore \text{최대값 } Y_n \text{은 } \theta \text{의 일치 추정량}$ \bar{X}_n은 $\theta/2$의 일치 추정량 $\Rightarrow 2\bar{X}_n$은 θ의 일치 추정량</td></tr></table>	$X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}$ $g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}$ ($0 < t \leq \theta$) $E(Y_n) = \int_0^\theta t \left(n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore \text{최대값 } Y_n \text{은 } \theta \text{의 일치 추정량}$ \bar{X}_n 은 $\theta/2$ 의 일치 추정량 $\Rightarrow 2\bar{X}_n$ 은 θ 의 일치 추정량		
$X_1, \dots, X_n \sim \text{unif}(0, \theta), Y_n = \max\{X_1, \dots, X_n\}$ $g_n(Y_n) = \frac{n!}{(n-1)! 0! 1!} F(Y_n)^{n-1} (1 - F(Y_n))^0 f(y_n) = n \frac{t^{n-1}}{\theta^n}$ ($0 < t \leq \theta$) $E(Y_n) = \int_0^\theta t \left(n \frac{t^{n-1}}{\theta^n} \right) dt = \frac{n}{n+1} \theta \therefore \text{최대값 } Y_n \text{은 } \theta \text{의 일치 추정량}$ \bar{X}_n 은 $\theta/2$ 의 일치 추정량 $\Rightarrow 2\bar{X}_n$ 은 θ 의 일치 추정량				
분포 수렴	1. 정의: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F_X \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ “극한분포”			
	2. t분포 \Rightarrow z분포 ($n \rightarrow \infty$) ① $f_n(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{(n+1)}{2}}, \int_{-\infty}^t f_n(y) dy \leq \int_{-\infty}^t 10f_1(y) dy = \frac{10}{\pi} \tan^{-1} t < \infty$ (르벡 DCT) ② $\lim_{n \rightarrow \infty} F_n(t) = \lim_{n \rightarrow \infty} \int_{-\infty}^t f_n(x) dx = \int_{-\infty}^t \lim_{n \rightarrow \infty} f_n(x) dx = \int_{-\infty}^t \lim_{n \rightarrow \infty} \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{(n+1)}{2}} dx = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \Phi(t)$			
	3. 정리			
	① $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$	https://freshrimpsushi.tistory.com/175?category=696570		
	② $X_n \xrightarrow{P} b \Leftrightarrow X_n \xrightarrow{D} b$	if 분포수렴 $\Rightarrow \lim_{n \rightarrow \infty} P[X_n - b \leq \epsilon] = \lim_{n \rightarrow \infty} F_{X_n}(b + \epsilon) - F_{X_n}(b - \epsilon) = 1 - 0 = 0$		
	③ $X_n \xrightarrow{D} X \ \& \ (A_n \xrightarrow{P} a, B_n \xrightarrow{P} b)$ $\Rightarrow A_n + B_n X_n \xrightarrow{D} a + bX$	<Slutsky 정리> e.g. $P_n - Q_n \xrightarrow{P} 0, Q_n \xrightarrow{D} X \Rightarrow P_n = (P_n - Q_n) + Q_n \xrightarrow{D} X$		
	* 받침 상 연속 $g(x)$ ④ $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$	$Z_n \xrightarrow{D} Z \Rightarrow Z_n^2 \xrightarrow{D} Z^2(1)$		
	⑤ $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$	$Y_n \sim b(n, p) \Rightarrow \lim_{n \rightarrow \infty} M_n(t) = \lim_{n \rightarrow \infty} E(e^{tY_n}) = \lim_{n \rightarrow \infty} [(1-p) + (pe^t)]^n = e^{\mu(e^t-1)}$ $\therefore \text{이항분포 } b(n, p) \xrightarrow{D} \text{푸아송분포 } (\mu = np)$		

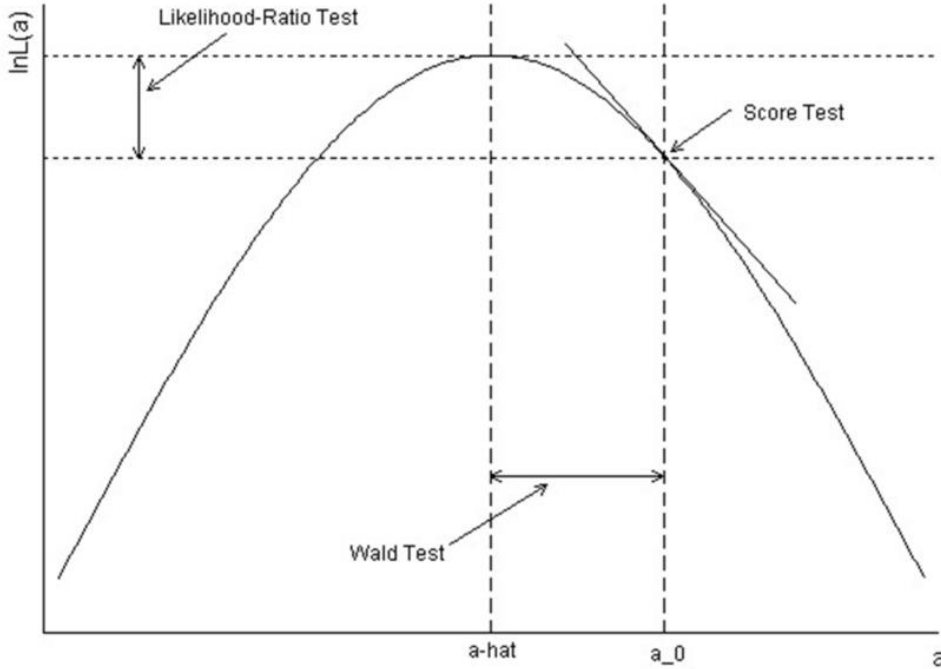
5. 일치성 / 극한분포 (“통계학적 수렴”)

Δ-방법	$\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$ 이고, $g(x)$ 가 θ 에서 미분 가능 & $g'(\theta) \neq 0$ 이면 $\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, g'(\theta)^2 \sigma^2)$ [Δ-method를 잘 이용하면 모수에 종속되지 않는 통계량 분산 만들] pf) 테일러 정리에 의해 $g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o(X_n - \theta)$ 이므로 $\sqrt{n}(g(X_n) - g(\theta)) = \sqrt{n}g'(\theta)(X_n - \theta) + o(\sqrt{n} X_n - \theta) \xrightarrow{P} \sqrt{n}g'(\theta)(X_n - \theta) \xrightarrow{D} N(0, g'(\theta)^2 \sigma^2)$ (중간에 little-o를 0으로 확률수렴 시키는 전개는 확률 유계인 Y_n 에 대해 $o(Y_n) \xrightarrow{P} 0$ 임을 이용)								
중심 극한 정리 (CLT)	1. 중심극한정리: $Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1) \leftarrow \text{iid } X_i \sim (\text{평균: } \mu, \text{분산: } \sigma^2)$ 2. 대표본 추론 통계량: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{D} N(0, 1) \quad \because S \xrightarrow{P} \sigma \Leftrightarrow \frac{S}{\sigma} \xrightarrow{P} 1, \text{CLT \& Slutsky에 의해 } \left(\frac{\sigma}{S}\right) \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$ 2. 증명: MGF 이용 (특성함수 $\varphi(t) = E(e^{itx})$ 이용해야 더 정확함) $m(t) := E[e^{t(X-\mu)}] = e^{-\mu t} M(t) \Rightarrow m(0) = 1, m'(0) = E(X - \mu) = 0, m''(0) = E[(X - \mu)^2] + m'(0)^2 = \sigma^2$ 테일러 정리에 의해 $m(t) = m(0) + m'(0)t + \frac{1}{2}m''(\xi)t^2 = 1 + \frac{1}{2}m''(\xi)t^2 = 1 + \frac{1}{2}\sigma^2 t^2 + \frac{1}{2}(m''(\xi) - \sigma^2)t^2, \xi \in [-t, t]$ $M(t; n) := E(e^{tZ_n}) = E\left(\exp\left(t \frac{(1/n)\sum X_i - \mu}{\sigma/\sqrt{n}}\right)\right) = E\left(\exp\left(t \frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}}\right)\right) = \prod_{i=1}^n E\left(\exp\left(t \frac{X_i - \mu}{\sigma\sqrt{n}}\right)\right)$ $= \left[E\left(\exp\left(\frac{t(X - \mu)}{\sigma\sqrt{n}}\right)\right)\right]^n = \left[m\left(\frac{t}{\sigma\sqrt{n}}\right)\right]^n, \quad -h < \frac{t}{\sigma\sqrt{n}} < h$ $M(t; n) = \left[m\left(\frac{t}{\sigma\sqrt{n}}\right)\right]^n = \left\{1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2}\right\}^n, \quad \xi \in \left[-\frac{t}{\sigma\sqrt{n}}, \frac{t}{\sigma\sqrt{n}}\right]$ $\therefore \lim_{n \rightarrow \infty} M(t; n) = \lim_{n \rightarrow \infty} \left\{1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2}\right\}^n = \lim_{n \rightarrow \infty} \left(1 + \frac{t^2}{2n}\right)^n = \exp\left(\frac{1}{2}t^2\right) \quad \because \lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0 \quad (\because \xi \rightarrow 0)$ Z_n 의 mgf $M(t; n)$ 의 $n \rightarrow \infty$ 극한값은 $N(0, 1)$ 의 mgf $\exp\left(\frac{1}{2}t^2\right) \Rightarrow \therefore Z_n \xrightarrow{D} N(0, 1)$								
다변량 분포 확장	<table border="1"> <tr> <td data-bbox="165 1115 277 1373"> 수렴성 다변량 확장 </td><td data-bbox="277 1115 1560 1373"> 1) 확률수렴: $\{X_n\} \in \mathbb{R}^p$일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다. 즉, $X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j$ (모든 $j = 1, \dots, p$에서 성립) 2) 분포수렴: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ ① $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$ (corollary: $g(x) = x_j$로 두면 분포수렴이 주변 (marginal) 수렴 수반) ② $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$ </td></tr> <tr> <td data-bbox="165 1373 277 1653"> 다변량 표본 </td><td data-bbox="277 1373 1560 1653"> $\{X_n\} \in \mathbb{R}^p$인 평균 μ, 공분산행렬 Σ인 iid 확률벡터열 ① 표본평균벡터: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T$ ② 표본공분산행렬: $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); \quad p \times p \text{ 행렬}$ $\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma$ (4차 적률 유한할 때 대수 약법칙) </td></tr> <tr> <td data-bbox="165 1653 277 1709"> CLT </td><td data-bbox="277 1653 1560 1709"> $Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$ </td></tr> <tr> <td data-bbox="165 1709 277 1821"> Δ방법 </td><td data-bbox="277 1709 1560 1821"> $\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})$ $\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)$ </td></tr> </table>	수렴성 다변량 확장	1) 확률수렴: $\{X_n\} \in \mathbb{R}^p$ 일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다. 즉, $X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j$ (모든 $j = 1, \dots, p$ 에서 성립) 2) 분포수렴: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ ① $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$ (corollary: $g(x) = x_j$ 로 두면 분포수렴이 주변 (marginal) 수렴 수반) ② $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$	다변량 표본	$\{X_n\} \in \mathbb{R}^p$ 인 평균 μ , 공분산행렬 Σ 인 iid 확률벡터열 ① 표본평균벡터: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T$ ② 표본공분산행렬: $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); \quad p \times p \text{ 행렬}$ $\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma$ (4차 적률 유한할 때 대수 약법칙)	CLT	$Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$	Δ방법	$\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})$ $\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)$
수렴성 다변량 확장	1) 확률수렴: $\{X_n\} \in \mathbb{R}^p$ 일 때, 벡터의 각 성분이 수렴하는 경우가 전체 벡터의 수렴과 동치이다. 즉, $X_n \xrightarrow{P} X \Leftrightarrow X_{nj} \xrightarrow{P} X_j$ (모든 $j = 1, \dots, p$ 에서 성립) 2) 분포수렴: $X_n \xrightarrow{D} X \Leftrightarrow \forall x \in \{F(x) \text{ 연속 점}\}, \lim_{n \rightarrow \infty} F_n(x) = F(x), \quad (F: X \text{의 cdf}, F_n: X_n \text{의 cdf})$ ① $X_n \xrightarrow{D} X \Rightarrow g(X_n) \xrightarrow{D} g(X)$ (corollary: $g(x) = x_j$ 로 두면 분포수렴이 주변 (marginal) 수렴 수반) ② $X_n \xrightarrow{D} X \Leftrightarrow \lim_{n \rightarrow \infty} M_n(t) = M(t)$								
다변량 표본	$\{X_n\} \in \mathbb{R}^p$ 인 평균 μ , 공분산행렬 Σ 인 iid 확률벡터열 ① 표본평균벡터: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = (\bar{X}_1, \dots, \bar{X}_p)^T$ ② 표본공분산행렬: $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2, S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k); \quad p \times p \text{ 행렬}$ $\therefore \bar{X}_n \xrightarrow{P} \mu, S_n \xrightarrow{P} \Sigma$ (4차 적률 유한할 때 대수 약법칙)								
CLT	$Y_n = \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \Leftrightarrow \text{근사적으로 } \bar{X}_n \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$								
Δ방법	$\sqrt{n}(X_n - \mu_0) \xrightarrow{D} N_p(0, \Sigma) \quad (g \text{는 } \mathbb{R}^p \rightarrow \mathbb{R}^k \text{ 로의 변환 } (k \leq p); \text{미분행렬 } B = \left[\frac{\partial g_i}{\partial x_j}\right] \text{이 연속, } B \neq 0 \text{ in } \mu_0 \text{ 근방})$ $\sqrt{n}(g(X_n) - g(\mu_0)) \xrightarrow{D} N_p(0, B_0 \Sigma B_0^T) \quad B_0 = B(\mu_0)$								

6. 최대가능도방법 (Maximum Likelihood Methods)

MLE (R0)~(R2)	MLE 핵심	<p>(R0), (R1) 하에서 $\lim_{n \rightarrow \infty} P_{\theta_0} [L(\theta_0, \mathbf{X}) > L(\theta, \mathbf{X})] = 1 \quad (\forall \theta \neq \theta_0)$</p> <p>$p f) \frac{1}{n} \sum_{i=1}^n \ln \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] \xrightarrow{P} E_{\theta_0} \left(\ln \left[\frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] \right) < \ln E_{\theta_0} \left[\frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right]$ by 대수의 법칙, Jensen 부등식</p> <p>$E_{\theta_0} \left[\frac{f(X_1; \theta)}{f(X_1; \theta_0)} \right] = \int \frac{f(x; \theta)}{f(x; \theta_0)} f(x; \theta_0) dx = 1$ (R1 공통 받침 하에서)</p> <p>$\therefore \frac{1}{n} \sum_{i=1}^n \ln \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] < 0 \Leftrightarrow L(\theta_0, \mathbf{X}) > L(\theta, \mathbf{X})$</p> <p>$\therefore$ 근사적으로 참값 θ_0에서 우도함수 $L(\theta, \mathbf{X})$가 최대가 된다. ($\hat{\theta} = \text{Argmax}[L(\theta)] \xrightarrow{P} \theta_0$)</p>	
	불변성	<p>$\eta = g(\theta) \Leftrightarrow \hat{\eta} = g(\hat{\theta})$</p> <p>$p f) \textcircled{1} g \in 1\text{대}1 \text{ 함수: } \max L(\theta) = \max L(g^{-1}(\eta))$ 이므로 $\hat{\theta} = g^{-1}(\hat{\eta})$에서 우도 최대화</p> <p>$\textcircled{2} g \notin 1\text{대}1 \text{ 함수: } g^{-1}(\eta) := \{\theta: g(\theta) = \eta\}$ 새로 정의 $\rightarrow \hat{\theta} \in g^{-1}(\hat{\eta})$에서 우도최대화</p>	
	추정 방정식	<p>*추정방정식 (estimating equation; EE): $\partial l(\theta) / \partial \theta = 0$</p> <p>(R0)~(R2) 하에서 $\partial l(\theta) / \partial \theta = 0$ 는 $\hat{\theta} \xrightarrow{P} \theta_0$ 인 $\hat{\theta}$를 가짐</p> <p>(Corollary: EE가 유일해를 가지면 그 해는 $\hat{\theta} \xrightarrow{P} \theta_0$)</p>	
Cramér Rao Bound (R0)~(R4)	스코어 함수 & 피셔정보	<p>$\textcircled{1}$ Score 함수 $s(\theta) = \frac{\partial \ln f}{\partial \theta}$</p> <p>$\textcircled{2}$ Fisher information $I(\theta) = \text{Var} \left(\frac{\partial \ln f}{\partial \theta} \right) = E \left[\left(\frac{\partial \ln f}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln f}{\partial \theta^2} \right]$</p> <p>$1 = \int_{-\infty}^{\infty} f dx \rightarrow$ 양변 θ로 i) 한번 미분 ii) 두번 미분 하면</p> <p>i) $0 = \int_{-\infty}^{\infty} (\partial f / \partial \theta) dx = \int_{-\infty}^{\infty} \frac{(\partial f / \partial \theta)}{f} f dx = \int_{-\infty}^{\infty} \left(\frac{\partial \ln f}{\partial \theta} \right) f dx \quad \therefore E \left(\frac{\partial \ln f}{\partial \theta} \right) = 0$</p> <p>ii) $0 = \int_{-\infty}^{\infty} \frac{\partial^2 \ln f}{\partial \theta^2} f dx + \int_{-\infty}^{\infty} \left(\frac{\partial \ln f}{\partial \theta} \right) \left(\frac{\partial \ln f}{\partial \theta} \right) f dx \quad \therefore E \left[\frac{\partial^2 \ln f}{\partial \theta^2} \right] + E \left[\left(\frac{\partial \ln f}{\partial \theta} \right)^2 \right] = 0$</p> <p>iid $[X_1, \dots, X_n]$ 에 대해서</p> <p>$\textcircled{1}$ Score 함수 $s_n(\theta) = \frac{\partial l}{\partial \theta} = \frac{\partial \ln L}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta}$</p> <p>$\textcircled{2}$ Fisher 정보 $I_n(\theta) = \text{Var} \left(\frac{\partial l}{\partial \theta} \right) = \text{Var} \left(\frac{\partial \ln L}{\partial \theta} \right) = n I(\theta)$</p>	
	Cramér-Rao Bound (CRB)	<p>$\textcircled{1} \text{Var}(T) \geq \frac{[\partial E(T) / \partial \theta]^2}{n I(\theta)}$ for 임의의 통계량 $T = g(X_1, \dots, X_n)$</p> <p>$\textcircled{2} \text{Var}(T) \geq \frac{1}{n I(\theta)}$ for 불편추정량 T ($\because E(T) = \theta$)</p> <p>$p f) E(T) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} [T] f(x_1; \theta) \dots f(x_n; \theta) dx_1 \dots dx_n$</p> <p>$\Leftrightarrow \partial E(T) / \partial \theta = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} [T] \left[\sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right] f(x_1; \theta) \dots f(x_n; \theta) dx_1 \dots dx_n, Z := \left[\sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right]$</p> <p>$\Leftrightarrow \partial E(T) / \partial \theta = E(TZ) = E(T)E(Z) + \rho \sigma_T \sigma_Z = \rho \sqrt{\text{Var}(T)} \sqrt{n I(\theta)} \quad \therefore \rho^2 \leq 1 \Leftrightarrow \text{Var}(T) \geq \frac{[\partial E(T) / \partial \theta]^2}{n I(\theta)}$</p>	
	효율성	<p>*효율성: 통계량 T의 효율성은 $\text{CRB}(T) / \text{Var}(T)$</p> <p>* ARE (근사 상대효율성) $= e(T, W) = \frac{\text{Var}(W)}{\text{Var}(T)}$ (if $T \xrightarrow{P} \theta_0, W \xrightarrow{P} \theta_0$이며 둘다 정규근사 될 때)</p>	
	MLE 정규근사 (R0)~(R5)	<p>$\textcircled{1}$ 정규 근사: $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N \left(0, \frac{1}{I(\theta_0)} \right)$ for 유한 피셔정보 $I(\theta_0)$ * $p f) l'(\hat{\theta})$를 θ_0 테일러 전개 ...</p> <p>\Rightarrow MLE의 근사 정규 신뢰 구간 구할 수 있음.</p> <p>$\therefore \text{Var}(\hat{\theta}) \xrightarrow{P} \frac{1}{n I(\theta_0)}$ (mle는 근사적으로 효율적 or mle의 분산은 CRB에 근사)</p> <p>$\textcircled{2}$ Δ방법: $\sqrt{n}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{D} N \left(0, \frac{g'(\theta_0)^2}{I(\theta_0)} \right)$ ($g(x)$가 θ에서 미분 가능 & $g'(\theta) \neq 0$ 이면)</p> <p>$\textcircled{3}$ 정규 근사: $\hat{\theta} - \theta_0 = \frac{1}{n I(\theta_0)} \sum_{i=1}^n \frac{\partial \ln f(X_i; \theta_0)}{\partial \theta} + \frac{R_n}{\sqrt{n}} = -\frac{l'(\theta_0)}{l''(\theta_0)} + \frac{R_n}{\sqrt{n}} \quad (R_n \xrightarrow{P} 0)$</p>	
	MLE Newton's	<p>$\hat{\theta}_1 = \hat{\theta}_0 - \frac{l'(\hat{\theta}_0)}{l''(\hat{\theta}_0)}$ 과정 반복 * $\hat{\theta}_0$이 일치 추정량이면 $\hat{\theta}_1$은 mle $\mathcal{L} \left(\xrightarrow{P} N \left(0, \frac{1}{I(\theta_0)} \right) \right)$</p>	

6. 최대가능도방법 (Maximum Likelihood Methods)

최대 가능도 검정 (ML tests)	전개	$\text{우도비 (LR): } \Lambda = \frac{L(\theta_0)}{L(\hat{\theta})} \quad (\Lambda \leq c \text{ 에서 기각})$ $-\frac{1}{n} l''(\theta_0) \xrightarrow{P} I(\theta_0), \quad \frac{l'(\theta_0)}{\sqrt{n}} = \sqrt{n}(\hat{\theta} - \theta_0)I(\theta_0) + R_n \text{ 이므로}$ $l(\hat{\theta}) = l(\theta_0) + (\hat{\theta} - \theta_0)l'(\theta_0) + \frac{1}{2}(\hat{\theta} - \theta_0)l''(\theta_n^*) \text{의 미분계수 항들에 대입해주면}$ $-2 \ln \Lambda = 2[l(\hat{\theta}) - l(\theta_0)] = \left[\sqrt{nI(\theta_0)}(\hat{\theta} - \theta_0) \right]^2 + R_n^* \quad (R_n^* \xrightarrow{P} 0)$ $\therefore -2 \ln \Lambda \xrightarrow{D} \chi^2(1) \leftarrow \sqrt{nI(\theta_0)}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0,1)$	
	우도비 검정	$\chi_L^2 = -2 \ln \Lambda$	$\chi^2 \geq \chi_{\alpha}^2(1)$ 에서 단측 검정 기각역 ($H_0: \theta = \theta_0, H_1: \theta \neq \theta_0$)
	Wald 검정	$\chi_W^2 = \left[\sqrt{nI(\hat{\theta})}(\hat{\theta} - \theta_0) \right]^2$	
	Score 검정	$\chi_R^2 = \left(\frac{l'(\theta_0)}{\sqrt{nI(\theta_0)}} \right)^2$	
	<div></div> <p>have the following relationship $\text{Wald} \geq \text{LR} \geq \text{score}$ (Johnston and DiNardo 1997 p. 150). That is, the Wald test statistic will always be greater than the LR test statistic, which will, in turn, always be greater than the test statistic from the score test. When computing power was much more limited, and many models took a long time to run, being able to approximate the LR test using a single model was a fairly major advantage. Today, for most of the models researchers are likely to want to compare, computational time is not an issue, and we generally recommend running the likelihood ratio test in most situations. This is not to say that one should never use the Wald or score tests. For example, the Wald test is commonly used to perform multiple degree of freedom tests on sets of dummy variables used to model categorical predictor variables in regression (for more information see our webbooks on Regression with Stata, SPSS, and SAS, specifically Chapter 3 – Regression with Categorical Predictors.) The advantage of the score test is that it can be used to search for omitted variables when the number of candidate variables is large.</p>		
정칙 조건	(R0): pdf $f(x; \theta)$ 는 서로 distinct 하다. i.e. $\theta_1 \neq \theta_2 \Rightarrow f(x; \theta_1) \neq f(x; \theta_2)$ (R1): pdf $f(x; \theta)$ 는 모든 θ 에 대해 공통된 support를 갖는다. (θ 에 의존적이지 않다.) (R2): θ_0 (참값) $\in \Omega$ (R3): pdf $f(x; \theta)$ 는 θ 로 두 번 미분 가능 (R4): $\int f(x; \theta) dx$ 는 θ 로 두 번 미분 가능 (R5): pdf $f(x; \theta)$ 는 θ 로 세 번 미분 가능, 모든 θ 에 대해 $ \partial^3 \ln f / \partial \theta^3 \leq M(x)$ ($E_{\theta_0}[M(X)] < \infty$) in θ_0 근방 $\forall x$		
Regularity conditions			

6. 최대가능도방법 (Maximum Likelihood Methods)

*정칙조건 $\sim(R9)$ 까지 추가됨. (기존 정칙의 다변량 확장)

맨위 "MLE 핵심" 정리는 벡터 $\theta = [\theta_1, \dots, \theta_p]^T \in \mathbb{R}^p$ 에 대해서도 똑같이 성립함. $\Leftrightarrow \nabla l(\theta) = \mathbf{0}$ 의 해 구하기

다중 모수 추정	피셔정보량	$\nabla \ln f(X; \theta) = \left(\frac{\partial \ln f(X; \theta)}{\partial \theta_1}, \dots, \frac{\partial \ln f(X; \theta)}{\partial \theta_p} \right)^T$ 피셔 정보량: $\mathbf{I}(\theta) = \text{Cov}(\nabla \ln f(X; \theta)) = -E \left[\frac{\partial^2}{\partial \theta_j \partial \theta_k} \ln f \right]_{jk} = E \left[\left(\frac{\partial \ln f}{\partial \theta_j} \right) \left(\frac{\partial \ln f}{\partial \theta_k} \right) \right]_{jk}$
	피셔정보량 (표본 n 확장)	$\nabla l = \nabla \ln L = \sum_{i=1}^n \nabla \ln f$ 피셔 정보량: $\mathbf{I}_n(\theta) = \text{Cov}(\nabla l) = \text{Cov}(\nabla \ln L) = n\mathbf{I}(\theta)$
	CRB	$\text{Var}(T_j) \geq \frac{1}{n} [\mathbf{I}^{-1}(\theta)]_{jj}$ (T_j 가 θ_j 의 불편 추정량)
	정규근사	$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1}(\theta_0)) \Rightarrow \sqrt{n}(\hat{\theta}_j - \theta_j) \xrightarrow{D} N(0, [\mathbf{I}^{-1}(\theta_0)]_{jj})$
	Δ 방법	$\sqrt{n}(\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta_0)) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{B}[\mathbf{I}^{-1}(\theta_0)]\mathbf{B}^T)$ (\mathbf{g} 는 $\mathbb{R}^p \rightarrow \mathbb{R}^k$ 로의 변환 ($k \leq p$); 미분행렬 $\mathbf{B} = \left[\frac{\partial g_i}{\partial \theta_j} \right]$ 이 연속, $\mathbf{B} \neq \mathbf{0}$ in θ_0 근방)

다중모수

다중 모수 검정	기 본	$H_0: \theta \in \omega, H_1: \theta \in (\omega^c \cap \Omega)$ (Ω : p차원 전체 모수 공간; ω : p-q차원 귀무가설 모수공간 (q : 제약된 모수 개수))
		우도비 (LR): $\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \frac{\max_{\theta \in \omega} L(\theta)}{\max_{\theta \in \Omega} L(\theta)}$ $\chi_L^2 = -2 \ln \Lambda \xrightarrow{D} \chi^2(q)$ (Wald, Score 검정통계량도 가능)
	예 시	정규 μ $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0 \quad \{X_n\} \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ $L(\hat{\Omega}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\hat{\sigma}^2} \right\} = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left(-\frac{n}{2} \right)$ $L(\hat{\omega}) = \frac{1}{(2\pi\hat{\sigma}_0^2)^{n/2}} \exp \left(-\frac{n}{2} \right) \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$ $\left(\frac{1}{\Lambda} \right)^{\frac{2}{n}} = \left(\frac{L(\hat{\Omega})}{L(\hat{\omega})} \right)^{\frac{2}{n}} = \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = 1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = 1 + \frac{1}{n-1} \left\{ \frac{(\bar{X} - \mu_0)^2}{S/\sqrt{n}} \right\}$ $\left(\frac{1}{\Lambda} \right)^{\frac{2}{n}} \geq c' \Leftrightarrow T \geq c^* = \sqrt{(c' - 1)(n-1)} \quad \therefore \text{양측 t검정과 동치}$
		다항 p $H_0: p_1 = p_2, H_1: p_1 \neq p_2$ (유력후보1 vs 유력후보2 vs 나머지 군소후보) 3항 베르누이 $(X_{i1}, X_{i2}) \sim p_1^{x_1} p_2^{x_2} (1 - p_1 - p_2)^{1-x_1-x_2} \quad (X_{i1}, X_{i2}) \in \{(0,0), (0,1), (1,0)\}$ $\hat{p}_j = \frac{\sum_{i=1}^n X_{ij}}{n} \text{ for } j = 1, 2 \quad (\text{표본: } \{(X_{n1}, X_{n2})\})$ LR $\frac{1}{\Lambda} = \left(\frac{2\hat{p}_1}{\hat{p}_1 + \hat{p}_2} \right)^{n\hat{p}_1} \left(\frac{2\hat{p}_2}{\hat{p}_1 + \hat{p}_2} \right)^{n\hat{p}_2}, \quad -2 \ln \Lambda > \chi_{\alpha}^2(1) \text{에서 기각}$ Wald $\begin{bmatrix} \hat{p}_1 \\ \hat{p}_2 \end{bmatrix} \stackrel{a}{\sim} N_2 \left(\begin{bmatrix} p_1 \\ p_2 \end{bmatrix}, \frac{1}{n} \begin{bmatrix} p_1(1-p_1) & -p_1p_2 \\ -p_1p_2 & p_2(1-p_2) \end{bmatrix} \right)$ $W = \hat{p}_1 - \hat{p}_2 = g \left(\begin{bmatrix} \hat{p}_1 \\ \hat{p}_2 \end{bmatrix} \right), \quad \Delta \text{방법에서 } \mathbf{B} = \left[\frac{\partial g_i}{\partial p_j} \right] = [1, -1]$ $\text{Var}(W) = \frac{1}{n} \mathbf{B} \mathbf{I}^{-1} \mathbf{B}^T = \frac{p_1 + p_2 - (p_1 - p_2)^2}{n}$ $\therefore W \stackrel{a}{\sim} N \left(p_1 - p_2, \frac{p_1 + p_2 - (p_1 - p_2)^2}{n} \right) \Rightarrow \text{근사 Z 검정 or 카이제곱}$
		2표본 이항 p $H_0: p_1 = p_2, H_1: p_1 \neq p_2, \{X_{n1}\} \stackrel{\text{iid}}{\sim} B(1, p_1), \{Y_{n2}\} \stackrel{\text{iid}}{\sim} B(1, p_2)$ Wald $\hat{p}_1 \stackrel{a}{\sim} N \left(p_1, \frac{p_1(1-p_1)}{n_1} \right), \hat{p}_2 \stackrel{a}{\sim} N \left(p_2, \frac{p_2(1-p_2)}{n_2} \right), \text{Cov}(\hat{p}_1, \hat{p}_2) = 0$ $\hat{p}_1 - \hat{p}_2 \stackrel{a}{\sim} N \left(p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} \right) \& \text{Slutsky } (\hat{p}_1 \xrightarrow{P} p_1, \hat{p}_2 \xrightarrow{P} p_2)$ $\Rightarrow \text{근사 Z 검정 or 카이제곱}$

7. 충분성 (Sufficiency) – 통계량의 성질

통계량 Review	통계량	① 점추정: $\theta \in \Omega$ 에 대한 추정량 $\hat{\theta}$ *통계량 (Statistic): $T = T(X_1, \dots, X_n)$ (표본에 대한 함수) ② 95% CI: $0.95 = P_{\theta}[\theta \in (\hat{\theta}_L, \hat{\theta}_U)]$ * $\theta \in (\hat{\theta}_L, \hat{\theta}_U)$ 인 베르누이 사건 $\sim B(1, 0.95)$
	성질	1) 일치추정량: $T_n \xrightarrow{P} \theta$ 면 $\Leftrightarrow T_n$ 은 θ 의 일치 추정량 2) 불편추정량: $E(T) = \theta \Leftrightarrow T$ 는 θ 의 불편 추정량 (bias = 0) ① MVUE : 분산 최소인 불편추정량 (UE) \rightarrow 유일 ② CRB : $\text{Var}(T) \geq 1/\{nI(\theta)\}$ 3) MLE: $\hat{\theta} = \text{Argmax}[L(\theta)] = \text{Argmax}[\prod_{i=1}^n f(x_i, \theta)]$ ① MLE는 근사적으로 효율적 ② $\hat{\theta} \stackrel{a}{\sim} N\left(\theta_0, \frac{1}{nI(\theta_0)}\right) \Rightarrow Z$ or χ^2 화 하면 Wald statistic 4) $ARE(T_1, T_2) = \frac{\text{Var}(T_2)}{\text{Var}(T_1)}$
	Bias MSE	1) $\text{bias}(\hat{\theta}) = E(\hat{\theta} - \theta) = E(\hat{\theta}) - \theta$ * $\text{bias}(g(\hat{\theta})) = E(g(\hat{\theta}) - g(\theta))$ 2) Mean square error (MSE): $\text{mse}(\hat{\theta}) = E\{(\hat{\theta} - \theta)^2\} = \text{Var}(\hat{\theta}) + \{\text{bias}(\hat{\theta})\}^2$ 3) Mean absolute error (MAE): $\text{mse}(\hat{\theta}) = E\{ \hat{\theta} - \theta \}$
	적률 추정법 (MoM)	r차 표본적률 \xrightarrow{P} r차 모적률 (\Rightarrow 연립하여 모수 추정량 구함; 일반적으로 비선형) ex) $\{X_i\} \stackrel{iid}{\sim} \text{Gamma}(k, \theta)$ $m_1 = \frac{\sum_{i=1}^n X_i}{n} = \hat{k}\hat{\theta}$, $m_2 = \frac{\sum_{i=1}^n X_i^2}{n} = \hat{k}(\hat{\theta})^2 + (\hat{k}\hat{\theta})^2$ $\hat{\theta} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n\bar{X}} = \left(\frac{n-1}{n}\right) \frac{S^2}{\bar{X}} = \frac{S_{mle}^2}{\bar{X}}$, $\hat{k} = \frac{n(\bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \left(\frac{n}{n-1}\right) \frac{\bar{X}}{S^2} = \frac{\bar{X}^2}{S_{mle}^2}$
충분성	정의	$Y = u(X_1, \dots, X_n)$ 에 대해 $X Y$ 가 θ 와 무관함 $\Leftrightarrow Y$ 가 θ 에 대한 모든 정보 다 포함 (e.g. $Y = \sum_{i=1}^n X_i$) $\frac{\prod_{i=1}^n f(x_i, \theta)}{f_Y(y; \theta)} = H(x_1, \dots, x_n)$ (f_Y : Y의 pdf)
	Neyman-Fisher	$[Y \text{가 } \theta \text{의 SS}] \Leftrightarrow \prod_{i=1}^n f(x_i, \theta) = f_Y(y; \theta) H(x_1, \dots, x_n) = g(y; \theta) h(x_1, \dots, x_n)$ (임의의 g, h 로 인수분해)
	Rao-Blackwell	θ 의 충분통계량 Y_1 , 불편추정량 Y_2 에 대해, 새로운 불편추정량 $\varphi(Y_1) = E(Y_2 Y_1)$ $E(\varphi(Y_1)) = E[E(Y_2 Y_1)] = E(Y_2) = \theta$ 2) $\text{Var}(\varphi(Y_1)) = \text{Var}(E(Y_2 Y_1)) \leq \text{Var}(Y_2)$ \therefore New UE $\varphi(Y_1) = E(Y_2 Y_1)$ 는 Old UE Y_2 보다 분산이 작다. *실전: $E(\varphi(Y_1)) = \theta$ 인 $\varphi(Y_1)$ 찾기
	Lehmann-Scheffe	① 통계량 Y 는 complete (완비) if 모든 θ 에서 $E(h(Y)) = 0 \Rightarrow h(t) = 0$ 만 가능함 ② 레만-셰페: CSS인 Y_1 으로 Rao-Blackwellization $\rightarrow \varphi(Y_1) = E(Y_2 Y_1)$ 는 유일한 MVUE of θ pdf CSS인 Y_1 에 대해 불편추정량 $\varphi(Y_1), \psi(Y_1)$ 존재 $\Rightarrow E(\varphi(Y_1) - \psi(Y_1)) = \theta - \theta = 0$ 완비족 $\{f_{Y_1}(y; \theta); \theta \in \Omega\}$ 에 대해 위 등식은 $\varphi(Y_1) = \psi(Y_1)$ 에서만 성립 (더 이상 분산 못 줄임)
	지수족 Exponential Family	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta(\theta))]$ ($x \in S$) ($\eta = \eta(\theta)$ 는 자연 모수) *정칙: 1) S 가 θ 에 종속 X, 2) $\eta(\theta)$ 연속, 3) (연속이면) $H(x)$ 연속 in $\{K'(x) \neq 0\}$ ① 지수족: 이산 (포아송, 이항, 기하, 음이항, 다항 등) / 연속 (감마, 베타, 정규 등) ② $Y = \sum_{i=1}^n T(x)$ 는 θ 의 CSS ③ $E(T(X)) = A'(\eta)$, $\text{Var}(T(X)) = A''(\eta)$
	결합 충분통계량 (다중모수)	$\mathbf{Y} = (Y_1, \dots, Y_m)^T \in \mathbb{R}^m$ & $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \mathbb{R}^p$ 에 대해 (일반적으로 $m = p$) $\prod_{i=1}^n f(x_i, \boldsymbol{\theta}) = f_Y(\mathbf{y}; \boldsymbol{\theta}) H(x_1, \dots, x_n) = g(\mathbf{y}; \boldsymbol{\theta}) h(x_1, \dots, x_n)$ *순서통계량 $\mathbf{Y} = (Y_1, \dots, Y_n)^T$; $Y_1 < \dots < Y_n \rightarrow$ 모든 연속분포의 결합충분통계량
	보조통계량 (Ancillary)	$A = a(X_1, \dots, X_n)$ 가 θ 와 무관 ex) 정규분포 iid의 S^2 : μ 에 대해 ancillary 1) Basu 정리: $\{Y \text{가 } \theta \text{의 CSS}\} \& \{Z \text{가 } \theta \text{의 ancillary}\} \Leftrightarrow \{Y \text{와 } Z \text{는 독립}\}$ ex) $\bar{X} \perp S^2, \{X_i\} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ 2) ① 위치불변: $Z = u(W_1 + \theta, \dots, W_n + \theta) = u(W_1, \dots, W_n)$ ex) $S^2, \max\{X_i\} - \min\{X_i\}, \frac{1}{n} \sum_{i=1}^n X_i - Q_2 $ ② 척도불변: $Z = u(\theta W_1, \dots, \theta W_n) = u(W_1, \dots, W_n)$ ex) $X_1/(X_1 + X_2), X_1^2/\sum_{i=1}^n X_i^2, \min\{X_i\}/\max\{X_i\}$ ③ 위치척도불변: $Z = u(\theta_1 W_1 + \theta_2, \dots, \theta_1 W_n + \theta_2) = u(W_1, \dots, W_n)$ ex) $(X_i - \bar{X})/S^2$
	MLE	$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i, \theta) = f_Y(y; \theta) H(x_1, \dots, x_n) \rightarrow L$ 과 f_Y 동시에 극대화 by θ ① MLE $\hat{\theta}$ 이 유일 $\Leftrightarrow \hat{\theta}$ 는 충분통계량 Y 의 함수 $\therefore \hat{\theta} = \text{argmax}(L(\theta, \mathbf{x})) = \text{argmax}(f_Y(y; \theta))$ ② MLE $\hat{\theta}$ 가 충분통계량 $\Leftrightarrow \hat{\theta}$ 는 최소 충분통계량 (MSS) *최소충분: reduced from 다른 충분통계량

7. 충분성 (Sufficiency) – 통계량의 성질

지수족	지수족	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta(\theta))] \quad (x \in S) \quad (\eta = \eta(\theta) \text{는 자연 모수})$ *정칙: 1) S 가 θ 에 종속 \mathbf{X} , 2) $\eta(\theta)$ 연속, 3) (연속이면) $H(\mathbf{x})$ 연속 in $\{K'(x) \neq 0\}$ ① 지수족: 이산 (포아송, 이항, 기하, 음이항, 다항 등) / 연속 (감마, 베타, 정규 등) ② $Y = \sum_{i=1}^n T(x)$ 는 θ 의 CSS ③ $E(T(X)) = A'(\eta), \text{Var}(T(X)) = A''(\eta)$					
	다변량 확장	1변수 1모수	$f(x; \theta) = \exp[\eta(\theta)T(x) + H(x) - A(\eta)]$				
		1변수 다중모수	$f(x; \boldsymbol{\theta}) = \exp[\boldsymbol{\eta}(\boldsymbol{\theta}) \cdot \mathbf{T}(x) + H(x) - A(\boldsymbol{\eta})]$				
		다변량 다중모수	$f(\mathbf{x}; \boldsymbol{\theta}) = \exp[\boldsymbol{\eta}(\boldsymbol{\theta}) \cdot \mathbf{T}(\mathbf{x}) + H(\mathbf{x}) - A(\boldsymbol{\eta})]$				
		기대값	$\nabla A(\boldsymbol{\eta}) = E[\mathbf{T}(\mathbf{x})], \mathbf{H}[A(\boldsymbol{\eta})] = \text{Cov}(\mathbf{T}(\mathbf{x}))$ $\nabla A(\boldsymbol{\eta}_{mle}) = \frac{1}{n} \sum_{i=1}^n \mathbf{T}(\mathbf{x}_i)$				
	예시	분포	모수 θ	자연모수 η	역모수	$\mathbf{T}(\mathbf{x})$	$A(\boldsymbol{\eta})$
		베르누이	p	$\ln \frac{p}{1-p}$	$\frac{1}{1+e^{-\eta}}$ * logistic function	x	$\ln(1+e^\mu)$
		이항					$n \ln(1+e^\mu)$
		푸아송	m	$\ln m$	e^η	x	e^η
		음이항(r)	p	$\ln(1-p)$	$1-e^\eta$	x	$-r \ln(1-e^\mu)$
		다항(n)	$\begin{bmatrix} p_1 \\ \vdots \\ p_{k-1} \end{bmatrix}$	$\begin{bmatrix} \ln \frac{p_1}{p_k} \\ \vdots \\ \ln \frac{p_{k-1}}{p_k} \end{bmatrix}$	$\begin{bmatrix} \frac{\exp(\eta_1)}{1 + \sum_{j=1}^{k-1} \exp(\eta_j)} \\ \vdots \\ \frac{\exp(\eta_{k-1})}{1 + \sum_{j=1}^{k-1} \exp(\eta_j)} \end{bmatrix}$ * softmax function	$\begin{bmatrix} x_1 \\ \vdots \\ x_{k-1} \end{bmatrix}$	$n \ln(1 + \sum_{j=1}^{k-1} \exp(\eta_j))$
		감마	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \alpha-1 \\ -\frac{1}{\beta} \end{bmatrix}$	$\begin{bmatrix} \eta_1+1 \\ -\frac{1}{\eta_2} \end{bmatrix}$	$\begin{bmatrix} \ln x \\ x \end{bmatrix}$	$\ln \Gamma(\eta_1+1) - (\eta_1+1) \ln(-\eta_2)$
		지수	β	$-\frac{1}{\beta}$	$-\frac{1}{\eta}$	x	$-\ln(-\eta)$
		카이제곱	ν	$\frac{\nu}{2}-1$	$2(\eta+1)$	$\ln x$	$\ln \Gamma(\eta+1) + (\eta+1) \ln 2$
		베타	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \alpha \\ \beta \end{bmatrix}$	$\begin{bmatrix} \eta_1 \\ \eta_2 \end{bmatrix}$	$\begin{bmatrix} \ln x \\ \ln(1-x) \end{bmatrix}$	$\ln B(\alpha, \beta) = \ln \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
		정규 기지 σ^2	μ	$\frac{\mu}{\sigma^2}$	$\sigma^2 \eta$	x	$\frac{1}{2} \sigma^2 \eta^2$
		정규 미지 σ^2	$\begin{bmatrix} \mu \\ \sigma^2 \end{bmatrix}$	$\begin{bmatrix} \frac{\mu}{\sigma^2} \\ -\frac{1}{2\sigma^2} \end{bmatrix}$	$\begin{bmatrix} -\frac{\eta_1}{2\eta_2} \\ -\frac{1}{2\eta_2} \end{bmatrix}$	$\begin{bmatrix} x \\ x^2 \end{bmatrix}$	$-\frac{\eta_1^2}{4\eta_2} - \frac{1}{2} \ln(-2\eta_2)$
		다변량 정규	$\begin{bmatrix} \boldsymbol{\mu} \\ \boldsymbol{\Sigma} \end{bmatrix}$	$\begin{bmatrix} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} \\ -\frac{1}{2} \boldsymbol{\Sigma}^{-1} \end{bmatrix}$	$\begin{bmatrix} -\frac{1}{2} \boldsymbol{\eta}_2^{-1} \boldsymbol{\eta}_1 \\ -\frac{1}{2} \boldsymbol{\eta}_2^{-1} \end{bmatrix}$	$\begin{bmatrix} \mathbf{x} \\ \mathbf{xx}^T \end{bmatrix}$	$-\frac{1}{4} \boldsymbol{\eta}_1^T \boldsymbol{\eta}_2^{-1} \boldsymbol{\eta}_1 - \frac{1}{2} \ln -2\boldsymbol{\eta}_2 $

*. 가설의 최적검정

8. 정규모형 추론: ANOVA / 회귀분석

2-way ANOVA	1-way ANOVA: b개 처리 별 → 동일 크기 (a) 샘플 간 평균 동일성 2-way ANOVA: 요인 A (n=1, ..., a) + 요인 B (n=1, ..., b) ① $X_{ij} \stackrel{iid}{\sim} N(\mu_{ij}, \sigma^2), n = ab$ ② $\mu_{ij} = \mu + (\bar{\mu}_{i.} - \mu) + (\bar{\mu}_{.j} - \mu) = \mu + \alpha_i + \beta_j \quad (\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = 0)$ *Additive model ($\because \sum_{j=1}^b \sum_{i=1}^a \mu_{ij} = \sum_{i=1}^a b \bar{\mu}_{i.} + \sum_{j=1}^b a \bar{\mu}_{.j} - ab\mu = ab\mu$)		b개 (j) 처리 개수	
		a개 (i) 처리 개수	$\begin{matrix} X_{11} & X_{12} & \cdots & X_{1j} & \cdots & X_{1b} & \bar{X}_{1.} \\ X_{21} & X_{22} & \cdots & X_{2j} & \cdots & X_{2b} & \bar{X}_{2.} \\ \vdots & \vdots & \cdots & \vdots & \cdots & \vdots & \vdots \\ X_{i1} & X_{i2} & \cdots & X_{ij} & \cdots & X_{ib} & \bar{X}_{i.} \\ \vdots & \vdots & \cdots & \vdots & \cdots & \vdots & \vdots \\ X_{a1} & X_{a2} & \cdots & X_{aj} & \cdots & X_{ab} & \bar{X}_{a.} \\ \bar{X}_{.1} & \bar{X}_{.2} & \cdots & \bar{X}_{.j} & \cdots & \bar{X}_{.b} & \bar{X}_{..} \end{matrix}$	
	$Q = Q_2 + Q_4 + Q_5 \Leftrightarrow (ab-1)S^2 = b \sum_{i=1}^a (\bar{X}_{i.} - \bar{X}_{..})^2 + a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 + \sum_{j=1}^b \sum_{i=1}^a (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$			
	*핵심 질문: 요인 a,b의 effect ① $H_{0A}: \alpha_1 = \cdots = \alpha_a = 0$ ② $H_{0B}: \beta_1 = \cdots = \beta_b = 0$ *열간 차이 모델 (H_{0B}, H_{1B}) $H_{0B}: \hat{\sigma}_\omega^2 = \frac{Q_4 + Q_5}{ab} = \sum_{i=1}^a \sum_{j=1}^b \frac{(X_{ij} - \bar{X}_{i.})^2}{ab}$ $H_{1B}: \hat{\sigma}_\Omega^2 = \frac{Q_5}{ab}$ $\Lambda = (\hat{\sigma}_\Omega^2 / \hat{\sigma}_\omega^2)^{\frac{ab}{2}} \Leftrightarrow F = \frac{Q_4 / (b-1)}{Q_5 / [(a-1)(b-1)]} \geq c$ *행간 차이 모델 (H_{0A}, H_{1A}) $\Leftrightarrow F = \frac{Q_2 / (b-1)}{Q_5 / [(a-1)(b-1)]} \geq c$			
회귀 분석	2-way ANOVA 일반화: 칸당 c>1개 관측값. (위 모델은 칸 당 1개) → 총 n=abc (3차원 구조) ① $X_{ijk} \stackrel{iid}{\sim} N(\mu_{ij}, \sigma^2), n = abc$ ② $\mu_{ij} = \mu + (\bar{\mu}_{i.} - \mu) + (\bar{\mu}_{.j} - \mu) + (\mu_{ij} - \bar{\mu}_{i.} - \bar{\mu}_{.j} + \mu) = \mu + \alpha_i + \beta_j + \gamma_{ij} \quad (\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = 0, \sum_{i=1}^a \gamma_{ij} = \sum_{j=1}^b \gamma_{ij} = 0)$ (γ_{ij} : 교호작용 모수, interaction parameter) *핵심 가설: 교호작용 모수=0 $H_{0AB}: \gamma_{ij} = 0, \text{ for all } (i, j) \Leftrightarrow F\text{통계량} \geq c$			
	① 미래의 관측값 $Y = y$ 를 예측할 수 없지만, $E(Y)$ 는 예측 가능하다. ② 선형 모형: $E(Y) = \alpha + \beta x + \gamma x^3 + \delta \log x$ (선형 모형: 모수에 대한 선형성) *추후 정리 with 몽고메리 서적			

9. 비모수-로버스트 통계학: 추후 정리

10. 베이지안 통계학 기본

베이 지안 절차	사전/사후 분포	<p>① 기본: $X_i \theta \stackrel{iid}{\sim} f(x \theta)$ (X는 θ에 의존적인 확률 분포에서 추출)</p> <p>② 사전분포: $\theta \sim h(\theta)$ *모수의 prior</p> <p>③ 우도: $L(\mathbf{x} \theta) = f(x_1 \theta) \cdots f(x_n \theta)$ *표본 $\mathbf{X}^T = (X_1, \dots, X_n)$</p> <p>④ 결합 PDF: $g(\mathbf{x}, \theta) = L(\mathbf{x} \theta)h(\theta)$</p> <p>$\therefore$ 사후분포: $k(\theta \mathbf{x}) = \frac{g(\mathbf{x}, \theta)}{g_1(\mathbf{x})} = \frac{L(\mathbf{x} \theta) h(\theta)}{g_1(\mathbf{x})} = \frac{L(\mathbf{x} \theta) h(\theta)}{\int_{-\infty}^{\infty} L(\mathbf{x} \theta) h(\theta) d\theta} \Rightarrow k(\theta \mathbf{x}) \propto L(\mathbf{x} \theta)h(\theta)$</p> <p>*공액분포족: 사전$\leftrightarrow$사후 분포가 같은 족에 속함 (e.g. $X \theta$가 푸아송 \rightarrow 공액족은 감마분포 $X \theta$가 이항분포 \rightarrow 공액족은 베타분포)</p>
		<p><다변량 조건부/주변 분포 이용한 유도></p> <p>1) $h(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \dots, x_n, \theta) dx_1 \cdots dx_n$</p> <p>2) $L(\mathbf{x} \theta) = L_{\mathbf{x} \theta}(x_1, \dots, x_n \theta) = \frac{g(\mathbf{x}, \theta)}{h(\theta)}$</p> <p>3) $g_1(\mathbf{x}) = g_1(x_1, x_2, \dots, x_n) = \int_{-\infty}^{\infty} g(\mathbf{x}, \theta) d\theta$ (초등 적분으로 해결 안되는 경우 \rightarrow MCMC 등의 근거)</p>
	베이지안 추정	<p>1) 점추정: Maximum A Posteriori (MAP): 사후확률을 최대화하는 값으로 모수 추정 ($\hat{\theta}_{MAP}$)</p> <p>① MLE는 모수 미지의 정해진 분포에서 iid 추출한 값들 \rightarrow 샘플 기준으로 모수 추정 $\therefore \hat{\theta}_{MLE} = \underset{\theta}{\operatorname{argmax}} L(\mathbf{x} \theta)$</p> <p>② MAP는 모수$\sim$사전분포 + iid 추출 샘플들 \rightarrow 두 가지를 혼합한 사후 분포에서 모수 추정 $\therefore \hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} L(\mathbf{x} \theta)h(\theta)$</p> <p>③ 균등 Prior [=Beta(1,1)] $\rightarrow h(\theta)$가 상수이므로 $\underset{\theta}{\operatorname{argmax}} L(\mathbf{x} \theta)h(\theta) = \underset{\theta}{\operatorname{argmax}} L(\mathbf{x} \theta) \Leftrightarrow \hat{\theta}_{MLE} = \hat{\theta}_{MAP}$ (기타 점추정 방식: 1) MAP, 2) 사후 평균, 3) 사후 중간값 등)</p>
		<p>2) 구간 추정: $P[u(\mathbf{x}) < \theta < v(\mathbf{x}) \mathbf{X} = \mathbf{x}] = \int_{u(\mathbf{x})}^{v(\mathbf{x})} k(\theta \mathbf{x}) d\theta = 0.95$</p> <p>$\Leftrightarrow$ Credible interval (신용구간) or 사후확률구간 0.95</p> <p>① HPDI: 사후분포에서 가장 짧은 길이 / ② Equal-tail CI (양측 꼬리 넓이 동일)</p>
		<p>베이지안 검정</p> <p>$P(\theta \in \omega_0 \mathbf{x})$ vs. $P(\theta \in \omega_1 \mathbf{x}) \rightarrow$ 더 큰 쪽으로 가설 채택 (사후 분포 상 가설의 모수 영역 더 넓은 쪽)</p>
	계층적 베이지	<p>① $X \theta \sim f(x \theta)$ ② $\theta \gamma \sim h(\theta \gamma)$ ③ $\gamma \sim \psi(\gamma)$ (γ: 초모수)</p> <p>$k(\theta \mathbf{x}) = \frac{\int_{-\infty}^{\infty} L(\mathbf{x} \theta)h(\theta \gamma)\psi(\gamma)d\gamma}{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} L(\mathbf{x} \theta)h(\theta \gamma)\psi(\gamma)d\gamma d\theta}$</p>
	경험적 베이지	<p>① $X \theta \sim f(x \theta)$ ② $\theta \gamma \sim h(\theta \gamma)$</p> <p>$m(\mathbf{x} \gamma) = \int_{-\infty}^{\infty} g(\mathbf{x}, \theta \gamma) d\theta = \int_{-\infty}^{\infty} L(\mathbf{x} \theta) h(\theta \gamma) d\theta \rightarrow$ 새로운 우도 최대화 하는 $\hat{\gamma}$ 구함 \rightarrow 위 조건부 사전분포에 대입하여 진행</p>
몬테 카를로 기법	<div> <div>깁스 샘플러</div> <div></div> </div>	